

Quantifizierung von Verbuschung in Natura-2000-Heideflächen: Ein Vergleich von 2D- und 3D-Deep-Learning-Verfahren zur drohnengestützten Habitatbewertung

BACHELORARBEIT

zur Erlangung des akademischen Grades

Bachelor of Science (B.Sc.)

Universität Münster
Institut für Geoinformatik

Erstgutachter: *Dr. Marvin Ludwig*

Zweitgutachter: *Dr. Torsten Prinz*

Vorgelegt von: *Luis Waldeyer*

Matrikelnummer: 545669

Münster, 15. September 2026

Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VI
1 Einleitung und Motivation	1
2 Theoretischer Hintergrund	4
2.1 Ökologischer Hintergrund	4
2.2 Structure from Motion	6
2.2.1 Grundprinzip	6
2.2.2 Ablauf der Rekonstruktion	7
2.3 Convolutional Neural Networks (CNNs)	9
2.3.1 Aufbau und Funktionsweise	9
2.3.2 Anwendung in der Fernerkundung	11
2.4 Geometric Deep Learning	12
2.4.1 Semantische Segmentierung von 3D-Punktwolken	12
2.4.2 PointNet	13
2.4.3 PointNet++	13
2.5 Evaluationsmetriken	15
2.5.1 Metriken der Segmentierung	15
2.5.2 Metriken des Verbuschungsgrades	17
3 Methodik	19
3.1 Untersuchungsgebiete und Datengrundlage	19
3.1.1 Untersuchungsgebiete	19
3.1.2 Befliegung und photogrammetrische Auswertung	19
3.1.3 Manuelle Annotation und Klassenschema	20
3.2 Datenvorverarbeitung	21
3.2.1 Aufbereitung und Prüfung der Ausgangsdaten	21
3.2.2 Bodenerkennung und Höhennormalisierung	22
3.2.3 Übertragung der Labels auf die Punktwolke	22
3.2.4 Höhenbasierte Labelkorrektur	24
3.2.5 Lokale Höhenmerkmale	26
3.2.6 Kachelung	27
3.2.7 Räumlich getrennte Datenaufteilung	28

3.3	Modell und Trainingssetup	28
3.3.1	Architektur	28
3.3.2	Verlustfunktion	29
3.3.3	Training	30
3.4	Ablationsstudie	30
3.5	Evaluation	32
3.6	Quantifizierung des Verbuschungsgrades	33
3.6.1	Vorbereitung der Befliegungsgebiete	33
3.6.2	Anwendung des Modells	33
3.6.3	Bezugsfläche und Verbuschungsmaß	34
3.6.4	Referenzdaten und Validierung	35
4	Ergebnisse und Diskussion	37
4.1	Ergebnisse der Ablationsstudie	37
4.2	Güte der semantischen Segmentierung	40
4.3	Anwendung auf die Befliegungsgebiete	41
4.4	Berechneter Verbuschungsgrad im Vergleich zur Kartierung	43
4.5	Diskussion	47
4.5.1	Bedeutung der Höheninformation	47
4.5.2	Zeitlicher Abstand zwischen Kartierung und Befliegung	48
4.5.3	Vergleich mit der Geländekartierung	48
4.5.4	Segmentierungsgüte und Herkunft der Labels	49
4.5.5	Limitationen	50
4.5.6	Anwendbarkeit in der Praxis	51
5	Fazit und Ausblick	52
5.1	Fazit	52
5.2	Ausblick und Einordnung	53
	Literaturverzeichnis	54

Abbildungsverzeichnis

Abbildung 1:	Grundprinzip von Structure from Motion	7
Abbildung 2:	Ablauf der inkrementellen SfM-Pipeline	8
Abbildung 3:	Funktionsweise der Faltung	10
Abbildung 4:	Aufbau eines CNN	11
Abbildung 5:	Architektur von PointNet++	14
Abbildung 6:	Fehllabel durch den Label-Transfer	24
Abbildung 7:	Wirkung der höhenbasierten Labelkorrektur	25
Abbildung 8:	Vorhergesagte Vegetationsklassen im Gebiet HeideWildnis	42
Abbildung 9:	Verbuschungsgrad im Gebiet HeideWildnis	46
Abbildung 10:	Verbuschungsgrad der vier Befliegungsgebiete	47

Tabellenverzeichnis

Tabelle 1: Übersicht der Ablationsläufe	31
Tabelle 2: Ergebnisse der Läufe run01 bis run04	37
Tabelle 3: Ergebnisse der Läufe run05 bis run09	38
Tabelle 4: Klassenweise Kennzahlen des Modells run07	40
Tabelle 5: Konfusionsmatrix des Modells run07	41
Tabelle 6: Vergleich der Verbuschungsdefinitionen	44
Tabelle 7: Kartierter und berechneter Verbuschungsgrad der Heidepolygone	45

Abkürzungsverzeichnis

CNN	Convolutional Neural Network
CSF	Cloth Simulation Filter
DBU	Deutsche Bundesstiftung Umwelt
FFH	Flora-Fauna-Habitat
IoU	Intersection over Union
mIoU	mittlere Intersection over Union
MLP	Multilayer Perceptron
OA	Overall Accuracy
ONNX	Open Neural Network Exchange
PDAL	Point Data Abstraction Library
RMSE	Root Mean Squared Error
RTK	Real Time Kinematic
SfM	Structure from Motion
SNIC	Simple Non-Iterative Clustering
UAS	Unmanned Aircraft System
UAV	Unmanned Aerial Vehicle

1 Einleitung und Motivation

Der Schutz und Erhalt naturnaher Lebensräume ist eine zentrale Aufgabe des europäischen Naturschutzes. Allein das Natura-2000-Netzwerk umfasst rund 25.000 Schutzgebiete in den EU-Mitgliedsstaaten, deren Zustand regelmäßig erfasst und überwacht werden muss [1]. Indikatoren des Habitatzustands sind dabei unverzichtbar, um Fortschritte im Naturschutz nachzuvollziehen. Ihre Erhebung über große Flächen und in feiner Auflösung bleibt jedoch eine Herausforderung [1].

Klassischerweise kartieren Fachleute die Vegetation im Gelände, indem sie die Flächen begehen und die Daten vor Ort manuell erheben. Weil dieses Vorgehen zeit- und kostenintensiv ist, deckt es meist nur kleine Ausschnitte ab, woraus sich der Bedarf an fernerkundlichen Verfahren ergibt. Vor allem das drohnen- bzw. UAS-gestützte Monitoring liefert hochauflösende Daten und senkt den Aufwand intensiver Geländekartierungen erheblich, wobei es Genauigkeiten erzielt, die klassische Verfahren der Luftbildinterpretation einholen oder übertreffen [2].

Speziell für Heideflächen ist belegt, dass sich der Erhaltungszustand fernerkundlich bewerten lässt, sofern die Auswertung eng an die etablierten feldbasierten Kartierschemata angelehnt ist [3]. Allerdings besteht weiterhin eine deutliche Lücke zwischen den feldbasierten Monitoring-Richtlinien und den bestehenden fernerkundlichen Ansätzen, was deren praktische Anwendung erschwert [3]. Der entscheidende Haken klassischer Fernerkundung liegt zudem darin, dass die erhobenen Daten wiederum manuell von Fachleuten ausgewertet werden müssen, was erneut sehr zeitaufwendig ist. Genau hier wird der Einsatz künstlicher Intelligenz interessant, da sie die Auswertung der Fernerkundungsdaten automatisieren kann.

Verfahren des maschinellen Lernens sind in der Fernerkundung seit Jahren etabliert, wobei klassische Algorithmen wie Random Forest (RF) vor allem zur Klassifizierung der Bodenbedeckung dienen. Eischeid et al. [4] kartierten mit einem überwachten RF-Klassifikator die Vegetation arktischer Tundra aus Drohnenbildern, während Cao et al. [5] Mangrovenarten objektbasiert aus hochauflösenden UAV-Hyperspektraldaten klassifizierten.

Einen entscheidenden Fortschritt brachten Deep Learning und insbesondere die Convolutional Neural Networks (CNNs), welche die Objekterkennung und damit das Habitatmonitoring deutlich verbessert haben [6]. Ihr wesentlicher Vorteil liegt darin, dass sie die entscheidenden Merkmale selbstständig aus komplexen, hochdimensionalen Rohdaten lernen, wohingegen klassische Algorithmen eine manuelle Merkmalsextraktion voraussetzen und bei unregelmäßigen Datenmengen rasch an ihre Grenzen stoßen.

Aus den genannten Gründen ist es nicht verwunderlich, dass aktuelle Projekte im Bereich des Habitat-Qualitätsmonitorings auf Deep Learning zurückgreifen. So auch das Projekt des Instituts für Landschaftsökologie der Universität Münster: “Ready for Take-Off?! How to integrate UAS remote sensing into the monitoring of EU habitats directive sites?”. Dort wird untersucht, wie sich UAS-basierte Fernerkundung in das Monitoring von FFH-Gebieten integrieren lässt, zumal UAS deutlich hochauflösendere Daten liefern als Satellitenbilder und flexibler einsetzbar sind. Die zugrunde liegende Flora-Fauna-Habitat-Richtlinie bildet innerhalb des Natura-2000-Netzwerks das Rückgrat des europäischen Naturschutzes [7] und definiert damit die Schutzgebiete, deren Erhaltungszustand im Projekt erfasst werden soll.

Neben dem Arteninventar und der Habitatstruktur, etwa den Lebenszyklusphasen von *Calluna* oder dem Sandanteil, sollen vor allem Degradationsindikatoren erfasst werden. Unter ihnen zum Beispiel der Deckungsgrad invasiver Neophyten, von Gras sowie von Sträuchern und Bäumen. Letzterer, die Verbuschung, verdrängt die charakteristische Zwergstrauchvegetation und löst die offene Struktur der Heide auf, weshalb er als zentraler Indikator für einen ungünstigen Erhaltungszustand gilt. Um den Erhaltungszustand von Heideflächen verlässlich beurteilen zu können, muss sich der Verbuschungsgrad daher objektiv, flächendeckend und reproduzierbar erfassen lassen.

Dazu wurden die Flächen mit einer Drohne befliegen, um hochauflösende RGB-Bilder zu gewinnen und aus den überlappenden Aufnahmen mittels Structure from Motion eine dreidimensionale Punktwolke der Fläche zu rekonstruieren. Diese Daten bilden den Ausgangspunkt für ein Deep-Learning-Modell, das die Vegetation segmentiert und jeden Punkt einer Klasse zuordnet, woraus sich anschließend der Verbuschungsgrad berechnen lässt.

Im Projekt entstehen aus denselben Befliegungen zwei Datensätze, nämlich die RGB-Orthomosaik und die daraus gerechneten SfM-Punktwolken. Für die Orthomosaik ist das CNN U-Net vorgesehen, für die Punktwolken PointNet++, ein Netz, das eigens für unstrukturierte 3D-Punktmengen entwickelt wurde. Aufgabe dieser Arbeit ist der dreidimensionale Weg, also die Entwicklung des Verfahrens, seine Erprobung in einer Ablationsstudie und seine Bewertung an einer im Gelände erhobenen Referenz. Ein Vergleich beider Ansätze bleibt einer späteren Arbeit vorbehalten, weil die Ergebnisse des 2D-Ansatzes zum Zeitpunkt dieser Arbeit noch nicht vorlagen.

Daraus ergeben sich zwei Forschungsfragen (FF) mit jeweils einer untergeordneten Teilfrage (TF), die den Weg von der Datenaufbereitung über die Segmentierung bis zur praktischen Nutzung abbilden:

FF1: Inwiefern eignet sich die semantische Segmentierung von 3D-SfM-Punktwolken mittels Deep Learning dazu, die für die Verbuschung von Heideflächen maßgeblichen Vegetationsklassen voneinander zu trennen?

TF1: Inwiefern lässt sich ein automatisierter Label-Transfer von 2D-Referenzdaten auf 3D-Punktwolken realisieren, um den Trainingsaufwand für tiefe neuronale Netze effizient zu gestalten?

FF2: Inwiefern stimmt der aus der segmentierten Punktwolke abgeleitete Verbuschungsgrad mit dem im Gelände kartierten Wert überein?

TF2: Wie stabil und anwenderfreundlich lässt sich das entwickelte Modell in eine bestehende GIS-Umgebung integrieren, um für Naturschutzpraktiker nutzbar zu sein?

Das übergeordnete Ziel ist schließlich ein vollständiger Workflow, der es Naturschutzpraktikern ermöglicht, den Verbuschungsgrad von Heideflächen effizient und zuverlässig zu erfassen.

Kapitel 2 (Theoretischer Hintergrund) legt die theoretischen Grundlagen. Kapitel 3 (Methodik) beschreibt das methodische Vorgehen, bevor in Kapitel 4 (Ergebnisse und Diskussion) die Ergebnisse evaluiert werden. Kapitel 5 (Fazit und Ausblick) fasst die Ergebnisse zusammen und benennt die verbleibenden Ansatzpunkte.

2 Theoretischer Hintergrund

Die Arbeit verbindet drei Felder, die zunächst getrennt eingeführt werden. Den Anfang macht die Ökologie der Heideflächen, aus der sich ergibt, warum sich die Verbuschung als Indikator eignet. Darauf folgen die photogrammetrische Rekonstruktion der Punktwolken und die neuronalen Netze, die sie auswerten, bevor die Kennzahlen beschrieben werden, an denen sich das Ergebnis später messen lässt.

2.1 Ökologischer Hintergrund

Als Heiden werden baumfreie Offenlandschaften auf nährstoffarmen, sauren Böden bezeichnet, die überwiegend von niedrigwüchsigen Zwergsträuchern aus der Familie der Heidekrautgewächse (Ericaceae) bewachsen sind. Prägende und namensgebende Leitart ist dabei die Besenheide (*Calluna vulgaris*) [8].

Die heutigen Heideflächen entstanden vor etwa 4.000 Jahren großflächig als Folge menschlicher Waldrodungen [8]. Vor allem die anschließende Beweidung hielt die Böden nährstoffarm und verhinderte zugleich, dass sich erneut Wald entwickelte, sodass sich die Heide ausbreiten konnte. Damit zählen Heideflächen zu den wichtigsten Kulturlandschaften Westeuropas, die sich durch lange menschliche Nutzung auszeichnen und im Gegensatz zur unberührten Naturlandschaft stehen. Erstreckten sie sich einst über mehrere Millionen Hektar, sind es heute nur noch etwa 350.000 Hektar, weshalb Heidegebiete als Flächen mit hohem Naturschutzpotential gelten [8].

Bleibt die zuvor beschriebene Nutzung aus, setzt an den Heidestandorten eine Sukzession ein, das heißt die gerichtete zeitliche Abfolge von Pflanzengesellschaften an einem Standort. Sie verläuft hier von der Zwergstrauchheide über eine zunehmende Vergrasung bis hin zu Gehölzen und langfristig zurück zum Wald. Ohne Pflege wachsen nach und nach Pioniergehölze auf, etwa Schlehe, Rose und Weißdorn als Sträucher sowie Birke, Zitterpappel und Kiefer als Bäume [9]. Diese Dominanzbestände überwuchern die Heide, indem sie ihr Nährstoffe entziehen und beschatten, sodass die niedrigwüchsigen Zwergsträucher zu wenig Licht erhalten. Neben der ausbleibenden Pflege ist die atmosphärische Stickstoffdeposition der zentrale Treiber der heutigen Degradation. Über Jahrzehnte gelangt Stickstoff aus Landwirtschaft und Verkehr über die Luft in die Heide und reichert die von Natur aus nährstoffarmen Böden schleichend an, wobei die Einträge vielerorts über der ökologischen Belastungsgrenze liegen [10]. Dadurch verschiebt sich die Konkurrenz zugunsten schnellwüchsiger Gräser, wodurch auf Trockenheiden die Besenheide (*Calluna vulgaris*) durch das Drahtschmielengras (*Deschampsia flexuosa*)

verdrängt wird und auf Feuchtheiden *Erica tetralix* durch das Pfeifengras (*Molinia caerulea*). Grund dafür ist, dass die Gräser den zusätzlichen Stickstoff effizienter aufnehmen und binden. Mit steigender Stickstoffverfügbarkeit wird die Konkurrenz zunehmend asymmetrisch, sodass die Zwergsträucher unterdrückt werden [11].

Vergrasung und die anschließende Verbuschung, die zunehmende Ausbreitung von Sträuchern und Gehölzen auf der eigentlich offenen Heidefläche, bilden aufeinanderfolgende Stadien derselben Sukzession, von denen für die vorliegende Arbeit die Verbuschung maßgeblich ist. Der Verbuschungsgrad bezeichnet das quantitative Maß dieser Ausbreitung, den Anteil der von Gehölzen bedeckten Fläche. Da die Verbuschung die charakteristische Zwergstrauchvegetation verdrängt und die offene Struktur der Heide auflöst, gilt sie als Degradationsindikator für den Erhaltungszustand von Heideflächen [3]. Der Erhaltungszustand wiederum ist die Bewertungsgröße, anhand derer die Flora-Fauna-Habitat-Richtlinie den Zustand der geschützten Lebensräume erfasst [7]. Ein hoher Verbuschungsgrad steht damit für einen ungünstigen Erhaltungszustand der Heide.

Um die Heide offenzuhalten und der Sukzession entgegenzuwirken, war seit jeher eine kontinuierliche Nutzung nötig, aus der die heutigen Pflegemaßnahmen hervorgegangen sind. Da die traditionellen Nutzungsformen wie Plaggen und Schafbeweidung weggefallen sind, übernimmt der Naturschutz die Offenhaltung heute mit gezielten Maßnahmen wie dem maschinellen Plaggenhieb, der Beweidung mit Heidschnucken, der Mahd, dem Entkusseln und dem kontrollierten Abbrennen. Allen diesen Verfahren ist gemeinsam, dass sie dem System Nährstoffe entziehen und aufkommende Gehölze zurückdrängen, bei anhaltend hoher Stickstoffdeposition aber in kurzen Abständen von etwa fünf Jahren wiederholt werden müssen [12].

Diese Pflegemaßnahmen sind personal-, kosten- und zeitintensiv, da sie sich nicht einmalig, sondern nur in wiederkehrenden Abständen durchführen lassen. Ihr gezielter Einsatz und die Kontrolle ihres Erfolgs setzen daher voraus, dass sich der Verbuschungsgrad großflächig, objektiv und wiederholbar bestimmen lässt. Das sind Anforderungen, die eine rein feldbasierte Kartierung nur schwer erfüllt [1]. Damit rücken fernerkundliche und automatisierte Auswertungsverfahren in den Fokus, deren methodische Grundlagen die folgenden Abschnitte behandeln.

2.2 Structure from Motion

2.2.1 Grundprinzip

Ausgangspunkt der semantischen Segmentierung sind Drohnenaufnahmen im sichtbaren (RGB-)Spektrum, zunächst zweidimensionale Bilder. Um daraus eine dreidimensionale Punktwolke zu gewinnen, lässt sich grundsätzlich zwischen zwei Wegen unterscheiden. Während LiDAR-Punktwolken direkt mit einem eigens dafür vorgesehenen Sensor am UAV erfasst und anschließend nur noch über eine herstellereigene Software in ein passendes Format wie LAS überführt werden müssen, wird die Punktwolke bei Structure from Motion (SfM) hingegen rechnerisch aus den RGB-Bildern abgeleitet. Spezielle Algorithmen kombinieren viele stark überlappende Einzelbilder zu 2D-Bildmosaiken und 3D-Punktwolken und nutzen die in den UAV-Bildern enthaltene photogrammetrische Information, um daraus hochaufgelöste Gelände- und Oberflächenmodelle zu erstellen. Für deren Berechnung stehen zwar zahlreiche Algorithmen zur Verfügung, doch die Wahl der Parameter und die damit verbundenen Unsicherheiten sind häufig nur unzureichend dokumentiert. Abhilfe schaffen quelloffene Softwarewerkzeuge wie COLMAP, die einen reproduzierbaren SfM-Workflow ermöglichen [1].

SfM beruht auf demselben Grundprinzip wie die stereoskopische Photogrammetrie, bei der sich die dreidimensionale Struktur einer Szene aus einer Reihe überlappender, versetzter Aufnahmen ableiten lässt, was dem räumlichen Sehen mit zwei Augen ähnelt (Abbildung 1). Der entscheidende Unterschied zur klassischen Photogrammetrie liegt darin, dass diese die Position und Ausrichtung der Kamera vorab kennen muss oder auf Passpunkte mit bekannten 3D-Koordinaten angewiesen ist. SfM benötigt beides nicht, da Kamerapositionen und Szenengeometrie allein aus den Bildern automatisch bestimmt werden. Möglich wird das durch einen Bündelausgleich (bundle adjustment), ein Ausgleichsverfahren, das alle Kameraparameter und 3D-Punktpositionen gleichzeitig so optimiert, dass der Rückprojektionsfehler minimal wird. Das Verfahren stammt ursprünglich aus der Computer-Vision-Forschung der 1990er Jahre und wurde durch die Arbeit von Snavely (2008) bekannt, die SfM-Ansätze im Kontext der Cloud-Anwendung Microsoft Photosynth beschreibt [13].




Abbildung 1: Grundprinzip von Structure from Motion: Aufnahme desselben Objekts aus mehreren überlappenden, versetzten Kamerapositionen [13].

Damit die Rekonstruktion gelingt, müssen dieselben Merkmale in mindestens drei Aufnahmen sichtbar sein. Ein hoher Überlappungsgrad und möglichst viele Bilder aus unterschiedlichen Positionen verbessern das Ergebnis, da sie die Zahl zuverlässiger Merkmalszuordnungen und die Redundanz des Systems erhöhen [13].

2.2.2 Ablauf der Rekonstruktion

Die konkrete Umsetzung dieses Prinzips lässt sich an der inkrementellen SfM-Pipeline (Abbildung 2) nachvollziehen, wie sie in COLMAP realisiert ist. Sie gliedert sich in zwei Phasen. In der ersten Phase, der Korrespondenzsuche (correspondence search), werden in jedem Bild lokale Merkmale erkannt, über mehrere Bilder hinweg einander zugeordnet und geometrisch auf Fehlzuordnungen geprüft. Das Ergebnis ist ein Scene Graph, der festhält, welche Bilder denselben Bildbereich zeigen und welche Punkte einander entsprechen. Er bildet die Grundlage für die Rekonstruktion [14].

In der zweiten Phase wird daraus schrittweise das dreidimensionale Modell aufgebaut, ausgehend von einem sorgfältig gewählten Bildpaar, das als Keim des Modells dient (initialization). Von dort aus werden nach und nach weitere Bilder eingehängt (image registration), indem ihre Kameraposition über bereits bekannte 3D-Punkte bestimmt wird, wohingegen neue 3D-Punkte durch Triangulation aus mehreren Blickwinkeln berechnet und der Wolke hinzugefügt werden. Kamerapositionen und 3D-Punkte werden dabei immer

wieder gemeinsam durch den Bündelausgleich verfeinert und um Ausreißer bereinigt, damit sich Fehler nicht aufschaukeln. Diese Abfolge aus Einhängen, Triangulieren und Ausgleichen wiederholt sich, bis alle Bilder registriert sind. Am Ende liefert SfM die Kamerapositionen (motion) und eine zunächst noch spärliche 3D-Punktwolke (structure) [14].




Abbildung 2: Ablauf der inkrementellen SfM-Pipeline in COLMAP [14].

Diese spärliche Wolke enthält zunächst nur die markanten Merkmalspunkte. Die für die spätere Segmentierung benötigte dichte Punktwolke erst in einem nachgelagerten, eigenständigen Verfahren entsteht, dem Multi-View Stereo (MVS) [15]. Den Kern bildet dabei die pixelweise Korrespondenzsuche, bei der für sehr viele Bildpunkte über mehrere Ansichten hinweg nach übereinstimmenden Korrespondenzen gesucht wird, woraus sich für jeden Punkt eine Tiefe schätzen lässt. Photometrische und geometrische Kriterien steuern dabei, welche Ansichten herangezogen werden. Die so entstandenen Tiefenkarten (depth maps) werden anschließend zu einer einheitlichen, dichten Szenenrepräsentation zusammengeführt [15].

Diese Punktwolke liegt allerdings zunächst in einem relativen Koordinatensystem, dem Bildraum (image space) und besitzt weder einen echten Maßstab noch eine räumliche Orientierung. Um sie in reale Koordinaten zu überführen, wird sie anschließend georeferenziert. Das bedeutet, dass die Wolke über wenige Passpunkte (ground control points, GCPs) mit bekannten Objektinformationen vom Bildraum in den realen Objektraum (object space) überführt wird. Dazu dient eine 3D-Ähnlichkeitstransformation, die Maßstab, Drehung und Verschiebung zwischen beiden Koordinatensystemen angleicht [13].

Wie praxistauglich sich dieser Ansatz in der Heide anwenden lässt, zeigen Schmidt et al. (2017). Aus überlappenden UAV-RGB-Bildern leiteten sie per SfM eine 3D-Punktwolke ab und daraus ein Canopy Height Model, die Differenz aus Oberflächen- und Geländemodell. So ließ sich die Vegetationshöhe flächig abbilden und zur Bewertung des Erhaltungszustands Calluna-dominierten Heiden nutzen [3].

2.3 Convolutional Neural Networks (CNNs)

2.3.1 Aufbau und Funktionsweise

Klassische Verfahren des maschinellen Lernens konnten Rohdaten wie die Pixelwerte eines Bildes nicht unmittelbar verarbeiten. Stattdessen war ein manuell entworfener Merkmalsextraktor nötig, der die Rohdaten unter Einsatz von umfangreichem Fachwissen in eine geeignete interne Repräsentation, einen Merkmalsvektor, überführte [16]. Deep Learning überwindet diese Einschränkung, indem es die entscheidenden Merkmale automatisch aus den Rohdaten lernt, ohne die manuelle Merkmalskonstruktion durchzuführen. Damit eignet es sich besonders für hochdimensionale, nichtlineare und komplexe Daten [6].

Diese Fähigkeit beruht auf dem Prinzip des Representation Learning. Dieses beschreibt Methoden, die es einer Maschine erlauben, aus Rohdaten selbständig die für die Erkennung oder Klassifikation nötigen Repräsentationen zu finden. Deep Learning ist sozusagen Representation Learning mit mehreren Repräsentationsebenen. Dabei überführen verkettete, einfache und nicht-lineare Module die Repräsentation Schritt für Schritt von der Rohform in eine jeweils höhere, abstraktere Ebene. Entscheidend ist dabei, dass diese Merkmalsebenen, welche zudem hierarchisch aufeinander aufbauen, nicht von Menschen entworfen, sondern mit allgemeinen Lernverfahren aus den Daten gelernt werden. Bei einem Bild zum Beispiel erkennt die erste Ebene typischerweise Kanten, die zweite setzt diese zu Motiven zusammen, die dritte zu Teilen bekannter Objekte und weitere Ebenen schließlich zu ganzen Objekten. So entsteht schrittweise aus einfachen Merkmalen eine immer abstraktere Darstellung [16].

Ein Convolutional Neural Network (CNN) ist eine spezielle Deep-Learning-Architektur, die auf gitterförmige Daten wie Bilder zugeschnitten ist. Ein Farbbild liegt beispielsweise als drei zweidimensionale Arrays vor, je eines für die Pixelwerte der drei Farbkanäle. Dieses Netzwerk setzt das allgemeine Prinzip des mehrschichtigen, hierarchischen Merkmalslernens um, inklusive der Faltung (convolution) und der Hinzunahme geteilter Gewichte. Die vier prägenden Grundideen eines CNN sind neben lokalen Verbindungen, geteilten Gewichten und Pooling, auch die Verwendung vieler Schichten [6]. Die ersten Stufen bestehen aus Faltungs- und Pooling-Schichten. In einer Faltungsschicht sind die Einheiten in Merkmalskarten (feature maps) organisiert. Jede Einheit ist nur mit einem lokalen Ausschnitt (local patch) der vorherigen Schicht über einen Satz Gewichte (filter bank) verbunden. Das lokal gewichtete Summenergebnis läuft anschließend durch eine nichtlineare Aktivierungsfunktion, eine sogenannte Nichtlinearität, z. B. eine ReLU (Rectified Linear Unit), die negative Werte auf null setzt und positive unverändert weitergibt. Alle

Einheiten einer Merkmalskarte teilen sich dabei dieselbe filter bank, da benachbarte Werte in Bildern stark korreliert sind und lokale Motive bilden, die zudem ortsunabhängig auftreten können [16].

Anschaulich lässt sich das so verstehen, dass ein kleiner, lernbarer Filter schrittweise über das gesamte Bild geschoben wird und an jeder Position aus dem lokalen Ausschnitt eine Antwort berechnet. Alle Antworten zusammen bilden dann die Merkmalskarte (Abbildung 3). Weil derselbe Filter an jeder Stelle verwendet wird, erkennt er dasselbe lokale Muster überall im Bild, wohingegen verschiedene Filter jeweils ein anderes Muster detektieren und so verschiedene Merkmalskarten erzeugen.




Abbildung 3: Funktionsweise der Faltung. Eigene Darstellung.

Die Pooling-Schicht fasst anschließend semantisch ähnliche Merkmale zusammen. Dabei typisch ist das Max-Pooling, das den Maximalwert eines lokalen Ausschnitts einer Merkmalskarte übernimmt, wodurch die Dimension der Repräsentation reduziert und eine Invarianz gegenüber kleinen Verschiebungen und Verzerrungen erzeugt wird [16].

Im Gesamtaufbau durchläuft das Eingabebild schließlich mehrere gestapelte Stufen aus Faltung, Nichtlinearität und Pooling (Abbildung 4). Mit jeder Stufe wird die räumliche Auflösung gröber, die Merkmale aber zahlreicher und abstrakter, entsprechend der bereits beschriebenen Merkmalshierarchie. Am Ende folgen voll verbundene Schichten, die aus diesen Merkmalen die eigentliche Vorhersage berechnen [16].




Abbildung 4: Aufbau eines CNN aus gestapelten Faltungs- und Pooling-Stufen [16].

2.3.2 Anwendung in der Fernerkundung

In der Fernerkundung von Vegetation sind CNNs inzwischen breit erprobt. Für die Bildanalyse haben sich zwei Netzfamilien herausgebildet, die sich darin unterscheiden, wie kleinteilig sie ein Bild auswerten. Pixelbasierte Netze klassifizieren jeden einzelnen Bildpunkt und liefern so eine semantische Segmentierung, eine flächendeckende Klassenkarte. Objektbasierte Netze, sogenannte anchor-based Netze, gehen anders vor, indem sie vordefinierte Referenzboxen (anchors) über das Bild legen, um Objekte zu lokalisieren und ihre Kategorie und Position zu bestimmen. Ein bekanntes Beispiel für ein solches Netz ist YOLO (You Only Look Once) [6]. Für das Auffinden einzelner Objekte wie Baumkronen eignen sich solche Netze gut, für flächendeckende Klassenkarten kommen vor allem U-Net und DeepLab zum Einsatz, während ResNet eher der patchweisen Klassifikation dient, bei der ein ganzer Bildausschnitt eine einzige Klasse erhält statt jeder Bildpunkt einzeln. Gemeinsam haben sie jedoch, dass sie ihre Merkmale über Faltung und Pooling gewinnen [6].

U-Net besteht aus zwei aufeinander abgestimmten Teilen. Ein kontrahierender Pfad, der Encoder, reduziert die räumliche Auflösung schrittweise und verdichtet zugleich die Merkmalsinformation, während der expandierende Pfad, der Decoder, sie über Up-Convolutions und die Verkettung (concatenation) mit den hochaufgelösten Merkmalen des Encoders wieder zu einer pixelgenauen Ausgabe zusammenführt. Die direkten Verbindungen zwischen beiden Pfaden erhalten dabei die räumliche Genauigkeit [6]. Zahlreiche Anwendungen belegen die Leistungsfähigkeit dieses Ansatzes, etwa bei der Kartierung von Waldtypen und einzelnen Baumarten aus hochaufgelösten Luft- und Satellitenbildern [6].

Methodisch ist das dieselbe Aufgabe wie in dieser Arbeit, nämlich eine pixelweise semantische Segmentierung zur Kartierung von Vegetationsklassen. Die vorliegende Arbeit überträgt sie vom Wald auf die Heide und vom zweidimensionalen Bild auf die dreidimensionale Punktwolke. U-Net ist das im Projekt eingesetzte zweidimensionale Verfahren, während die vorliegende Arbeit den dreidimensionalen Weg über PointNet++ verfolgt.

2.4 Geometric Deep Learning

Die im vorigen Abschnitt beschriebenen CNNs setzen ein regelmäßiges Gitter voraus, wie es ein Bild bietet. Eine dreidimensionale Punktwolke ist dagegen unstrukturiert. Sie besteht aus einer ungeordneten Menge von Punkten ohne feste Nachbarschaftsbeziehungen, weshalb sich die Faltung nicht unmittelbar anwenden lässt. Für genau solche Daten wurde das Geometric Deep Learning (GDL) entwickelt. Der Begriff fasst Verfahren zusammen, die tiefe neuronale Netze von gitterförmigen auf nicht-euklidische Daten wie Graphen, Mannigfaltigkeiten und eben Punktwolken verallgemeinern [17].

Eine naheliegende Möglichkeit besteht darin, die Punktwolke vor der Verarbeitung in ein regelmäßiges Format zu überführen, etwa in ein 3D-Voxelgitter, das dreidimensionale Pendant zu Pixeln, oder eine Sammlung von Bildern. Dieser Umweg bläht die Daten jedoch unnötig auf und bringt weitere Probleme mit sich [18]. Sinnvoller ist ein Netz, das direkt auf den Punkten arbeitet. Die fehlende Ordnung, das heißt die beliebige Reihenfolge der Punkte in einer Punktwolke, stellt dabei eine besondere Herausforderung dar. Aus diesem Grund muss ein solches Netz permutationsinvariant sein, sodass das Ergebnis gleich bleibt, wenn dieselben Punkte anders angeordnet werden [18].

2.4.1 Semantische Segmentierung von 3D-Punktwolken

Die für diese Arbeit zentrale Aufgabe ist die semantische Segmentierung einer Punktwolke. Dabei erhält jeder einzelne Punkt eine von mehreren Zielklassen, ohne dass verschiedene Objekte derselben Klasse unterschieden werden [19]. Das trennt die Segmentierung von der reinen Klassifikation, bei der die gesamte Wolke ein einziges Label bekommt und nicht jeder Punkt ein eigenes [18]. Ein entsprechendes Netz gibt für jeden Punkt einen Wert pro Klasse aus, aus dem sich die wahrscheinlichste Klasse ableiten lässt [18]. Übertragen auf diese Arbeit heißt das, jedem Punkt der Heide-Punktwolke eine Vegetationsklasse zuzuweisen, woraus sich anschließend der Verbuschungsgrad berechnen lässt.

2.4.2 PointNet

PointNet war das erste Netz, das ungeordnete Punktwolken direkt verarbeitet [18]. Jeder Punkt wird dabei zunächst einzeln betrachtet und ist im einfachsten Fall nur durch seine drei Koordinaten gegeben, die sich um weitere Merkmale wie Normalen ergänzen lassen. Auf jeden Punkt wird dasselbe kleine neuronale Netz angewendet, ein sogenanntes Multilayer Perceptron (MLP). Ein MLP ist ein einfaches, vollständig verbundenes Netz aus mehreren Schichten, das einen Eingabevektor auf einen Ausgabevektor abbildet. Weil für alle Punkte dieselben Gewichte genutzt werden, spricht man von einem geteilten MLP, welches den geteilten Gewichten der filter bank bei CNNs entspricht und lediglich auf einzelne Punkte statt auf ganze Bildausschnitte angewendet wird [18].

Damit die Reihenfolge der Punkte keine Rolle spielt, führt PointNet die einzelnen Punktmerkmale mit einer symmetrischen Funktion zusammen, dem Max-Pooling. Es übernimmt für jedes Merkmal den größten Wert über alle Punkte hinweg, wodurch ein einziges globales Merkmal (global feature) entsteht, das die gesamte Punktwolke beschreibt und nicht von der Reihenfolge der Punkte abhängt [18]. Aus diesem globalen Merkmal berechnet PointNet je nach Aufgabe unterschiedliche Ausgaben, indem es für die Klassifikation das globale Merkmal direkt nutzt, für die Segmentierung dagegen zusätzlich mit den lokalen Merkmalen jedes einzelnen Punktes verkettet, um so für jeden Punkt ein eigenes Label abzuleiten [18]. Die größte Schwäche bleibt jedoch, dass sich PointNet stark auf dieses eine globale Merkmal stützt und jeden Punkt unabhängig von seinen Nachbarn verarbeitet. Lokale Strukturen, die sich aus den Abständen benachbarter Punkte ergeben, erfasst es daher kaum, was die Erkennung feiner Muster begrenzt [20]. Genau hier setzt die Weiterentwicklung PointNet++ an.

2.4.3 PointNet++

PointNet++ begegnet dieser Schwäche mit einem hierarchischen Aufbau (Abbildung 5), der PointNet wiederholt auf ineinander verschachtelte Teilmengen der Punktwolke anwendet [20]. Indem es benachbarte Punkte anhand ihrer räumlichen Abstände zu lokalen Regionen zusammenfasst, lernt das Netz lokale Merkmale auf zunehmend größeren Kontext-Skalen, angefangen bei kleinen Nachbarschaften bis hin zu größeren Regionen.

Kern des Verfahrens ist die sogenannte Set Abstraction, eine Verarbeitungsstufe aus drei Schritten. Im Sampling werden zunächst einzelne Punkte als Zentren (centroids) lokaler Regionen ausgewählt. Das anschließende Grouping bildet um jedes dieser Zentren eine lokale Region. Verwendet wird dafür die sogenannte ball query, die alle Punkte innerhalb

eines festen Radius um das Zentrum sammelt, wobei die Zahl der übernommenen Punkte nach oben auf K begrenzt ist [20]. Gegenüber einer Suche nach den K nächsten Nachbarn hat das den Vorteil, dass die Region unabhängig von der örtlichen Punktdichte stets dieselbe räumliche Ausdehnung besitzt, was der punktweisen Segmentierung zugutekommt [20].

Findet die Abfrage weniger als K Punkte, füllt die Implementierung die freien Plätze mit Kopien eines bereits gefundenen Punktes auf [21]. Liegt nur das Zentrum selbst innerhalb der Kugel, besteht die Gruppe folglich aus K Kopien desselben Punktes und trägt keine Nachbarschaftsinformation. In der abschließenden PointNet-Schicht fasst ein kleines PointNet jede solche Region zu einem einzelnen Merkmalsvektor zusammen. Mehrere solcher Stufen hintereinander erzeugen die Hierarchie, in der die Zahl der Punkte von Stufe zu Stufe abnimmt und die Merkmale zugleich reichhaltiger werden [20].

Für die Segmentierung muss am Ende jeder ursprüngliche Punkt ein Label erhalten, nicht nur die wenigen verbliebenen Zentren. Dazu werden die auf den groben Stufen gelernten Merkmale schrittweise wieder auf alle Punkte übertragen, ein Vorgang, der als feature propagation bezeichnet wird. Die Übertragung erfolgt durch eine abstandsgewichtete Interpolation über die k nächsten Nachbarn und wird durch sogenannte skip connections ergänzt, die Merkmale früherer Stufen direkt mit einbringen. So erhält am Ende jeder Punkt der Wolke eine Klasse [20].




Abbildung 5: Architektur von PointNet++ mit hierarchischen Set-Abstraktions-Stufen sowie Segmentierungs- und Klassifikationszweig [20].

PointNet++ ist damit das in dieser Arbeit eingesetzte 3D-Verfahren. Es weist jedem Punkt der Heide-Punktwolke eine Vegetationsklasse zu und erfasst dabei die lokalen Strukturen, die für die Unterscheidung der Vegetationsarten und damit für die Bestimmung der Verbuschung entscheidend sind.

2.5 Evaluationsmetriken

Die Bewertung der Ergebnisse erfolgt auf zwei Ebenen, die den beiden Forschungsfragen entsprechen. Auf der ersten Ebene wird die Güte der punktweisen Segmentierung beurteilt, also wie zuverlässig das Netz jedem Punkt die richtige Vegetationsklasse zuweist. Die dafür üblichen Maße leiten sich aus der Konfusionsmatrix ab, die für jede Klasse die korrekten und die falschen Zuordnungen gegenüberstellt [19]. Auf der zweiten Ebene wird der daraus abgeleitete Verbuschungsgrad geprüft, indem der vorhergesagte Wert je Rasterzelle mit einem Referenzwert verglichen wird. Da hier kein Klassenlabel, sondern ein flächiger Anteil bewertet wird, kommen statistische Maße für die Übereinstimmung zum Einsatz. Die folgenden beiden Abschnitte stellen die jeweils verwendeten Metriken vor.

2.5.1 Metriken der Segmentierung

Die erste Forschungsfrage betrifft die Güte der punktweisen Segmentierung. Grundlage der Bewertung ist die Konfusionsmatrix (confusion matrix), die die vorhergesagten Klassen den tatsächlichen Klassen gegenüberstellt. In ihren Zeilen steht die wahre Klasse eines Punktes, in ihren Spalten die vom Netz vorhergesagte Klasse, sodass der Eintrag c_{ij} angibt, wie viele Punkte der Klasse i als Klasse j klassifiziert wurden. Auf der Diagonalen stehen folglich die korrekt zugeordneten Punkte, wohingegen die Einträge außerhalb der Diagonalen die Verwechslungen zwischen den Klassen sichtbar machen [19]. Aus dieser Matrix leiten sich die folgenden Maße ab, wobei N die Anzahl der Klassen bezeichnet.

Die Gesamtgenauigkeit (Overall Accuracy, OA) beschreibt den Anteil aller korrekt klassifizierten Punkte an der Gesamtzahl der Punkte. Sie ergibt sich als Summe der Diagonaleinträge geteilt durch die Summe aller Einträge der Matrix [19]:

$$OA = \frac{\sum_{i=1}^N c_{ii}}{\sum_{i=1}^N \sum_{j=1}^N c_{ij}}$$

Die Gesamtgenauigkeit lässt sich einfach interpretieren, reagiert aber empfindlich auf ungleich große Klassen. Dominiert eine Klasse den Datensatz, kann ein hoher Wert vor allem deren gute Trennung widerspiegeln, ohne dass seltene Klassen zuverlässig erkannt werden.

Um die einzelnen Klassen unabhängig von ihrer Häufigkeit zu beurteilen, wird die Schnittmenge über Vereinigung (Intersection over Union, IoU) je Klasse betrachtet. Sie setzt die korrekt erkannten Punkte einer Klasse ins Verhältnis zur Vereinigung aus

vorhergesagten und tatsächlichen Punkten dieser Klasse und berücksichtigt so sowohl übersehene als auch fälschlich zugeordnete Punkte [19]:

$$\text{IoU}_i = \frac{c_{ii}}{c_{ii} + \sum_{j \neq i} c_{ij} + \sum_{j \neq i} c_{ji}}$$

Als zusammenfassendes Maß über alle Klassen dient die mittlere Schnittmenge über Vereinigung (mean IoU, mIoU), der Mittelwert der klassenweisen IoU-Werte [19]:

$$\text{mIoU} = \frac{1}{N} \sum_{i=1}^N \text{IoU}_i$$

Da jede Klasse gleich in den Mittelwert eingeht, gewichtet die mittlere IoU seltene und häufige Klassen gleichermaßen und eignet sich daher als Hauptkennzahl für den Vergleich der Segmentierungsgüte. In dieser Arbeit lässt die klassenweise IoU erkennen, welche Vegetationsklassen das Netz gut voneinander trennt und welche es häufig verwechselt. Die mittlere IoU bündelt dagegen die Gesamtleistung in einer einzigen Kennzahl. Die Konfusionsmatrix ergänzt diese Werte, indem sie zeigt, zwischen welchen Klassen die Fehler konkret auftreten.

Wird eine einzelne Klasse gegen alle übrigen betrachtet, kommen drei weitere Maße hinzu, die sich ebenfalls aus der Konfusionsmatrix ergeben [19]. Die richtig erkannten Punkte dieser Klasse heißen richtig positiv (true positives, TP), die ihr fälschlich zugeordneten falsch positiv (false positives, FP) und die übersehenen falsch negativ (false negatives, FN). Die Präzision (Precision) gibt an, welcher Anteil der vorhergesagten Punkte tatsächlich zu dieser Klasse gehört [19]:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Die Trefferquote (Recall) beschreibt umgekehrt, welcher Anteil der tatsächlich vorhandenen Punkte dieser Klasse auch als solcher erkannt wurde [19]:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Beide Maße lassen sich gegeneinander ausspielen, denn wer vorsichtig vorhersagt, erreicht eine hohe Präzision bei niedriger Trefferquote und umgekehrt. Das F1-Maß fasst sie deshalb als harmonisches Mittel zusammen [19]:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Für diese Arbeit lässt sich anhand von Präzision und Trefferquote erkennen, in welche Richtung sich das Netz irrt. Eine niedrige Präzision bedeutet, dass zu viel als Gehölz ausgewiesen und der Verbuschungsgrad überschätzt wird, eine niedrige Trefferquote das Gegenteil. Der Unterschied ist für die Bewertung des Erhaltungszustands erheblich, weil beide Fehler zu gegensätzlichen Pflegeempfehlungen führen.

2.5.2 Metriken des Verbuschungsgrades

Die zweite Forschungsfrage betrifft die Genauigkeit des aus der Segmentierung abgeleiteten Verbuschungsgrades. Anders als bei der Segmentierung wird hier keine Klassenzuordnung, sondern ein flächiger Anteil je Rasterzelle bewertet. Für jede Zelle liegt ein vorhergesagter Verbuschungsgrad $\hat{y}_i$ und ein Referenzwert y_i vor. Die Bewertung stützt sich dabei auf die Abweichung zwischen beiden Werten. Diese Abweichung entspricht dem Residuum $\hat{\epsilon}_i = y_i - \hat{y}_i$, das die Differenz zwischen beobachtetem und vorhergesagtem Wert angibt [22]. Aus den Residuen über alle n Zellen leiten sich die folgenden Maße ab.

Der Wurzelwert des mittleren quadratischen Fehlers (Root Mean Squared Error, RMSE) mittelt die quadrierten Residuen und zieht daraus die Wurzel. Durch die Quadrierung gehen große Abweichungen stärker ein, sodass der RMSE einzelne grobe Fehleinschätzungen betont:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Der RMSE beschreibt die Größe der Abweichung, nicht ihre Richtung. Ob die Vorhersage im Mittel zu hoch oder zu niedrig liegt, zeigt der Versatz (Bias) als vorzeichenbehafteter Mittelwert der Residuen:

$$\text{Bias} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

Ein positiver Wert bedeutet, dass das Verfahren die Größe im Mittel überschätzt.

Das Bestimmtheitsmaß (Coefficient of Determination, R^2) gibt den Anteil der Streuung der Referenzwerte an, der durch die Vorhersage erklärt wird. Es setzt die verbleibende

Residualstreuung ins Verhältnis zur Gesamtstreuung der Referenzwerte, wobei $\bar{y}$ deren Mittelwert bezeichnet [22]:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

R^2 nimmt dabei höchstens den Wert eins an. Da hier keine an die Daten angepasste Regressionsgerade, sondern eine feste Modellvorhersage bewertet wird, kann R^2 auch negative Werte annehmen, wenn die Vorhersage schlechter abschneidet als der bloße Mittelwert der Referenz. Ein Wert nahe eins bedeutet, dass die Vorhersagen den Referenzwerten weitgehend folgen, ein Wert nahe null oder darunter, dass die Vorhersage nicht besser oder sogar schlechter ist als der Mittelwert der Referenz.

Ergänzend zum Bestimmtheitsmaß wird der Korrelationskoeffizient nach Bravais-Pearson (Pearson) berichtet, der den linearen Zusammenhang zwischen Vorhersage und Referenz unabhängig von deren Lage und Streuung misst [22]:

$$r = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}}$$

Da sowohl das Bestimmtheitsmaß als auch der Pearson-Koeffizient bei kleinen Stichproben empfindlich auf einzelne stark abweichende Werte reagieren, wird zusätzlich die Rangkorrelation nach Spearman berichtet. Sie entsteht, indem nicht die Werte selbst, sondern ihre Ränge korreliert werden, sodass allein die Reihenfolge zählt und nicht der Abstand zwischen den Werten [22]. Sie misst damit nicht die Stärke des linearen, sondern die des monotonen Zusammenhangs [22]. Fällt sie merklich niedriger aus als das Bestimmtheitsmaß oder der Pearson-Koeffizient, bringt das Verfahren die Flächen nicht zuverlässig in die richtige Rangfolge, selbst wenn einzelne stark abweichende Werte den linearen Zusammenhang günstiger erscheinen lassen.

Bestimmtheitsmaß und RMSE sind in der Heide-Fernerkundung etabliert. Schmidt et al. bewerten die Übereinstimmung ihrer fernerkundlich geschätzten Calluna-Deckung und Bestandshöhen mit Referenzdaten ebenfalls über R^2 und RMSE [3]. Für diese Arbeit erlaubt der RMSE eine Aussage über die durchschnittliche Größe der Abweichung im Verbuschungsgrad, wohingegen das Bestimmtheitsmaß die Güte des Zusammenhangs mit der Referenz bewertet.

3 Methodik

Die folgenden Abschnitte beschreiben den Weg von den bereitgestellten Punktwolken bis zum berechneten Verbuschungsgrad. Die Gliederung folgt dabei dem Datenfluss und nicht der zeitlichen Abfolge der Bearbeitung.

3.1 Untersuchungsgebiete und Datengrundlage

3.1.1 Untersuchungsgebiete

Der Authausener Wald liegt in Sachsen nordöstlich von Leipzig und umfasst rund 2.200 Hektar. Ab 1937 beanspruchte das Militär die Fläche, ab 1955 bewirtschaftete sie die DDR als Militärforst und bis 1995 unterhielt die Bundeswehr dort ein Materiallager. Aus dieser Nutzung sind drei kleine Heideflächen innerhalb eines ausgedehnten Waldgebietes hervorgegangen, deren Erhalt und Verbesserung zu den Entwicklungszielen der Fläche zählt [23]. Beflogen wurden für diese Arbeit vier Gebiete, nämlich die Schneise I, die zusammen beflogenen Schneisen IV und V, die HeideWildnis sowie der Korridor einer 110-kV-Trasse. Bis auf die kompaktere HeideWildnis-Fläche handelt es sich um schmale, von Wald gesäumte Streifen.

Die Cuxhavener Küstenheiden in Niedersachsen umfassen rund 1.400 Hektar und bilden das größte zusammenhängende Heidegebiet auf dem Festland der deutschen Nordseeküste. Auch dort geht die Offenhaltung auf militärische Nutzung zurück, zunächst auf einen Marineschießplatz ab 1915 und später auf einen Truppenübungsplatz der Bundeswehr von 1956 bis 2003. Heute wird die Fläche durch Beweidung mit Schafen, Pferden und Rindern offengehalten [24].

3.1.2 Befliegung und photogrammetrische Auswertung

Befliegung und photogrammetrische Auswertung lagen nicht in der Hand dieser Arbeit, sondern erfolgten im Rahmen des Projekts durch die Deutsche Bundesstiftung Umwelt, die die fertigen Orthomosaike und Punktwolken bereitgestellt hat. Die folgenden Angaben geben deshalb wieder, was seitens der DBU dokumentiert vorliegt.

Zum Einsatz kam eine DJI Mavic 3M. Sie trägt eine RGB-Kamera mit 20 Megapixeln sowie vier Multispektralkameras mit je fünf Megapixeln, darunter eine für das Nahinfrarot bei 860 Nanometern. Aus diesem Band stammt der Nahinfrarotkanal, dessen Nutzen als

zusätzliches Eingabemerkmale in Abschnitt 3.4 geprüft wird. Georeferenziert wurde über das RTK-Modul der Drohne, ohne dass Bodenpasspunkte zum Einsatz kamen. Für den fixierten RTK-Betrieb gibt der Hersteller eine Lagegenauigkeit von einem Zentimeter zuzüglich eines Millionstels der Basislinienlänge an [25].

Die Authausener Flächen wurden im Mai 2025 beflogen, die Cuxhavener Küstenheide ebenfalls im Jahr 2025. Der Aufnahmezeitpunkt ist insofern von Bedeutung, als sich das Erscheinungsbild der Heide im Jahresverlauf deutlich verändert und blühende Besenheide spektral anders auftritt als nicht blühende.

Die Rekonstruktion der Punktwolken erfolgte mit Agisoft Metashape. Aus ihr gingen fünf getrennte Punktwolken hervor, vier für den Authausener Wald mit zusammen 100,6 Millionen Punkten und eine für die Cuxhavener Küstenheide mit 415,3 Millionen Punkten. Annotierte Teilflächen liegen allein in der Schneise I, in der 110-kV-Trasse und in Cuxhaven, sodass sich Training und die Bewertung anhand gelabelter Testkacheln auf diese drei Wolken stützen, während die übrigen beiden erst bei der Anwendung des Modells auf die gesamte Fläche hinzukommen (Abschnitt 3.6.1). Die Punktdichte liegt in den Authausener Gebieten zwischen 116 und 156 Punkten je Quadratmeter und in Cuxhaven bei rund 98. Sie bestimmt mit, wie viele Punkte dem Netz bei einem gegebenen Nachbarschaftsradius zur Verfügung stehen. Flughöhe, Bodenauflösung, Überlappungsgrad sowie die verwendete Programmversion und ihre Einstellungen sind dagegen nicht dokumentiert, was für diese Arbeit unerheblich ist, weil die Punktwolken ohnehin als gegebene Eingabe verarbeitet werden.

3.1.3 Manuelle Annotation und Klassenschema

Die Grundlage für Training und Bewertung bilden manuell annotierte Referenzflächen, für die einzelne Ausschnitte der Orthomosaik bearbeitet wurden, im Folgenden Teilflächen genannt. Statt die Flächen von Hand zu zeichnen, zerlegt ein Segmentierungsverfahren jedes Orthomosaik zunächst in kleine, in sich einheitliche Bildregionen, die anschließend manuell einer Klasse zugeordnet werden. Verwendet wurde dafür in R das Verfahren Simple Non-Iterative Clustering (SNIC), das benachbarte Pixel nach spektraler Ähnlichkeit und räumlicher Nähe zu kompakten, zusammenhängenden Regionen zusammenfasst [26]. Die daraus entstehenden Segmente liegen als Polygone vor.

Vergeben wurden die acht Klassen `bush`, `deadwood`, `graminoid`, `heath`, `other`, `sand`, `soil` und `tree`. Für die Fragestellung tragen vor allem `bush` und `tree` bei, die zusammen die Gehölze bilden, sowie `heath` und `graminoid` als die davon

abzugrenzende niedrige Vegetation. Eine neunte Klasse für Wasser ist in der Verarbeitung vorgesehen, in den Annotationen jedoch nicht belegt.

Neben der Klasse wurden je Segment drei Angaben zur Aufnahmequalität erfasst. Zwei davon sind binär und halten fest, ob ein Segment verschattet oder überbelichtet ist. Die dritte gibt die Sicherheit der Zuordnung auf einer Skala von null bis zehn an. Diese Angaben steuern das Gewicht eines Punktes im Verlust (Abschnitt 3.3.2).

Annotiert wurden 16 Teilflächen mit 76.193 Segmenten auf 8,92 Hektar, elf davon im Authausener Wald mit 3,39 Hektar und fünf in der Cuxhavener Küstenheide mit 5,53 Hektar.

3.2 Datenvorverarbeitung

Die Vorverarbeitung überführt drei Ausgangsgrößen in einen Trainingsdatensatz für PointNet++, nämlich die SfM-Punktwolken der drei Gebiete, die manuell annotierten Polygone und die daran hängenden Qualitätsattribute. Sie ist vollständig in R umgesetzt und stützt sich auf das Paket `lidR` für die Verarbeitung der Punktwolken [27] sowie auf `sf` für die Vektoroperationen [28] und `terra` für die Rasteroperationen [29]. Am Ende steht ein Verzeichnis aus Textdateien, in dem jede Datei eine Kachel der Fläche beschreibt und jede Zeile einen Punkt mit seinen Merkmalen und seinem Label enthält.

3.2.1 Aufbereitung und Prüfung der Ausgangsdaten

Voraussetzung für den Label-Transfer ist, dass die annotierten Polygone und die Punktwolke im selben Koordinatensystem liegen und räumlich deckungsgleich sind. Beides wurde vorab geprüft, und zwar zuerst rechnerisch über einen Vergleich der EPSG-Codes und der Ausdehnungen und anschließend visuell durch eine gemeinsame Darstellung von Punkten und Polygonrändern. Alle verwendeten Daten liegen in der UTM-Zone 32N (EPSG 25832) vor.

Geladen wird je Teilfläche nur der Ausschnitt, der innerhalb des umschließenden Rechtecks (bounding box) der zugehörigen Polygone liegt. Da diese Rechtecke die tatsächlichen Annotationsflächen nur grob umschreiben, enthalten die geladenen Ausschnitte auch Punkte außerhalb der Polygone, die im weiteren Verlauf als ungelabelt aussortiert werden. Von den mitgeführten Punktattributen werden ausschließlich die Koordinaten, die vier Farbkanäle sowie die Klassen- und Qualitätsangaben übernommen, da die Punktwolken der drei Gebiete unterschiedliche Zusatzattribute enthalten und sich sonst nicht zu einem gemeinsamen Datensatz zusammenführen ließen.

3.2.2 Bodenerkennung und Höhennormalisierung

Die Z-Koordinate der Rohpunkte gibt die absolute Höhe an und ist für eine vegetationskundliche Auswertung wenig aussagekräftig, weil sie das Relief des Geländes enthält. Für die Unterscheidung von Heide, Gras und Gehölzen ist dagegen die Höhe über dem Boden entscheidend, das heißt die Wuchshöhe der Pflanze an ihrem Standort. Die Punktwolke wird deshalb höhennormalisiert, wodurch jeder Punkt statt seiner absoluten Höhe seinen vertikalen Abstand zur Geländeoberfläche erhält.

Zunächst werden die Bodenpunkte automatisch mit einem Cloth Simulation Filter (CSF) erkannt [30]. Anschaulich lässt sich das Verfahren so verstehen, dass die Punktwolke auf den Kopf gestellt wird und ein virtuelles Tuch auf die dabei entstandene Oberfläche fällt, dessen Form sich nach dem Absinken der Geländeoberfläche annähert. Alle Punkte, deren Abstand zu dieser Fläche unter einem Schwellenwert liegt, werden als Boden klassifiziert. Gegenüber älteren hangneigungs- und morphologiebasierten Filtern kommt CSF mit wenigen, einfach zu setzenden Parametern aus [30]. Gesetzt wurden der horizontale Abstand zweier benachbarter Tuchknoten (grid resolution) auf 0,5 Meter, der Abstandsschwellenwert für die Trennung von Boden- und Objektpunkten auf 0,3 Meter sowie die Steifigkeit des Tuchs (rigidness) auf zwei, den mittleren der drei zulässigen Werte.

Aus den so bestimmten Bodenpunkten wird anschließend für jeden Punkt der Wolke die lokale Geländehöhe geschätzt und von seiner Z-Koordinate abgezogen. Die Schätzung erfolgt über eine inverse Distanzgewichtung (inverse distance weighting) der zehn nächstgelegenen Bodenpunkte, deren Beitrag zur Schätzung mit dem Quadrat ihres Abstands zum geschätzten Punkt abnimmt. Bodenpunkte liegen danach nahe null und die Höhe eines Vegetationspunktes entspricht seiner Wuchshöhe.

Diese Normalisierung erfolgt getrennt für jede der 16 annotierten Teilflächen, in deren Zuschnitt die Daten bereits geladen wurden. An den Rändern der Gebiete, wo die photogrammetrische Rekonstruktion ungenau wird und das Geländemodell aus weiter entfernt liegenden Bodenpunkten extrapoliert werden muss, entstehen dadurch stark negative Höhen. Aus diesem Grund werden nach der Normalisierung Punkte unterhalb von minus einem Meter verworfen.

3.2.3 Übertragung der Labels auf die Punktwolke

Auf der so normalisierten Punktwolke lassen sich die Annotationen übertragen, die als zweidimensionale Polygone im Luftbild vorliegen, während das Modell ein Label je Punkt der dreidimensionalen Wolke benötigt. Ein räumlicher Verschnitt prüft dafür für jeden Punkt,

in welchem Polygon seine X- und Y-Koordinate liegt, und weist ihm dessen Klasse zu. Auf demselben Weg werden neben der Vegetationsklasse auch die drei Qualitätsattribute `shadow`, `overexposed` und `confidence` übertragen. Punkte ohne zugeordnetes Polygon werden anschließend entfernt.

Dieses Vorgehen beantwortet die erste Teilfrage nach einem automatisierten Label-Transfer, bringt jedoch eine systematische Schwäche mit sich. Die Polygone wurden auf der von oben sichtbaren Oberfläche gezeichnet, ihre Klasse wird beim Verschnitt aber auf die gesamte darunterliegende Punktsäule übertragen. Jedes Polygon wirkt damit wie ein Ausstecher, der seine Klasse durch die volle Höhe der Punktwolke stempelt.

Ragt eine Baumkrone über eine Heidefläche, ist im Luftbild nur die Krone zu sehen, wodurch die darunter wachsende Heide fälschlich das Label `tree` erhält. An den Rändern derselben Krone kehrt sich der Fehler um, weil einzelne Zweige über die benachbarte Fläche hinausreichen, im Bild aber nicht eigens abgegrenzt werden, da die Polygongrenze vereinfacht entlang der sichtbaren Kronenkante verläuft. Punkte auf diesen Zweigen fallen dadurch in ein Heide- oder Graspolygon und tragen dessen Label. Der Ausstecher wirkt damit in beide Richtungen.

Ein erheblicher Teil der als `tree` gelabelten Punktmasse liegt, wie die Höhenverteilung je Klasse zeigt, nahe der Bodenoberfläche und bildet damit Unterwuchs statt Baum ab. In der Gegenrichtung reichen einzelne als `heath` gelabelte Punkte bis 22 Meter, als `graminoid` gelabelte bis 23 Meter und als `sand` gelabelte bis 14 Meter über den Boden, was in der Natur für diese Klassen ausgeschlossen ist. Betroffen sind davon allerdings nur wenige Punkte, denn das 95. Perzentil der Heidepunkte liegt bei 1,26 Metern. Anschaulich wird das durch eine Abbildung, die einen senkrechten Schnitt durch die Punktwolke darstellt (Abbildung 6), in dem beide Fehlerarten nebeneinander auftreten.




Abbildung 6: Senkrechter Schnitt durch die Punktwolke der Schneise I nach dem Label-Transfer. Eigene Darstellung.

3.2.4 Höhenbasierte Labelkorrektur

Um diese Fehllabel zu bereinigen, wird auf der normalisierten Höhe ein Regelwerk angewendet, das Punkte in zwei Richtungen umklassifiziert. Die Aufwärtsregeln stufen Punkte, die für ihre Klasse zu hoch liegen, zur Klasse `tree` hoch. Die Abwärtsregeln behandeln den umgekehrten Fall und weisen tiefliegende Punkte unter Baumpolygonen dem Unterwuchs zu, wobei Punkte unterhalb von 0,5 Metern die Klasse `heath` und Punkte zwischen 0,5 und 2,0 Metern die Klasse `bush` erhalten (Abbildung 7). Die Rückstufung ist dadurch gerechtfertigt, dass die Punktwolke photogrammetrisch aus Aufnahmen von oben entstanden ist und Baumstämme unter geschlossenen Kronen kaum rekonstruiert werden, sodass tiefliegende Punkte unter einem Baumpolygon mit hoher Wahrscheinlichkeit Vegetation am Boden abbilden.




Abbildung 7: Senkrechter Schnitt durch die Punktwolke der 110-kV-Trasse vor (a) und nach (b) der Labelkorrektur. Die Linien bei 0,5 und 2,0 Metern markieren die Grenzen der Abwärtsregeln. Eigene Darstellung.

Um die Schwellenwerte der Aufwärtsregeln aus den Daten selbst abzuleiten, wurde für jede Klasse über alle 16 annotierten Teilflächen das 95. Perzentil der normierten Höhe berechnet und auf einen gerundeten Wert festgelegt, woraus sich ein Höschwellenwert von 1,15 Meter für `soil`, 1,4 Meter für `sand`, 1,2 Meter für `graminoid` und 1,3 Meter für `heath` ergibt.

Auf die Klasse `bush` ist dieses Vorgehen nicht anwendbar, da ihr oberes Perzentil durch überstehende Bäume so stark verfälscht wird, dass es mit 13,5 Metern weit oberhalb jeder realistischen Strauchhöhe liegt. Ihre Schwelle wurde deshalb als eigene Setzung auf 3,5 Meter festgelegt. Dieser Wert orientiert sich an der Wuchshöhe der auf Heideflächen typischen Pioniergehölze wie Schlehe, Weißdorn und Rosenarten [9] und liegt bewusst unterhalb der in der Vegetationskunde üblichen Obergrenze der Strauchschicht von etwa fünf Metern, da Gehölze dieser Höhe im Untersuchungsgebiet bereits durchweg als Birke oder Kiefer und damit als Baum auftreten.

Die Klasse `deadwood` bleibt bewusst ohne Höhenregel, weil Totholz sowohl liegend als auch stehend vorkommt und ihre Höhenverteilung deshalb zweigipflig ist, sodass eine einzelne Schwelle eine der beiden Erscheinungsformen systematisch falsch behandeln würde.

Die Zuweisung des Unterwuchses über feste Höhenbänder bleibt allerdings eine Näherung. Tiefliegende Punkte unter Baumkronen können auch offener Boden oder Sand sein, werden durch die Abwärtsregeln aber je nach Höhe entweder der Heide oder den Büschen zugeordnet. Beide Klassen können dadurch überschätzt werden, was im Fall von `bush` sogar unmittelbar die Zielgröße dieser Arbeit betrifft.

Hinzu kommt, dass die Regeln punktwise und nicht objektbezogen arbeiten. Ein Strauch, dessen Basis am Boden ansetzt, wird an der Grenze von 0,5 Metern waagrecht durchgeschnitten und unterhalb davon der Heide, oberhalb den Büschen zugeordnet, obwohl es sich um dieselbe Pflanze handelt. In Abbildung 7 ist das an mehreren Stellen zu erkennen.

Aus der Reihenfolge der Regeln entsteht eine weitere Nebenwirkung, denn weil die Aufwärtsregeln zuerst greifen, wird etwa ein Graspunkt oberhalb von 1,2 Metern zunächst zu `tree` hochgestuft und unmittelbar danach von der Abwärtsregel zu `bush` zurückgestuft, obwohl kein Regelsatz diesen Übergang direkt vorsieht. Betroffen sind davon vor allem die Klassen `graminoid` und `heath`. Wie stark beide Effekte die Buschklasse verschieben, wird bei der Einordnung der Ergebnisse aufgegriffen (Kapitel 4). Die Schwellenwerte selbst beruhen zudem auf den 16 annotierten Teilflächen und wären bei einer erneuten Erweiterung des Datensatzes neu zu bestimmen.

3.2.5 Lokale Höhenmerkmale

Die bisher vorliegenden Merkmale beschreiben jeden Punkt über seine Lage, seine Farbe und seine Höhe über dem Boden. Für die entscheidende Trennung reicht das nicht aus, denn die Höhe allein trennt einen 40 Zentimeter hohen Busch nicht von einem gleich hohen Heidebestand. Im Luftbild erkennt eine annotierende Person den Unterschied an der Textur, also an derselben unruhigen Oberfläche, die sich in der Punktwolke als kleinräumige Höhenvariabilität niederschlägt. Um diese Information für das Netz verfügbar zu machen, werden je Punkt zwei zusätzliche Merkmale berechnet. Das Merkmal `z_range` gibt die Höhenspanne innerhalb einer Rasterzelle von 0,5 Metern an und erreicht große Werte bei locker aufgebauten Sträuchern, deren Zweige in verschiedenen Höhen liegen, kleine Werte im geschlossenen Heideteppich und nahezu den Wert null auf offenem Boden. Das Merkmal `z_rel` beschreibt die Höhe eines Punktes über der medianen Höhe seiner Umgebung von 2,5 Metern und wird positiv, wenn eine Struktur aus dem umgebenden Bestand herausragt. Berechnet werden beide Merkmale getrennt je Gebiet.

Beide Merkmale werden bei fünf Metern begrenzt, `z_rel` zusätzlich nach unten bei minus fünf Metern. Ohne diese Grenze reicht `z_range` in Zellen, die eine Baumkrone schneiden,

bis über 20 Meter und drückt den für die Verbuschung entscheidenden Bereich zwischen Heide und Busch auf einen sehr schmalen Ausschnitt zusammen. Verloren geht durch die Kappung wenig, da solche Spannen nur unter Baumkronen auftreten und sich Bäume bereits über die normalisierte Höhe zuverlässig von der niedrigen Vegetation abheben.

3.2.6 Kachelung

Nachdem alle Merkmale berechnet sind, muss die Punktwolke in die Form gebracht werden, die das Netz erwartet, denn PointNet++ verarbeitet keine beliebig großen Szenen, sondern Punktmengen fester Größe. Ein gleitendes Fenster (sliding window) von zehn Metern Kantenlänge wandert dafür über die Fläche und schneidet daraus quadratische Kacheln. Zwischen zwei Fenstern liegen jeweils fünf Meter Versatz, sodass benachbarte Kacheln sich zur Hälfte überlappen. Damit verdoppelt sich nicht nur die Zahl der Trainingsbeispiele, sondern das Netz sieht dieselbe Struktur auch an wechselnder Stelle innerhalb der Kachel, was einer Datenerweiterung (data augmentation) entspricht.

Das gleitende Fenster wird je zusammenhängendem Bereich verschoben und nicht über alle Gebiete hinweg, damit die großen unannotierten Zwischenräume ausgelassen werden. Die acht aneinandergrenzenden Teilflächen der Schneise I bilden ein durchgehendes Raster, wohingegen alle übrigen Teilflächen isoliert liegen und einzeln verarbeitet werden.

Jede Kachel muss dieselbe Anzahl an Punkten enthalten, weil das Netz eine feste Eingabegröße erwartet. Aus jedem Fenster werden deshalb 8.192 Punkte ohne Zurücklegen gezogen, damit kein Punkt doppelt in eine Kachel gelangt und dort eine Dichte vortäuscht, die in den Daten nicht vorhanden ist. Enthält ein Fenster weniger Punkte, wird es verworfen, was vor allem Randfenster betrifft, die nur zum Teil innerhalb einer annotierten Fläche liegen. Aus 4.170 Fenstern entstehen auf diesem Weg 3.017 Kacheln. Gezogen wird mit einem festen Startwert des Zufallsgenerators, damit ein erneuter Export dieselben Kacheln erzeugt und die Läufe der Ablationsstudie vergleichbar bleiben. Wie viele Punkte eine Kachel enthält, gehört zu den Faktoren, die dort variiert werden (Abschnitt 3.4).

Die Punkte jeder Kachel werden auf die Fenstermitte zentriert, damit das Netz keine absoluten Koordinaten lernt, sondern nur die Anordnung der Punkte zueinander. Die Farbkanäle einschließlich des Nahinfrarotkanals erhalten Werte zwischen null und eins. Die Klassenbezeichner werden von der Nummerierung eins bis acht auf null bis sieben umgeschrieben, so wie es die Implementierung erwartet. Abgelegt wird jede Kachel als Textdatei, in der eine Zeile einem Punkt entspricht. Dort stehen in fester Reihenfolge die zentrierten X- und Y-Koordinaten, die normalisierte Höhe, die vier Farbkanäle, die beiden lokalen Höhenmerkmale, das Label sowie die drei Qualitätsattribute.

3.2.7 Räumlich getrennte Datenaufteilung

Bevor trainiert werden kann, muss der Kacheldatensatz in einen Trainings-, einen Validierungs- und einen Testteil zerlegt werden, damit die abschließende Bewertung auf Kacheln beruht, die das Netz nie gesehen hat.

Die Kacheln zufällig auf die drei Teile zu verteilen, wäre in diesem Fall irreführend, denn wegen der 50-prozentigen Überlappung enthalten zwei benachbarte Kacheln zur Hälfte dieselben Punkte. Landet nun die eine im Training und die andere in der Validierung, wird das Netz an Punkten geprüft, mit denen es trainiert wurde, sodass die gemessene Güte zu optimistisch ausfiele.

Verteilt werden deshalb nicht einzelne Kacheln, sondern räumlich voneinander getrennte Blöcke. Alle Kacheln eines Blocks gehen geschlossen in denselben Teil, sodass keine Überlappung eine Grenze überschreiten kann. Die isoliert liegenden Teilflächen bilden jeweils einen eigenen Block, wohingegen die Schneise I als großes, zusammenhängendes Gebiet in drei Blöcke aufgeteilt wird, zwischen denen jeweils ein zehn Meter breiter Streifen frei bleibt, sodass kein Fenster über eine Blockgrenze reichen kann. Ohne diese Aufteilung fiel der gesamte Landschaftstyp der Schneise I in einen einzigen Teil, sodass das Netz auf ihm entweder nicht trainiert oder nicht geprüft würde.

Verteilt werden die Blöcke mit dem Ziel einer Aufteilung von 70 zu 15 zu 15 Prozent, die sich nur annähern lässt, weil immer ganze Blöcke vergeben werden. Von den 3.017 Kacheln entfallen am Ende 2.094 auf das Training, 455 auf die Validierung und 468 auf den Test, was 69, 15 und 16 Prozent entspricht. Beide Untersuchungsgebiete, der Authausener Wald und die Cuxhavener Küstenheide, sind in allen drei Teilen vertreten, sodass keiner der beiden Landschaftstypen ausschließlich im Training oder ausschließlich im Test vorkommt.

3.3 Modell und Trainingssetup

3.3.1 Architektur

Als Netz kommt PointNet++ in der Variante für semantische Segmentierung zum Einsatz, deren Aufbau in Abschnitt 2.4.3 beschrieben ist [20]. Gewählt wurde es, weil es Punktwolken unmittelbar verarbeitet und die Höhenstruktur des Bestandes erhält, während zweidimensionale Verfahren die dritte Dimension auf ein Rasterbild projizieren müssen. Genau an dieser Struktur hängt die Unterscheidung zwischen Busch und Heide.

Die Umsetzung folgt der frei verfügbaren Referenzimplementierung von Yan [21], die unter der MIT-Lizenz steht. Übernommen wurde sie unverändert als eigener Commit, bevor die erste eigene Zeile entstand, sodass sich jede spätere Änderung dieser Arbeit zuordnen lässt.

Das Netz betrachtet eine Kachel in vier Set-Abstraction-Stufen mit jeweils größerem Blickfeld. In der ersten Stufe wählt es 1.024 Punkte als Zentren aus und beschreibt jedes davon anhand von bis zu 32 Nachbarn im Umkreis von 0,1 Metern, wodurch feine Textur erfasst wird. Über die folgenden Stufen sinkt die Zahl der Zentren auf 256, 64 und schließlich auf 16, während der Umkreis auf 0,2, 0,4 und 0,8 Meter wächst. Die Szene wird dadurch von Stufe zu Stufe gröber betrachtet, dafür aber im größeren Zusammenhang. Vier Feature-Propagation-Stufen verteilen die so gewonnenen Beschreibungen anschließend wieder auf alle Punkte, sodass am Ende jeder einzelne Punkt einen Wert je Klasse erhält. Eine Dropout-Schicht setzt während des Trainings in jedem Schritt zufällig die Hälfte der Merkmalswerte auf null, sodass sich das Netz nicht auf einzelne Merkmale verlassen kann und weniger zur Überanpassung (overfitting) neigt. Bei der Anwendung des fertigen Modells bleibt sie abgeschaltet. Eingabekanäle, Nachbarschaftsradien und die Zahl der Radien je Stufe sind umschaltbar und gehören zu den Faktoren, die in Abschnitt 3.4 variiert werden.

3.3.2 Verlustfunktion

Was ein Netz lernt, steuert die Verlustfunktion (loss function). Sie misst, wie weit die Vorhersage vom Label abweicht, und genau dieser Wert wird beim Training minimiert. Zwei Eigenschaften der Trainingsdaten erfordern an dieser Stelle einen Eingriff.

Die erste ist das Klassenungleichgewicht (class imbalance), denn Bäume und Heide stellen zusammen den weit überwiegenden Teil der Punkte, während `deadwood` und `soil` nur vereinzelt vorkommen. Ein Netz kann den Fehler am einfachsten senken, indem es die seltenen Klassen gar nicht erst vorhersagt. Um dem entgegenzuwirken, geht jede Klasse mit einem eigenen Klassengewicht in den Verlust ein. Es berechnet sich aus dem Kehrwert der Wurzel ihrer Häufigkeit und fällt damit umso größer aus, je seltener die Klasse ist. Die Wurzel schwächt den Ausgleich bewusst ab, denn ohne sie bekämen die seltensten Klassen ein so hohes Gewicht, dass das Training instabil würde.

Die zweite Eigenschaft ist die unterschiedliche Verlässlichkeit der Labels, denn nicht jedes annotierte Segment war im Luftbild gleich gut zu erkennen. Aus den drei Qualitätsattributen wird deshalb je Punkt ein zusätzliches Gewicht abgeleitet, das unsichere und schlecht sichtbare Punkte abschwächt, ohne sie ganz auszuschließen. In der Praxis wirkt es kaum,

denn von den 76.193 Segmenten sind nur 220 als verschattet oder überbelichtet markiert, während 75.916 den höchsten Sicherheitswert tragen.

Beide Gewichtungen greifen nacheinander, denn der Fehler eines Punktes wird zuerst mit dem Gewicht seiner Klasse multipliziert und anschließend über alle Punkte gemittelt, wobei jeder Punkt entsprechend seinem Qualitätsgewicht in dieses Mittel eingeht. Die Qualitätsattribute sind damit kein Eingabemerkmale des Netzes, sondern steuern nur, wie stark ein Punkt beim Lernen zählt.

3.3.3 Training

Die Trainingsparameter bleiben über alle Läufe unverändert, damit Unterschiede zwischen ihnen allein auf den jeweils geänderten Faktor zurückgehen. Optimiert wird mit dem Adam-Verfahren [31], das auch die Referenzimplementierung verwendet. Die Lernrate beginnt bei 0,001 und fällt alle zehn Epochen auf 70 Prozent ihres Wertes, sodass das Netz zunächst grob und gegen Ende fein nachjustiert. Hinzu kommt ein Gewichtsverfall (weight decay) von 0,0001. Das Training läuft über 64 Epochen in Stapeln (batches) von 32 Kacheln, wobei es ab run08 nur noch 16 sind, weil die verdoppelte Punktzahl je Kachel den Speicherbedarf entsprechend erhöht. Gerechnet wurde in einer Conda-Umgebung mit Python 3.9 auf einer CUDA-fähigen Grafikkarte im JupyterHub der Universität.

Neben der Überlappung der Kacheln (Abschnitt 3.2.6) kommt während des Trainings eine zweite Form der Datenerweiterung hinzu. Jede Kachel wird vor der Verarbeitung um die Z-Achse um einen zufälligen Winkel gedreht. Auf ihre Koordinaten wird zusätzlich ein Rauschen mit einer Standardabweichung von einem Zentimeter, begrenzt auf fünf Zentimeter, hinzugerechnet. Die Drehung ist fachlich begründet, denn in welche Himmelsrichtung eine Kachel zeigt, sagt nichts über die Vegetation darin aus. Das Rauschen macht das Netz unempfindlicher gegen die Ungenauigkeiten der photogrammetrischen Rekonstruktion.

Gespeichert wird der Zwischenstand mit der höchsten mittleren IoU auf dem Validierungsteil. Als Kriterium dient bewusst nicht der Verlust, sondern die mittlere IoU, weil sie alle Klassen gleich gewichtet und damit derselben Größe folgt, an der die Ergebnisse später gemessen werden.

3.4 Ablationsstudie

Der Studie ging eine Sondierungsphase voraus, in der drei Läufe auf einer kleineren Datenbasis mit sechs annotierten Teilflächen entstanden. Aus ihr stammen die

Kachelparameter, die Wahl der Architektur und die Gewichtung der Punkte über die Qualitätsattribute. Nach der Erweiterung auf 16 Teilflächen wurden alle Läufe neu und ohne Warmstart gerechnet, sodass die Vorläufe auf einer anderen Datengrundlage beruhen und nicht berichtet werden.

Für die eigentliche Studie ändert jeder Lauf gegenüber seinem Vergleichslauf genau einen Faktor und lässt alles Übrige unverändert. Trainiert wird jedes Mal von Grund auf, statt auf einem vorhandenen Modell aufzusetzen, denn nur so lässt sich eine Veränderung dem geänderten Faktor zuordnen. Möglich wird dieses Vorgehen dadurch, dass sich Klassenschema und Nachbarschaftsradien über Umgebungsvariablen umstellen lassen und die Zahl der Eingabemerkmale aus der Spaltenzahl der Kacheldateien abgeleitet wird. Trainings- und Auswertungsskript bleiben für alle Varianten unverändert, ergänzt um ein Protokoll, das festhält, welche Einstellungen ein Lauf verwendet hat. Streng eingehalten wird das bei allen Läufen außer run08, bei dem die verdoppelte Punktzahl je Kachel zwei weitere Änderungen nach sich zieht, nämlich eine halbierte Stapelgröße und den Wegfall des Auffüllens unvollständiger Fenster.

Tabelle 1: Übersicht der Ablationsläufe mit dem jeweils geänderten Faktor und dem Lauf, gegen den verglichen wird. Eigene Darstellung.

Lauf	Geänderter Faktor	Vergleich
run01	Ausgangskonfiguration mit acht Klassen und sechs Kanälen	
run02	Nahinfrarot als siebter Kanal	run01
run03	Focal Loss statt gewichtetem Verlust	run02
run04	Reduktion auf sechs Klassen	run02
run05	Zwei lokale Höhenmerkmale als achter und neunter Kanal	run04
run06	Reduktion auf zwei Klassen, Gehölz gegen Rest	run05
run07	Nachbarschaftsradien um Faktor 2,5 vergrößert	run05
run08	8.192 statt 4.096 Punkte je Kachel	run07
run09	Zwei Radien je Stufe (multi-scale grouping)	run08

Zwei der neun Läufe erweitern die Merkmale je Punkt, einer verändert die Verlustfunktion, zwei vereinfachen das Klassenschema und die letzten drei verändern die Geometrie der Nachbarschaftssuche im Netz, wie Tabelle 1 zeigt. Diese letzte Gruppe geht auf eine Zwischenauswertung zurück, denn nachdem mehrere Änderungen an Merkmalen und Verlustfunktion ohne Wirkung geblieben waren, wurde geprüft, ob die Nachbarschaftsparameter des Netzes überhaupt zur Punktdichte der Daten passen. Die Radien der Referenzimplementierung sind auf den Innenraumdatensatz S3DIS abgestimmt, dessen Blöcke einen Meter Kantenlänge haben und ebenfalls 4.096 Punkte enthalten. Auf Kacheln von zehn Metern übertragen findet die erste Set-Abstraction-Stufe bei einem Radius von 0,1 Metern im Median nur einen einzigen Punkt, nämlich ihr eigenes Zentrum,

und lernt dort folglich nichts. Daraus ergaben sich zwei Wege, entweder die Radien zu vergrößern oder die Punktzahl je Kachel zu erhöhen.

Aus dem Export für run08 ergibt sich eine Einschränkung des Vergleichs, denn mit ihm änderten sich nicht nur die Trainings-, sondern auch die Testkacheln. Randfenster mit zu wenigen Punkten blieben bis dahin erhalten, weil sie durch Kopien vorhandener Punkte aufgefüllt wurden. Nun dagegen werden sie verworfen. Übrig bleiben dadurch 468 statt 487 Testkacheln. Da Läufe auf unterschiedlichen Testmengen nicht vergleichbar sind, wurden run05 bis run07 nachträglich gegen die neue Testmenge ausgewertet. Möglich ist das ohne Neutraining, weil PointNet++ beliebige Punktzahlen verarbeitet und run05 bis run07 dieselben neun Eingabekanäle nutzen wie run08 und run09. Die Läufe run05 bis run09 stehen damit alle auf derselben Testmenge von 468 Kacheln. Für run01 bis run04 gilt das nicht, denn ihre Eingabeschicht ist auf sechs oder sieben Kanäle festgelegt und passt damit nicht zu den neun Kanälen des neuen Exports. Diese vier Läufe stehen deshalb in einer eigenen Tabelle mit der ursprünglichen Testmenge.

3.5 Evaluation

Bewertet wird jeder Lauf auf dem Testteil, der bis dahin unberührt geblieben ist. Ein eigenes Skript sammelt die Vorhersagen über alle Testkacheln in einer gemeinsamen Konfusionsmatrix und leitet daraus die in Abschnitt 2.5 definierten Kennzahlen der Segmentierung ab. Ergänzend gibt das Skript die zehn häufigsten Verwechslungen aus, woran sich ablesen lässt, zwischen welchen Klassen die Fehler tatsächlich auftreten.

Für die Fragestellung reicht die mittlere IoU allerdings nicht aus, weil sie über alle Klassen mittelt und deshalb zwischen Läufen mit acht, sechs oder zwei Klassen nicht vergleichbar ist. Zusätzlich werden die Vorhersagen jedes Modells nachträglich zu Gehölz, das heißt `bush` und `tree`, sowie dem Rest zusammengefasst und für diese Zweiteilung IoU, Precision, Recall und F1-Score berechnet. Diese Größe hängt nicht vom trainierten Klassenschema ab und entspricht unmittelbar dem, was für den Verbuschungsgrad gebraucht wird. Zugleich ist sie der Maßstab, an dem sich der binäre Lauf messen lassen muss, denn die Gehölzklasse lässt sich auf zwei Wegen gewinnen, entweder durch ein eigens auf zwei Klassen trainiertes Modell oder durch nachträgliches Zusammenfassen der Vorhersagen eines Mehrklassenmodells. Der zweite Weg verursacht keinen zusätzlichen Aufwand, sodass sich ein eigens binär trainiertes Modell nur rechtfertigt, wenn es besser abschneidet.

Zu jedem Lauf entsteht ein Protokoll mit Konfusionsmatrix, Kennzahlen je Klasse und der Zusammenfassung Gehölz gegen Rest, sodass sich die Läufe im Nachhinein ohne erneute Berechnung gegenüberstellen lassen.

3.6 Quantifizierung des Verbuschungsgrades

Nachdem die vorangegangenen Abschnitte beschrieben haben, wie gut das Netz einzelne Punkte einer Vegetationsklasse zuordnet, geht es nun um die eigentliche Zielgröße der Arbeit. Aus den punktwisen Vorhersagen des in der Ablationsstudie besten Modells, run07, soll ein Verbuschungsgrad je Fläche entstehen, der sich mit einer im Gelände erhobenen Schätzung vergleichen lässt.

3.6.1 Vorbereitung der Befliegungsgebiete

Während für Training und Bewertung die 16 annotierten Teilflächen ausreichen, muss für den Verbuschungsgrad das vollständige Befliegungsgebiet klassifiziert werden, weil die Flächen der Geländekartierung überwiegend außerhalb der annotierten Ausschnitte liegen. Verarbeitet wurden deshalb die vier Authausener Befliegungen mit zusammen 100,6 Millionen Punkten.

Vorbereitet werden sie mit denselben Schritten und unveränderten Parametern wie die Trainingsdaten (Abschnitte 3.2.2 und 3.2.5). Schon eine abweichende Kappungsgrenze oder ein anderer Bodenfilter würde dazu führen, dass derselbe Merkmalswert bei der Anwendung anders zu deuten ist als beim Training.

Die Verarbeitung läuft blockweise in Abschnitten von hundert Metern, denen jeweils ein Puffer von zwanzig Metern beigegeben wird, da sich eine Bodenklassifikation über mehrere Quadratkilometer weder im Arbeitsspeicher halten noch in vertretbarer Zeit rechnen ließe [27]. Dieser Puffer verhindert Stufen in der Bodeninterpolation an den Blockgrenzen und wird vor dem Schreiben wieder entfernt. Als Ergebnis liegen dann georeferenzierte LAZ-Blöcke vor, die die beiden Höhenmerkmale als zusätzliche Punktattribute mitführen.

3.6.2 Anwendung des Modells

Während alle bisherigen Läufe der Messung auf gelabelten Kacheln beruhten, wird das Modell nun auf Punkte angewendet, für die keine Annotation vorliegt. Zerlegt werden die Blöcke dabei in Fenster derselben Größe und mit demselben Versatz wie beim Training (Abschnitt 3.2.6), wobei die Fensterursprünge nun nicht mehr am Rand der jeweiligen Fläche ansetzen, sondern auf einem gemeinsamen Raster über alle Blöcke hinweg liegen. Andernfalls wären die Fenster zweier Nachbarblöcke gegeneinander verschoben und ein Punkt an der Grenze fiel in unterschiedlich geschnittene Nachbarschaften. Geladen wird jeder Block zusammen mit einem Saum von zehn Metern aus den angrenzenden Blöcken,

vorhergesagt werden jedoch nur seine eigenen Punkte. Ohne diesen Saum sähe das Netz an jeder Blockgrenze nur eine halbe Nachbarschaft.

Aus dem Versatz von fünf Metern bei zehn Metern Kantenlänge (Abschnitt 3.2.6) folgt, dass jeder Punkt in bis zu vier Fenstern liegt und entsprechend mehrfach vorhergesagt wird. Statt diese Vorhersagen auszuzählen und die häufigste zu übernehmen, werden die Klassenwahrscheinlichkeiten über alle beteiligten Fenster gemittelt und erst aus dem Mittel die wahrscheinlichste Klasse bestimmt. Dadurch setzt sich eine sichere Vorhersage gegen eine unsichere durch und Randfehler einzelner Fenster gleichen sich aus. Der gemittelte Höchstwert bleibt als Sicherheitsmaß je Punkt erhalten.

Anders als beim Training, wo unvollständig belegte Fenster verworfen wurden, lässt sich hier nicht auf Bereiche verzichten, für die anschließend ein Verbuschungsgrad berechnet werden soll. Vorhergesagt wird deshalb auch in dünn belegten Fenstern, sofern sie mindestens hundert Punkte enthalten.

3.6.3 Bezugsfläche und Verbuschungsmaß

Naheliegender wäre, den Verbuschungsgrad als Anteil der Gehölzpunkte an allen Punkten einer Fläche zu berechnen. Dieses Maß wäre jedoch verzerrt, weil die Punktdichte einer photogrammetrischen Punktwolke ungleich verteilt ist und ein Strauch mit Ästen und Textur je Quadratmeter ein Vielfaches der Punkte liefert, die auf flachem Sandboden entstehen. Unter Gehölzen fehlen zugleich Punkte, weil die Kronen den Boden verdecken, sodass ein Punktanteil die Verbuschung systematisch überschätzen würde.

Verwendet wird stattdessen die projizierte Flächendeckung, also der von oben sichtbare Anteil der Fläche. Dafür wird ein Raster von 0,25 Metern über die Fläche gelegt, in dem jede Zelle Klasse und normalisierte Höhe ihres höchsten vorhergesagten Punktes übernimmt. Das entspricht dem Blick von oben, denn was von oben sichtbar ist, bedeckt den Boden. Ein Heidepunkt unter einem Buschzweig zählt folglich nicht als offene Heide. Da die Referenzdaten auf einer Deckungsgradschätzung im Gelände beruhen, die demselben Prinzip folgt, sind beide Größen unmittelbar vergleichbar.

Als verbuscht gilt eine Zelle dieses Feinrasters, wenn ihre Klasse `bush` oder `tree` lautet und ihre Höhe unterhalb einer festgelegten Grenze bleibt. Nötig ist diese zusätzliche Bedingung, weil die Klasse `tree` zwei fachlich verschiedene Dinge zusammenfasst, nämlich die aufkommenden Pioniergehölze auf der Offenfläche und den angrenzenden Altbestand, dessen Kronen über die Polygongrenze ragen. In der Klasse unterscheiden sich beide nicht, wohl aber in der Höhe. Fachlich deckt sich das mit der Definition, nach der

Verbuschung das Aufkommen von Pioniergehölzen auf offener Fläche meint und nicht den benachbarten Wald.

Welchen Wert diese Grenze annimmt, wurde aus dem Vergleich mit der Referenz bestimmt. Berechnet wurden dafür Varianten mit zwei, drei, fünf und acht Metern sowie eine ohne Begrenzung, die nach demselben Verfahren gegen die Kartierung geprüft werden (Abschnitt 3.6.4). Welche Grenze sich durchsetzt, zeigt Abschnitt 4.4.

3.6.4 Referenzdaten und Validierung

Als Referenz dient die FFH- und Biotoptypenkartierung des Authausener Waldes aus dem Jahr 2014 [32], die 393 Polygone umfasst und im Feld `VERBUP` den im Gelände geschätzten Verbuschungsgrad in Prozent führt. Ausgewertet werden ausschließlich Offenlandbiotop, Heiden und Magerrasen, Moore und Sümpfe, Staudenfluren sowie Grünland. In Wäldern, Gewässern und Rohbodenbiotopen ist die Größe nicht definiert und steht dort ausnahmslos auf null. Ein Polygon geht nur dann in die Auswertung ein, wenn mindestens 80 Prozent seiner Fläche mit Vorhersagen belegt sind und es mindestens 200 Zellen des Feinrasters umfasst. Somit verbleiben 43 Polygone, von denen 19 auf Heiden und Magerrasen entfallen und 14 von diesen dem Lebensraumtyp 4030, den trockenen europäischen Heiden, zugeordnet sind.

Zwischen Kartierung und Befliegung liegen elf Jahre, was den Vergleich belastet, denn eine 2014 frisch entkusselte Fläche ist bis 2025 wieder aufgewachsen. Um solche Fälle kenntlich zu machen, wird das Bemerkungsfeld der Kartierung nach Hinweisen auf kurz zuvor erfolgte Pflegemaßnahmen durchsucht. Sieben der 43 Polygone tragen einen solchen Vermerk, weshalb alle Kennzahlen zweimal berechnet werden, um eine mögliche Verzerrung des Ergebnisses auszuschließen.

Berichtet werden die in Abschnitt 2.5 definierten Kennzahlen des Verbuschungsgrades. Da bei einer Stichprobe dieser Größe einzelne Flächen die Absolutwerte verzerren können, tritt die Rangkorrelation nach Spearman hinzu, die allein die Reihenfolge der Flächen bewertet.

Aus demselben Feinraster entsteht schließlich ein Auswerteraster von fünf Metern, dessen Zellen jeweils den Anteil der als Verbuschung vorhergesagten Feinzellen an den kartierten Feinzellen tragen. Zellen, in denen weniger als die Hälfte der Feinzellen belegt ist, bleiben leer, damit dünn abgedeckte Randbereiche keine Scheinwerte liefern. Ausgegeben wird ein GeoTIFF in EPSG 25832, das über die vier Befliegungen 64,5 Hektar mit Werten abdeckt und damit ein Vielfaches der 24,9 Hektar, die die Geländekartierung beisteuert.

Sämtliche Skripte der beschriebenen Verarbeitungskette sind öffentlich verfügbar [33]. Das Repository enthält die Vorverarbeitung in R, das Training, die Auswertung und die Berechnung des Verbuschungsgrades, nicht jedoch die Punktwolken und Annotationen.

4 Ergebnisse und Diskussion

Befund und Deutung bleiben in diesem Kapitel getrennt. Die Ergebnisse der neun Ablationsläufe, der Segmentierung und der Verbuschungsberechnung werden zunächst berichtet, ihre Einordnung folgt geschlossen im Diskussionsteil.

4.1 Ergebnisse der Ablationsstudie

Getrennt nach den beiden Testmengen, die in Abschnitt 3.4 erläutert werden, halten die Tabellen 2 und 3 die Kennzahlen aller neun Läufe fest. Aussagekräftig ist jeweils nur der Vergleich innerhalb einer Tabelle, wobei run07 als einziger Lauf auf beiden Testmengen ausgewertet vorliegt und die beiden Teile miteinander verbindet. Von den acht Eingriffen, die gegenüber ihrem Vergleichslauf genau einen Faktor ändern, wirkt einer.

Tabelle 2: Ergebnisse der Läufe run01 bis run04 auf der Testmenge mit 487 Kacheln. Die mIoU von run04 mittelt über sechs statt acht Klassen. Eigene Darstellung.

Lauf	Klassen	OA	mIoU	IoU bush	Val.-mIoU (Ep.)
run01	8	0,671	0,248	0,394	0,356 (53)
run02	8	0,674	0,242	0,339	0,349 (7)
run03	8	0,650	0,229	0,329	0,346 (6)
run04	6	0,662	0,344	0,393	0,447 (58)

Der Nahinfrarotkanal bringt in der Gesamtbilanz keinen Gewinn, denn mittlere IoU und Gesamtgenauigkeit bleiben unverändert. Zwischen den Klassen verschiebt sich lediglich die Güte, denn die IoU von `graminoid` steigt von 0,292 auf 0,375, wohingegen `heath` von 0,262 auf 0,177 zurückfällt. Aufschlussreicher als die Kennzahlen selbst ist der Zeitpunkt des besten Modells, das statt in Epoche 53 bereits in Epoche 7 erreicht wird, denn ein Kanal ohne zusätzlichen Informationsgehalt führt das Netz früher in die Überanpassung. Naheliegender ist, dass sich die grünen Vegetationsklassen auch im Nahinfrarot zu ähnlich verhalten und gerade die Trennung ausbleibt, auf die es ankommt.

Noch deutlicher fällt das Urteil über den Focal Loss aus, der klassenweise durchweg schlechtere Werte liefert und auch die Gesamtgenauigkeit senkt. Am härtesten trifft es die ohnehin schwachen Klassen, denn die IoU von `soil` bricht von 0,035 auf 0,001 ein und `other` verschwindet ganz. Zusammen mit den bereits kräftigen Klassengewichten überbetont der Focal Loss offenbar die seltenen Klassen, die sich in diesem Datensatz

grundsätzlich nicht trennen lassen und verschlechtert im selben Zug die Klassen, die schon vorher gut trennbar waren.

Der Wechsel auf sechs Klassen hebt die mittlere IoU von 0,242 auf 0,344, doch der größere Teil dieses Sprungs ist mechanisch bedingt. Bildet man die Vorhersagen von run02 nachträglich auf dasselbe Schema ab, indem `sand` und `soil` zu `ground` zusammengefasst und die Klasse `other` entfernt wird, so ergibt sich bereits eine mittlere IoU von 0,336. Auf das Training mit weniger Klassen entfällt somit nur der kleinere Rest. Aufschlussreich ist trotzdem die Klasse `ground`, die durch das bloße Zusammenfassen von einer IoU um 0,04 auf 0,162 springt, denn Sand und offener Boden wurden gegeneinander verwechselt und nicht grundsätzlich übersehen. Für die Fragestellung dieser Arbeit günstig ist außerdem, wie sich die Güte zwischen den Vegetationsklassen verschiebt, denn die IoU von `bush` steigt von 0,339 auf 0,393 und die von `heath` von 0,177 auf 0,255, zulasten von `graminoid`, das von 0,375 auf 0,258 zurückfällt. Die Kernverwechslung löst die neue Taxonomie nicht, wohl aber erlaubt sie ein stabileres Training, wie das späte Optimum in Epoche 58 statt in Epoche 6 oder 7 zeigt.

Von den beiden lokalen Höhenmerkmalen war zu erwarten, dass sie Büsche und gleich hohe Heide voneinander lösen, doch die mittlere IoU steigt nur von 0,344 auf 0,348. Nach wie vor sagt das Netz gut vier von zehn Buschpunkten als `graminoid` voraus. Verantwortlich ist die Auflösung der Merkmale, denn `z_range` und `z_rel` beruhen auf Rasterzellen von 0,5 beziehungsweise 2,5 Metern, sodass alle Punkte einer Zelle denselben Bezugswert erhalten und ein Grasbüschel neben einem Busch dessen Höhenspanne erbt. Genau an dieser Stelle sitzt der Fehler, den die Merkmale beheben sollten.

Tabelle 3: Ergebnisse der Läufe run05 bis run09 auf der Testmenge mit 468 Kacheln. Die mIoU von run06 steht in Klammern, weil sie über zwei statt sechs Klassen mittelt. Eigene Darstellung.

Lauf	Klassen	mIoU	IoU bush	IoU Gehölz	Precision	Recall	F1
run05	6	0,357	0,413	0,724	0,934	0,763	0,840
run06	2	(0,725)	–	0,713	0,966	0,731	0,833
run07	6	0,393	0,500	0,761	0,930	0,808	0,864
run08	6	0,361	0,452	0,730	0,892	0,801	0,844
run09	6	0,347	0,359	0,701	0,942	0,733	0,824

Mit run06 wird das Klassenschema ein zweites Mal vereinfacht, diesmal bis auf zwei Klassen, sodass das Netz von Grund auf nur noch Gehölz gegen alles Übrige lernt. Dahinter stand die Überlegung, dass ein Teil der Kapazität auf die schwierige Trennung von Heide und Gras entfällt, die für den Verbuschungsgrad keine Rolle spielt. Gemessen wird es deshalb am einfacheren Weg, die sechs Klassen von run05 im Nachhinein zusammenzufassen

(Abschnitt 3.5). Das gelingt nicht, denn das binäre Modell bleibt bei Gehölz-IoU und F1-Wert knapp hinter dem zusammengefassten Sechsklassenmodell zurück und verschiebt lediglich das Verhältnis von Precision und Recall, indem es die Klasse Gehölz seltener vergibt und dabei seltener irrt. Die Vermutung, das Netz verschwende Kapazität, bestätigt sich somit nicht. Die Grenze zwischen Gehölz und niedriger Vegetation ist in den Daten selbst schwach ausgeprägt und wird nicht erst durch das Klassenschema verdeckt.

Wirkung zeigt einzig die Vergrößerung der Nachbarschaftsradien, die aus der in Abschnitt 3.4 beschriebenen Messung der Punktdichte hervorging. Auf der Testmenge mit 468 Kacheln steigen alle für die Fragestellung wichtigen Kennzahlen deutlich, die IoU von `bush` von 0,413 auf 0,500 und die Gehölz-IoU von 0,724 auf 0,761. Auf der ursprünglichen Testmenge mit 487 Kacheln sinkt die mittlere IoU im selben Vergleich dagegen von 0,348 auf 0,336, weil `graminoid` und `ground` verlieren. In dieser Gegenläufigkeit zeigt sich ein Skalenkonflikt, denn ein Busch ist ein großes Objekt und braucht Kontext, wohingegen die Unterscheidung von Gras und Zwergstrauchheide an feiner Textur hängt und mit größeren Nachbarschaften verwischt wird. Für diese Arbeit ist der Tausch günstig, weil sie vor allem eine verlässliche Gehölzerkennung braucht.

Die zweite mögliche Antwort auf die geringe Punktdichte, die verdoppelte Punktzahl je Kachel, verschlechtert das Ergebnis auf identischer Testmenge durchweg, wobei sich einzig `ground` verbessert. Auch Multi-Scale Grouping bringt keinen Gewinn und bleibt der schwächste Lauf der Reihe, wobei einzig `graminoid` den zweitbesten Wert aller Läufe erreicht. Sein zusätzlicher feiner Zweig arbeitet mit einem Radius von 0,125 Metern und findet nach der gemessenen Punktdichte selbst bei 8.192 Punkten je Kachel nur ein bis zwei Nachbarn, sodass er keine zusätzliche Information über einen Punkt liefert.

Über alle Läufe hinweg blieb die Verwechslung zwischen Zwergstrauchheide, Gras und Busch bestehen, obwohl mit dem Nahinfrarot, dem Focal Loss, dem reduzierten Klassenschema, den expliziten Höhenmerkmalen und dem binären Modell fünf voneinander unabhängige Ansätze an ihr angesetzt haben. Dass am Ende ein Parameter der Nachbarschaftssuche wirkt und kein zusätzliches Merkmal, spricht dafür, dass dem Netz nicht Informationen fehlte, sondern eine zur Punktdichte passende räumliche Bezugsgröße. Bemerkenswert ist daneben die Klasse `tree`, deren IoU in allen acht Mehrklassenläufen zwischen 0,937 und 0,963 liegt. Strukturell eindeutige Objekte werden zuverlässig erkannt und die Schwäche betrifft ausschließlich die niedrige Vegetation.

Für alle Vergleiche in beiden Tabellen gilt allerdings eine Einschränkung, die aus dem Zuschnitt des Validierungsteils folgt. Die besten Validierungswerte von `run07`, `run08` und `run09` liegen bei 0,4684, 0,4685 und 0,4656 und somit praktisch gleichauf. Auf dem Testteil streuen dieselben Modelle dagegen zwischen 0,347 und 0,393. Der Validierungsteil besteht

aus drei räumlich getrennten Blöcken, von denen ein einziger 378 der 455 Kacheln stellt, sodass das Auswahlkriterium im Wesentlichen an einer Teilfläche hängt. Welche der drei Varianten als bestes Modell gespeichert wird, entscheidet sich deshalb zu einem erheblichen Teil zufällig und Unterschiede von wenigen Tausendsteln sind nicht als Effekt zu deuten.

Als finales Modell dient deshalb run07. Es erreicht auf der Testmenge mit 468 Kacheln zugleich die beste mittlere IoU und die beste Gehölzerkennung. Seine Radien gehen zudem auf die gemessene Punktdichte der Kacheln zurück. Abschnitt 4.2 betrachtet seine Ergebnisse im Einzelnen.

4.2 Güte der semantischen Segmentierung

Ausgewertet wird run07 auf dem Testteil der annotierten Kacheln, der während des gesamten Trainings unberührt geblieben ist. Dort erreicht das Modell eine Gesamtgenauigkeit von 0,650 und eine mittlere IoU von 0,393. Hinter diesen beiden Werten steht eine große Spannweite, die Tabelle 4 klassenweise aufschlüsselt. Bäume erkennt das Modell nahezu fehlerfrei, `bush` erreicht ein mittleres Niveau und `ground` sowie `deadwood` bleiben schwach.

Tabelle 4: Klassenweise Kennzahlen des Modells run07 auf dem Testteil. Der Anteil gibt die wahren Punkte der Klasse an. Eigene Darstellung.

Klasse	IoU	Precision	Recall	F1	Anteil
bush	0,500	0,788	0,577	0,666	25,9 %
deadwood	0,196	0,239	0,523	0,328	1,2 %
graminoid	0,296	0,583	0,376	0,457	28,5 %
heath	0,322	0,358	0,762	0,487	14,9 %
ground	0,103	0,518	0,114	0,187	1,3 %
tree	0,938	0,971	0,965	0,968	28,3 %
Gehölz	0,761	0,930	0,808	0,864	54,2 %

Maßgeblich für die Fragestellung ist die letzte Zeile dieser Tabelle. Auf der Ebene von Gehölz gegen Rest findet das Modell vier von fünf tatsächlich vorhandenen Gehölzpunkten (Recall). Von den als Gehölz ausgewiesenen Punkten gehören über neun von zehn wirklich dazu (Precision). Die mittlere IoU fällt vor allem deshalb so niedrig aus, weil ein erheblicher Teil der Fehler zwischen `graminoid` und `heath` entsteht.

Wo genau die Fehler auftreten, zeigt die Konfusionsmatrix in Tabelle 5. Mehr als die Hälfte der Graspunkte weist das Modell der Zwergstrauchheide zu, die falsch zugeordneten

Buschpunkte verteilen sich auf `graminoid` und `heath`, und offener Boden geht zu mehr als zwei Dritteln an `heath` verloren. Sämtliche dieser Verwechslungen betreffen niedrige Bestände, die sich in Höhe und Farbe überschneiden. Bäume dagegen ordnet das Modell zu 96,5 Prozent richtig zu. Die wenigen Fehler betreffen fast nur die Klasse `bush`.

Tabelle 5: Konfusionsmatrix des Modells run07 in Prozent der wahren Klasse. Die Hauptdiagonale entspricht der Accuracy je Klasse. Eigene Darstellung.

wahr \ vorhergesagt	bush	deadw.	gramin.	heath	ground	tree
bush	57,7	3,0	20,9	15,4	0,0	3,0
deadwood	16,1	52,3	12,5	14,4	1,9	2,9
graminoid	7,8	0,5	37,6	54,0	0,1	0,0
heath	5,8	5,1	12,5	76,2	0,4	0,0
ground	1,4	0,5	18,6	68,0	11,4	0,0
tree	2,6	0,9	0,0	0,0	0,0	96,5

Die niedrigsten IoU-Werte erreichen mit `deadwood` und `ground` zugleich die beiden seltensten Klassen, denn sie stellen zusammen nur gut zwei Prozent der Testpunkte. Trotz der Gewichtung im Verlust (Abschnitt 3.3.2) lernt das Netz sie kaum. Da die mittlere IoU alle Klassen gleich gewichtet, ziehen sie den Mittelwert spürbar nach unten. Für die Zielgröße bleibt das folgenlos, weil weder Totholz noch offener Boden in den Verbuschungsgrad eingehen.

4.3 Anwendung auf die Befliegungsgebiete

Auf dieser Grundlage wurde run07 auf vier Befliegungen im Authausener Wald angewendet, nämlich die 110-kV-Trasse mit dem angrenzenden PSA-Platz, die HeideWildnis-Punktwolke sowie die Schneise I und die Schneisen IV und V. Mit 67,4 Millionen Punkten ist die 110-kV-Trasse das mit Abstand größte dieser Gebiete, die übrigen drei liegen zwischen 8,3 und 12,6 Millionen. Klassifiziert wurden auf diese Weise 65,9 Hektar belegter Fläche, für die zuvor keine Annotation vorlag.




Abbildung 8: Vom Modell run07 vorhergesagte Vegetationsklassen im Gebiet HeideWildnis, weiße Umrisse: Polygone der Biotopkartierung. Eigene Darstellung, Hintergrund: Google Satellite.

Wie eine solche Vorhersage aussieht, zeigt Abbildung 8 am Beispiel der HeideWildnis-Punktwolke. Die Offenfläche erscheint als zusammenhängender Bestand aus Zwergstrauchheide und Gras, durchsetzt von einzelnen Buschgruppen, und wird ringsum von einem geschlossenen Saum der Klasse `tree` eingefasst.

Über ein ganzes Gebiet hinweg lässt sich das in Klassenanteilen fassen, hier stellvertretend für die 110-kV-Trasse als größtes der vier Gebiete. Knapp die Hälfte aller Punkte entfällt auf die Klasse `tree`, was der bewaldeten Umgebung der Trasse entspricht, gut ein Zehntel auf

bush und der übrige Anteil überwiegend auf graminoid und heath. Aussagekräftiger als die Verteilung selbst ist die je Punkt mitgeführte Sicherheit, denn sie ordnet sich in derselben Reihenfolge wie die Güte auf dem Testteil. Bei Bäumen liegt sie im Mittel bei 0,98, bei deadwood mit 0,58 am tiefsten. Unsicher ist sich das Modell genau dort, wo es nachweislich häufig falsch liegt.

Ohne Vorhersage bleiben 2,25 Prozent der Punkte, die so dünn belegte Bereiche besetzen, dass kein sie überdeckendes Fenster die Mindestzahl von hundert Punkten erreicht. Für die Auswertung fällt das kaum ins Gewicht, weil ein Kartierungspolygon ohnehin nur dann einbezogen wird, wenn mindestens 80 Prozent seiner Fläche mit Vorhersagen belegt sind (Abschnitt 3.6.4).

Wie belastbar diese Vorhersagen sind, hängt daran, wo die annotierten Teilflächen liegen. Acht der elf Authausener Teilflächen liegen in der Schneise I, die übrigen drei in der 110-kV-Trasse. In der HeideWildnis-Punktwolke und in den Schneisen IV und V hat das Modell folglich nie trainiert, sodass jede dortige Vorhersage, auch die in Abbildung 8 gezeigte, eine Übertragung auf unbekanntes Gelände ist und für die Frage der Übertragbarkeit am meisten aussagt. Klassifiziert wird trotzdem jedes Gebiet lückenlos, denn der Verbuschungsgrad soll gerade für die Flächen außerhalb der annotierten Ausschnitte entstehen. Diese Ausschnitte bedecken rund fünf Prozent der klassifizierten Fläche, in der kleinen Schneise I allerdings über die Hälfte.

4.4 Berechneter Verbuschungsgrad im Vergleich zur Kartierung

Als Referenz gehen 43 Offenlandpolygone der Kartierung von 2014 in die Auswertung ein, die zusammen 24,9 Hektar bedecken und die in Abschnitt 3.6.4 genannten Bedingungen erfüllen. Dem Lebensraumtyp 4030 der trockenen europäischen Heiden gehören 14 von ihnen mit zusammen 9,9 Hektar an. Sieben Polygone tragen im Bemerkungsfeld einen Hinweis auf eine kurz vor der Kartierung erfolgte Pflegemaßnahme. Die Kennzahlen der folgenden Abschnitte beruhen auf den 14 Heidepolygonen mit zusammen 9,9 Hektar, der Vergleich der Höhengrenzen nur auf den sieben Flächen ohne Pflegevermerk mit 5,8 Hektar. Gemessen an den 64,5 Hektar, für die das Verfahren einen Wert liefert, sind das 15 beziehungsweise 9 Prozent.

Tabelle 6: Übereinstimmung des berechneten mit dem kartierten Verbuschungsgrad für sechs Definitionen, gerechnet über die sieben Heidepolygone ohne Pflegevermerk. RMSE und Versatz in Prozentpunkten. Eigene Darstellung.

Definition	RMSE	Versatz	R^2	Pearson	Spearman
nur <code>bush</code>	15,5	−6,9	0,07	0,53	0,45
Gehölz ohne Grenze	16,9	+9,2	−0,10	0,72	0,04
Gehölz unter 2 m	16,4	−7,6	−0,03	0,46	0,45
Gehölz unter 3 m	12,4	−4,6	0,41	0,72	0,38
Gehölz unter 5 m	9,5	+1,8	0,65	0,86	0,23
Gehölz unter 8 m	11,0	+3,8	0,54	0,83	0,34

Welche Höhengrenze die beste Übereinstimmung liefert, zeigt Tabelle 6. Die Grenze von fünf Metern erreicht mit 9,5 Prozentpunkten den kleinsten mittleren Fehler und mit +1,8 Prozentpunkten zugleich den geringsten Versatz. Ohne jede Begrenzung überschätzt das Verfahren die Verbuschung deutlich, weil die überhängenden Kronen des angrenzenden Waldes mit in die Berechnung eingehen. Im Polygon 13001_2623 etwa werden 71,7 Prozent der Fläche als `tree` vorhergesagt, während die Kartierung dort 15 Prozent Verbuschung nennt. Der größte Teil dieser Baumfläche gehört zum umgebenden Wald und nicht zum Gehölzaufwuchs auf der Offenfläche. Zwei und drei Meter als Grenze schließen umgekehrt das inzwischen herausgewachsene Gehölz aus und unterschätzen den Verbuschungsgrad entsprechend.

Belegen lässt sich das an der Kronenhöhe. Auf der stark verbuschten Fläche 13001_4443 liegt die mediane Kronenhöhe der als Gehölz vorhergesagten Zellen bei 3,4 Metern, auf der fast offenen Fläche 13001_2611 dagegen bei 11,6 Metern. Die Grenze bei acht Metern liefert nahezu dieselben Kennzahlen wie die bei fünf, was für eine breite Lücke zwischen aufkommendem Gehölz und Altbestand spricht. Die Wahl der Grenze hängt somit nicht an einem genauen Wert.

Tabelle 7: Kartierter und berechneter Verbuschungsgrad der 14 Polygone des Lebensraumtyps 4030, sortiert nach dem kartierten Wert. Die Kronenhöhe ist der Median der als Gehölz vorhergesagten Zellen. Eigene Darstellung.

Polygon	kartiert	berechnet	Kronenhöhe	2014 gepflegt
13001_4443	50 %	53,0 %	3,4 m	
13001_4444	15 %	29,2 %	2,2 m	
13001_1504	15 %	1,8 %	1,3 m	
13001_2615	10 %	2,4 %	5,6 m	
13001_2624	2 %	2,3 %	6,4 m	
13001_4442	1 %	29,1 %	3,8 m	ja
13001_2611	1 %	2,6 %	11,6 m	
13001_1502	1 %	4,6 %	1,9 m	ja
13001_4452	0 %	7,3 %	1,9 m	ja
13001_2612	0 %	2,5 %	5,5 m	ja
13001_2664	0 %	2,8 %	1,1 m	ja
13001_2666	0 %	3,6 %	1,0 m	ja
13001_1500	0 %	15,1 %	1,2 m	ja
13001_4434	0 %	13,9 %	6,0 m	

Mit dieser Grenze ergeben sich für die Heidepolygone die Werte in Tabelle 7. Bei den stark verbuschten Flächen stimmen Kartierung und Verfahren gut überein, am deutlichsten auf der Fläche 13001_4443, deren kartierte 50 Prozent zugleich der höchste Wert sind, den die Kartierung im gesamten Authausener Wald vergibt. Sie gehört zusammen mit 13001_4444 und 13001_4442 zur HeideWildnis (Abbildung 9). Diese drei Flächen tragen mit 50, 15 und einem Prozent die gesamte Spannweite der Referenz und stammen aus einem Gebiet, in dem keine annotierte Teilfläche liegt. Über alle 14 Heidepolygone hinweg beträgt der mittlere Fehler 11,2 Prozentpunkte bei einem Versatz von +5,4 Prozentpunkten und einem Bestimmtheitsmaß von 0,28. Der Unterschied zu Tabelle 6 geht allein auf die sieben Flächen mit Pflegevermerk zurück, die dort nicht enthalten sind.




Abbildung 9: Berechneter Verbuschungsgrad im Gebiet HeideWildnis, Zellgröße ein Meter, beschriftet mit dem 2014 geschätzten Wert. Eigene Darstellung, Hintergrund: Google Satellite.

Bei den schwach verbuschten Flächen geht diese Übereinstimmung verloren. Bei den sieben der 14 Flächen, die einen Pflegevermerk tragen, liegt der berechnete Wert ausnahmslos über dem kartierten. Auch ohne diese Flächen bleibt die Rangkorrelation nach Spearman mit 0,23 niedrig, das Verfahren bringt die schwach verbuschten Flächen also nicht in die richtige Reihenfolge. Die Ursache wird in Abschnitt 4.5 behandelt.

Unabhängig von den Referenzflächen liefert das Verfahren für jede Rasterzelle des Untersuchungsgebiets einen Wert. Über alle vier Befliegungen sind das 64,5 Hektar oder

rund 25.800 Zellen. Die Hälfte dieser Zellen liegt unter 4,2 Prozent Verbuschung, der Mittelwert beträgt dagegen 20,0 Prozent, denn gut ein Viertel der Zellen überschreitet 30 Prozent und zieht ihn nach oben. Wie Abbildung 10 zeigt, stehen große offene Bereiche einzelnen, stark verbuschten Teilflächen gegenüber. Eine einzelne Kennzahl beschreibt eine so verteilte Fläche deshalb schlecht.




Abbildung 10: Berechneter Verbuschungsgrad der vier Befliegungsgebiete, Zellgröße 20 Meter. Eigene Darstellung, Hintergrund: Google Satellite.

4.5 Diskussion

Die bisherigen Abschnitte haben die Zahlen berichtet, die folgenden ordnen sie ein. Im Mittelpunkt steht dabei die Frage, welcher Anteil der Abweichungen dem Modell zuzuschreiben ist und welcher der Referenz oder dem Verfahren, aus dem die Labels stammen.

4.5.1 Bedeutung der Höheninformation

Den größten Einzeleffekt in der gesamten Auswertung hat nicht die Wahl des Modells, sondern die Höhengrenze. Sie senkt den mittleren Fehler von 16,9 auf 9,5 Prozentpunkte

und hebt das Bestimmtheitsmaß von einem negativen Wert auf 0,65. Der Grund liegt darin, dass die Klasse `tree` Pioniergehölz und Altbestand nicht trennt (Abschnitt 3.6.3). Bestätigt wird das durch die Kartierung von 2014, die 13001_4443 als „Stark von Birke (50 %, bis 3 m hoch) verbuschte Callunaheide“ beschreibt, während die photogrammetrisch gemessene Kronenhöhe dort im Median bei 3,4 Metern liegt. Aus der Klasse allein ist diese Unterscheidung nicht zu gewinnen, da beide Bestände dieselbe Klasse tragen. Erst die Höhe je Zelle macht aus der Segmentierung eine Größe, die der fachlichen Definition entspricht, nach der Verbuschung das Aufkommen von Pioniergehölzen auf offener Fläche meint und nicht den benachbarten Wald.

4.5.2 Zeitlicher Abstand zwischen Kartierung und Befliegung

Zwischen Kartierung und Befliegung liegen elf Jahre. Verbuschung ist genau der Prozess, der sich in dieser Zeit verändert. Sieben der 14 Heidepolygone tragen einen Vermerk über eine kurz zuvor durchgeführte Gehölzentnahme. Gerade bei ihnen liegt der berechnete Wert ausnahmslos über dem kartierten, am deutlichsten auf der Fläche 13001_1500, für die die Kartierung eine kürzlich erfolgte Freistellung unter der Stromleitung vermerkt und das Verfahren eine Verbuschung von 15,1 Prozent ausweist.

Der im Feld `VERBUP` erhobene Wert von null Prozent war im Jahr 2014 durchaus richtig, für 2025 gilt er jedoch nicht mehr. An den Stellen, wo das Verfahren mehr Verbuschung ausweist als die Kartierung, ist deshalb nicht zwangsläufig das Modell im Unrecht, sondern in mehreren Fällen die Referenz veraltet. Aus demselben Grund bleibt auch die Wahl der Höhengrenze ein Kompromiss, weil in elf Jahren herangewachsenes Gehölz genau in dem Bereich liegt, den die Grenze abschneidet.

4.5.3 Vergleich mit der Geländekartierung

Ob ein mittlerer Fehler von 9,5 Prozentpunkten gut ist, zeigt erst der Vergleich mit publizierten Arbeiten. Schmidt et al. erreichen bei der fernerkundlichen Schätzung der Calluna-Deckung ein Bestimmtheitsmaß von 0,79 bei einem mittleren Fehler von 15,7 Prozentpunkten, gestützt auf 700 Stichprobenpunkte [3]. Die hier erreichten Werte liegen in derselben Größenordnung, beruhen jedoch auf sieben Flächen. Der dortige Wertebereich reicht mit null bis 96 Prozent etwa doppelt so weit. Aussagekräftiger als der Mittelwert ist ohnehin die Verteilung der Abweichungen, denn drei der sieben Flächen liegen innerhalb von drei Prozentpunkten, drei weitere weichen um 13 bis 14 Punkte ab. Der Versatz

von +1,8 Prozentpunkten zeigt zugleich, dass sich diese Abweichungen weitgehend ausgleichen und das Verfahren nicht systematisch über- oder unterschätzt.

Wie stark die Übereinstimmung bei den kräftig verbuschten Flächen von einer einzigen getragen wird, zeigt eine Kontrollrechnung ohne 13001_4443, bei der die Korrelation von 0,86 auf 0,32 fällt. Bei sieben Beobachtungen und einem Wert, der mehr als dreimal so hoch liegt wie alle übrigen, ist das zu erwarten. Dass die gegen Ausreißer robuste Rangkorrelation mit 0,23 weit unter dem Bestimmtheitsmaß von 0,65 liegt, zeigt, dass die Übereinstimmung an den Absolutwerten einzelner Flächen hängt und nicht an einer durchgängig richtigen Rangfolge.

Erklären lassen sich die größten Abweichungen über die Bemerkungsfelder. Für die Fläche 13001_2615 nennt die Kartierung eine beginnende Verbuschung mit Birke und Traubenkirsche, also kleine, verstreute Einzelgehölze mit winziger Kronenprojektion, die ein Kartierer im Gelände dennoch als deutliches Signal wahrnimmt. Für 13001_4434 beschreibt sie ein Übergangsbiotop zwischen verheidetem Borstgrasrasen und beerstrauchreichem Kiefernwald, wo der Gehölzanteil als Wesenszug des Biototyps gilt und nicht als Verbuschung. Darin zeigt sich, dass Referenz und Verfahren bei den schwach verbuschten Flächen verschiedene Dinge messen, denn der Kartierer bewertet, ob der Prozess eingesetzt hat, wohingegen das Verfahren überschirmte Fläche misst. Das ist keine Schwäche des Modells, sondern eine inhaltliche Grenze des Vergleichs.

4.5.4 Segmentierungsgüte und Herkunft der Labels

Einordnen lässt sich die erreichte Güte über veröffentlichte Ergebnisse derselben Architektur. Auf dem Straßenraumdatensatz Toronto3D erreicht PointNet++ eine mittlere IoU von 0,418 [19] und liegt damit dicht bei den hier erzielten 0,393, wobei sich beide Datensätze in Sensorik und Klassenschema unterscheiden und deshalb nur die Größenordnung vergleichbar ist. Der Mittelwert verdeckt dabei, wie ungleich sich die Güte über die Klassen verteilt, denn großflächige und strukturell eindeutige Klassen wie Straße und Vegetation erreichen dort 0,893 und 0,690, wohingegen Fahrbahnmarkierungen und Zäune bei 0,000 und 0,030 liegen. Die schwachen Werte für seltene Klassen wie `deadwood` und `ground` folgen demnach einem bekannten Muster dieser Architektur.

Anders verhält es sich mit der Verwechslung zwischen Zwergstrauchheide, Gras und Busch, die allen fünf Ansätzen der Ablationsstudie standgehalten hat und erst auf die Nachbarschaftsradien reagierte (Abschnitt 4.1).

Neben der Punktdichte kommt die Herkunft der Labels als Erklärung in Betracht, denn der Verschnitt überträgt die Klasse eines Polygons auf die gesamte Punktsäule darunter

(Abschnitt 3.2.3). Diesen Fehler in beide Richtungen greift die höhenbasierte Korrektur auf, die sich dabei allerdings eine eigene Schwäche einhandelt, weil sie punktweise und nicht objektbezogen arbeitet. Ein Strauch beispielsweise, dessen Basis am Boden ansetzt, wird an der Grenze von 0,5 Metern waagrecht durchgeschnitten. Hinzu kommt die Reihenfolge der Regeln, denn 40,6 Prozent aller Punkte, die neu die Klasse `bush` erhalten, durchlaufen zuvor eine Hochstufung zu `tree` und werden erst von der Abwärtsregel wieder zurückgestuft.

Daraus folgt eine These, die sich mit den vorliegenden Daten nicht abschließend prüfen lässt, als Erklärungsansatz aber gut begründet ist. Das Netz wird auf genau diesen Labels trainiert und lernt die Grenze bei 0,5 Metern, als wäre sie eine physische Eigenschaft der Vegetation. Ein Teil der Verwechslung zwischen `heath` und `bush`, die sich als hartnäckigste Schwäche des Modells zeigt, wäre dann ein Artefakt der Labelvergabe und keine Grenze der Architektur.

4.5.5 Limitationen

Mit sieben Heidepolygonen in der bereinigten Auswahl und 14 einschließlich der gepflegten Flächen ist die Stichprobe zu klein, um Bestimmtheitsmaß und Korrelation stabil zu schätzen, was der Einbruch der Korrelation nach dem Entfernen einer einzigen Fläche unmittelbar zeigt. Hinzu kommt, dass die Referenz selbst auf grob gestuften Augenmaßschätzungen im Gelände beruht.

Schwerer wiegt ein Ungleichgewicht zwischen Bewertung und Anwendung, denn Validierungs- und Testteil bestehen zu 83 beziehungsweise 66 Prozent aus Kacheln der Cuxhavener Küstenheide, während der Verbuschungsgrad ausschließlich für die Authausener Flächen berechnet wurde. Bewertet wird das Modell also überwiegend auf einem Landschaftstyp, für den keine Verbuschungsberechnung vorliegt. Der Validierungsteil kann zudem die letzten drei Modellvarianten nicht unterscheiden, sodass die Modellauswahl zu einem Teil zufällig ausfällt (Abschnitt 4.1).

Schließlich beruhen die Schwellenwerte der Labelkorrektur auf den 16 annotierten Teilflächen und wären bei einer Erweiterung des Datensatzes neu zu bestimmen. In dicht bewaldeten Bereichen rekonstruiert Structure from Motion außerdem fast nur die Kronenoberfläche, sodass die Höhennormalisierung dort unsicher wird. Für die Offenlandbiotope dieser Arbeit ist das unkritisch, für eine flächendeckende Karte des gesamten Waldgebietes wäre es zu berücksichtigen.

4.5.6 Anwendbarkeit in der Praxis

Als Ausgangsproblem nennt die Einleitung, dass eine Geländekartierung zeit- und kostenintensiv ist und deshalb immer nur einen Bruchteil der Fläche abdeckt. Genau dieses Verhältnis kehrt das Verfahren um, denn es liefert Werte für 64,5 Hektar, von denen sich nur 9,9 überprüfen lassen, und macht den Verbuschungsgrad für jede beliebige Bezugsfläche berechenbar. Hinzu kommt die Wiederholbarkeit, denn eine erneute Befliegung liefert mit demselben Modell unmittelbar eine Veränderungsanalyse, was eine einmalige Geländekartierung nicht leistet, für die Erfolgskontrolle von Pflegemaßnahmen aber erforderlich wäre.

Ob Naturschutzpraktiker das Verfahren selbst anwenden können, war nicht mehr Gegenstand dieser Arbeit, die Voraussetzungen dafür lassen sich jedoch benennen. Sämtliche Ergebnisse liegen in gängigen, georeferenzierten Formaten vor, die klassifizierten Punktwolken als LAZ und die Karten als GeoTIFF in EPSG 25832. Da QGIS seit Version 3.18 Punktwolken nativ darstellt und sich dafür auf die Bibliothek PDAL stützt [34], lassen sich die Ergebnisse ohne Zusatzsoftware betrachten und weiterverwenden.

Offen bleibt allein die Inferenz innerhalb der GIS-Umgebung. Für zweidimensionale Netze steht dafür mit Deepness ein etabliertes QGIS-Plugin bereit, das Modelle im Format ONNX (Open Neural Network Exchange) ausführt [35]. Es arbeitet jedoch ausschließlich auf Rasterlayern und ist auf ein punktbasiertes Netz wie PointNet++ nicht anwendbar. Da ein Gegenstück für Punktwolken bislang fehlt, laufen Vorverarbeitung und Inferenz vorerst außerhalb von QGIS und nur die Ergebnisse werden dort eingebunden. Weil die Verarbeitungsschritte bereits skriptgesteuert und über Umgebungsvariablen parametrisiert sind, würde eine spätere Einbindung keine methodische Änderung erfordern, sondern lediglich eine Anbindung an die Verarbeitungsumgebung von QGIS.

Für die Praxis folgt daraus eine Aufgabenteilung. Stark verbuschte Flächen trennt das Verfahren zuverlässig von offenen, sodass sich damit eine Rangfolge für anstehende Pflegemaßnahmen aufstellen lässt. Schwach verbuschte Flächen, etwa solche zwischen einem und zehn Prozent, stuft es dagegen nicht zuverlässig ab. Die Geländekartierung ersetzt es dort nicht, wohl aber weist es ihr die Flächen zu, auf denen sie sich lohnt.

5 Fazit und Ausblick

Zum Abschluss werden die Forschungsfragen aus der Einleitung beantwortet und die Befunde in das Projekt eingeordnet, aus dem die Daten stammen. Daran schließen sich die Ansatzpunkte an, die sich aus den Grenzen des Verfahrens ergeben.

5.1 Fazit

Ziel dieser Arbeit war es, den Verbuschungsgrad von Heideflächen objektiv, flächendeckend und wiederholbar aus dreidimensionalen SfM-Punktwolken abzuleiten. Dafür wurde PointNet++ auf 16 annotierten Teilflächen trainiert, in neun Läufen einer Ablationsstudie angepasst und auf vier Befliegungen im Authausener Wald angewendet.

Auf die erste Forschungsfrage nach der Trennbarkeit der maßgeblichen Vegetationsklassen gibt es keine einheitliche Antwort. Gehölz und offene Vegetation trennt das Modell verlässlich, mit einer IoU von 0,761 und einem F1-Wert von 0,864. Innerhalb der niedrigen Vegetation gelingt die Trennung nicht. Von acht geprüften Eingriffen hat allein die Anpassung der Nachbarschaftsradien an die gemessene Punktdichte gewirkt.

Der automatisierte Label-Transfer der ersten Teilfrage gelingt und macht den Trainingsdatensatz erst praktikabel, erzeugt jedoch systematische Fehler an genau den Klassengrenzen, an denen das Modell scheitert.

Ähnlich zweigeteilt fällt die Antwort auf die zweite Forschungsfrage nach der Übereinstimmung mit der Geländekartierung aus. Auf den sieben Heidepolygonen ohne Pflegevermerk beträgt der mittlere Fehler 9,5 Prozentpunkte bei einem Bestimmtheitsmaß von 0,65. Auf der am stärksten verbuschten Fläche stehen 53,0 berechnete gegen 50,0 kartierte Prozent, obwohl das Modell dort nie trainiert hat. Die Reihenfolge der schwach verbuschten Flächen trifft das Verfahren dagegen nicht.

Für die zweite Teilfrage bleibt festzuhalten, dass sich die Ergebnisse unmittelbar in eine bestehende GIS-Umgebung übernehmen lassen, die Inferenz selbst aber vorerst außerhalb davon läuft.

Damit liegt der in der Einleitung angestrebte durchgängige Weg von der Befliegung bis zum Verbuschungsgrad vor. Für das Monitoring des Erhaltungszustands bietet er eine wiederholbare Grundlage, auf der sich Pflegemaßnahmen planen und ihr Erfolg später überprüfen lassen. Eine Geländekartierung ersetzt er noch nicht. Wo die verbleibenden Ansatzpunkte liegen, zeigt der folgende Abschnitt.

5.2 Ausblick und Einordnung

Noch unverarbeitet bleibt das Gebiet der Cuxhavener Küstenheide. Punktwolke und Biotopkartierung liegen vor, doch die Inferenz über 415 Millionen Punkte war im Rahmen dieser Arbeit zeitlich nicht mehr zu leisten. Sie nachzuholen wäre der gewinnbringendste nächste Schritt, denn die Fläche würde die Zahl der Referenzpolygone deutlich erhöhen und zugleich das Ungleichgewicht zwischen Bewertung und Anwendung auflösen.

Der Vergleich mit dem zweidimensionalen Ansatz, der im Projekt parallel entsteht, war ursprünglich Teil dieser Arbeit und musste entfallen, weil dessen Ergebnisse nicht rechtzeitig vorlagen. Nachgeholt werden sollte er auf denselben Kartierungspolygonen und mit denselben Kennzahlen, denn erst dann lässt sich beantworten, ob die dritte Dimension den erheblichen Mehraufwand rechtfertigt.

Methodisch am vielversprechendsten wäre eine objektbezogene statt punktweise Labelkorrektur. Dieses Verfahren würde zusammenhängende Strukturen erkennen und als Ganzes einer Klasse zuweisen, statt sie an einer festen Höhe zu durchschneiden. An ihm ließe sich zugleich die These prüfen, nach der ein Teil der Verwechslung zwischen Heide und Busch aus der Labelvergabe stammt. Daneben würden weitere annotierte Teilflächen den Validierungsteil so weit verbreitern, dass er Modellvarianten wieder unterscheiden kann.

Für den Weg in die Praxis fehlt schließlich ein Gegenstück zu Deepness, das auf Punktwolkenlayern arbeitet. Solange es das nicht gibt, bleibt als naheliegende Lösung, die vorhandenen Skripte als Werkzeug in die Verarbeitungsumgebung von QGIS einzuhängen und die Rechenlast auf einen Server auszulagern, sodass mit dem Ergebnis gearbeitet werden kann, ohne die Verarbeitungskette selbst zu betreiben.

Die Daten dieser Arbeit stammen aus dem in der Einleitung genannten Projekt, das die UAS-gestützte Fernerkundung in das Monitoring von FFH-Gebieten überführen will. Für dessen Fragestellung deckt der hier entwickelte Weg einen von mehreren Degradationsindikatoren ab. Die übrigen, etwa der Deckungsgrad von Gras oder von invasiven Neophyten, ließen sich aus derselben Segmentierung ableiten, sobald das Netz die niedrigen Vegetationsklassen zuverlässiger trennt.

Literaturverzeichnis

- [1] W. D. Kissling, Y. Shi, J. Wang, A. Walicka, C. George, J. E. Moeslund und F. Gerard, „Towards consistently measuring and monitoring habitat condition with airborne laser scanning and unmanned aerial vehicles“, *Ecological Indicators*, Jg. 169, S. 112970, 2024. DOI: 10.1016/j.ecolind.2024.112970
- [2] J. Gonçalves, R. Henriques, P. Alves, R. Sousa-Silva, A. T. Monteiro, Â. Lomba, B. Marcos und J. Honrado, „Evaluating an unmanned aerial vehicle-based approach for assessing habitat extent and condition in fine-scale early successional mountain mosaics“, *Applied Vegetation Science*, Jg. 19, Nr. 1, S. 132–146, 2016. DOI: 10.1111/avsc.12204
- [3] J. Schmidt, F. E. Fassnacht, C. Neff, A. Lausch, B. Kleinschmit, M. Förster und S. Schmidtlein, „Adapting a Natura 2000 field guideline for a remote sensing-based assessment of heathland conservation status“, *International Journal of Applied Earth Observation and Geoinformation*, Jg. 60, S. 61–71, 2017. DOI: 10.1016/j.jag.2017.04.005
- [4] I. Eischeid, E. M. Soininen, J. J. Assmann, R. A. Ims, J. Madsen, Å. Ø. Pedersen, F. Pirotti, N. G. Yoccoz und V. T. Ravolainen, „Disturbance Mapping in Arctic Tundra Improved by a Planning Workflow for Drone Studies: Advancing Tools for Future Ecosystem Monitoring“, *Remote Sensing*, Jg. 13, Nr. 21, S. 4466, 2021. DOI: 10.3390/rs13214466
- [5] J. Cao, W. Leng, K. Liu, L. Liu, Z. He und Y. Zhu, „Object-Based Mangrove Species Classification Using Unmanned Aerial Vehicle Hyperspectral Images and Digital Surface Models“, *Remote Sensing*, Jg. 10, Nr. 1, S. 89, 2018. DOI: 10.3390/rs10010089
- [6] T. Yun, J. Li, L. Ma, J. Zhou, R. Wang, M. P. Eichhorn und H. Zhang, „Status, advancements and prospects of deep learning methods applied in forest studies“, *International Journal of Applied Earth Observation and Geoinformation*, Jg. 131, S. 103938, 2024. DOI: 10.1016/j.jag.2024.103938
- [8] N. R. Webb, „The traditional management of European heathlands“, *Journal of Applied Ecology*, Jg. 35, Nr. 6, S. 987–990, 1998. DOI: 10.1111/j.1365-2664.1998.tb00020.x
- [9] T. Schoknecht, *Trockenrasen und Heiden: Hinweise zur Biotop- und Landschaftspflege*, Deutscher Verband für Landschaftspflege (DVL) und Landesumweltamt Brandenburg, Potsdam, 1998.
- [10] R. Bobbink, K. Hicks, J. Galloway, T. Spranger, R. Alkemade, M. Ashmore, M. Bustamante, S. Cinderby, E. Davidson, F. Dentener, B. Emmett, J.-W. Erisman, M. Fenn, F. Gilliam, A. Nordin, L. Pardo und W. de Vries, „Global assessment of nitrogen deposition effects on terrestrial plant diversity: a synthesis“, *Ecological Applications*, Jg. 20, Nr. 1, S. 30–59, 2010. DOI: 10.1890/08-1140.1

-
- [11] U. Friedrich, G. von Oheimb, C. Dziedek, W.-U. Kriebitzsch, K. Selbmann und W. Härdtle, „Mechanisms of purple moor-grass (*Molinia caerulea*) encroachment in dry heathland ecosystems with chronic nitrogen inputs“, *Environmental Pollution*, Jg. 159, Nr. 12, S. 3553–3559, 2011. DOI: 10.1016/j.envpol.2011.08.010
 - [12] W. Härdtle, G. von Oheimb, A.-K. Gerke, M. Niemeyer, T. Niemeyer, T. Assmann, C. Drees, A. Matern und H. Meyer, „Shifts in N and P budgets of heathland ecosystems: effects of management and atmospheric inputs“, *Ecosystems*, Jg. 12, Nr. 2, S. 298–310, 2009. DOI: 10.1007/s10021-008-9223-3
 - [13] M. J. Westoby, J. Brasington, N. F. Glasser, M. J. Hambrey und J. M. Reynolds, „'Structure-from-Motion' photogrammetry: A low-cost, effective tool for geoscience applications“, *Geomorphology*, Jg. 179, S. 300–314, 2012. DOI: 10.1016/j.geomorph.2012.08.021
 - [14] J. L. Schönberger und J.-M. Frahm, „Structure-from-Motion Revisited“, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, S. 4104–4113. DOI: 10.1109/CVPR.2016.445
 - [15] J. L. Schönberger, E. Zheng, M. Pollefeys und J.-M. Frahm, „Pixelwise View Selection for Unstructured Multi-View Stereo“, in *Computer Vision – ECCV 2016*, Ser. Lecture Notes in Computer Science, Bd. 9907, Springer, 2016, S. 501–518. DOI: 10.1007/978-3-319-46487-9_31
 - [16] Y. LeCun, Y. Bengio und G. Hinton, „Deep learning“, *Nature*, Jg. 521, Nr. 7553, S. 436–444, 2015. DOI: 10.1038/nature14539
 - [17] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam und P. Vandergheynst, „Geometric deep learning: going beyond Euclidean data“, *IEEE Signal Processing Magazine*, Jg. 34, Nr. 4, S. 18–42, 2017. DOI: 10.1109/MSP.2017.2693418
 - [18] C. R. Qi, H. Su, K. Mo und L. J. Guibas, „PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation“, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, S. 652–660. DOI: 10.1109/CVPR.2017.16
 - [19] A. Diab, R. Kashef und A. Shaker, „Deep Learning for LiDAR Point Cloud Classification in Remote Sensing“, *Sensors*, Jg. 22, Nr. 20, S. 7868, 2022. DOI: 10.3390/s22207868
 - [20] C. R. Qi, L. Yi, H. Su und L. J. Guibas, „PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space“, in *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 2017, S. 5099–5108.
 - [22] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz, *Statistik: Der Weg zur Datenanalyse*, 9. Aufl. Berlin, Heidelberg: Springer Spektrum, 2023, ISBN: 978-3-662-67525-0. DOI: 10.1007/978-3-662-67526-7
 - [26] R. Achanta und S. Süsstrunk, „Superpixels and Polygons Using Simple Non-Iterative Clustering“, in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, USA, 2017, S. 4651–4660. Adresse: https://openaccess.thecvf.com/content_cvpr_2017/papers/Achanta_Superpixels_and_Polygons_CVPR_2017_paper.pdf

- [27] J.-R. Roussel, D. Auty, N. C. Coops, P. Tompalski, T. R. H. Goodbody, A. Sánchez Meador, J.-F. Bourdon, F. de Boissieu und A. Achim, „lidR: An R package for analysis of Airborne Laser Scanning (ALS) data“, *Remote Sensing of Environment*, Jg. 251, S. 112 061, 2020. DOI: 10.1016/j.rse.2020.112061
- [28] E. Pebesma, „Simple Features for R: Standardized Support for Spatial Vector Data“, *The R Journal*, Jg. 10, Nr. 1, S. 439–446, 2018. DOI: 10.32614/RJ-2018-009
- [29] R. J. Hijmans, *terra: Spatial Data Analysis*, R package version 1.8-86, 2025. DOI: 10.32614/CRAN.package.terra Adresse: <https://CRAN.R-project.org/package=terra>
- [30] W. Zhang, J. Qi, P. Wan, H. Wang, D. Xie, X. Wang und G. Yan, „An Easy-to-Use Airborne LiDAR Data Filtering Method Based on Cloth Simulation“, *Remote Sensing*, Jg. 8, Nr. 6, S. 501, 2016. DOI: 10.3390/rs8060501
- [31] D. P. Kingma und J. L. Ba, „Adam: A Method for Stochastic Optimization“, in *3rd International Conference on Learning Representations (ICLR)*, San Diego, CA, USA, 2015. arXiv: 1412.6980.
- [32] DBU Naturerbe GmbH, *Biotoptypenkartierung DBU-Naturerbefläche Authausener Wald*, Unveröffentlichte Kartierdaten, zur Verfügung gestellt von der DBU Naturerbe GmbH, 2014.
- [35] P. Aszkowski, B. Ptak, M. Kraft, D. Pieczyński und P. Drapikowski, „Deepness: Deep neural remote sensing plugin for QGIS“, *SoftwareX*, Jg. 23, S. 101 495, 2023, ISSN: 2352-7110. DOI: 10.1016/j.softx.2023.101495

Internetquellen


- [7] Rat der Europäischen Gemeinschaften. „Richtlinie 92/43/EWG des Rates vom 21. Mai 1992 zur Erhaltung der natürlichen Lebensräume sowie der wildlebenden Tiere und Pflanzen“, besucht am 2026-07-01. Adresse: <https://eur-lex.europa.eu/legal-content/DE/TXT/?uri=CELEX:31992L0043>
- [21] X. Yan. „Pointnet/Pointnet++ Pytorch“, besucht am 2026-08-04. Adresse: https://github.com/yanx27/Pointnet_Pointnet2_pytorch
- [23] DBU Naturerbe GmbH. „DBU-Naturerbefläche Authausener Wald“, besucht am 2026-08-07. Adresse: <https://www.dbu.de/naturerbeflaechen/authausener-wald/>
- [24] DBU Naturerbe GmbH. „DBU-Naturerbefläche Cuxhavener Küstenheiden“, besucht am 2026-08-07. Adresse: <https://www.dbu.de/naturerbeflaechen/cuxhavener-kuestenheiden/>
- [25] SZ DJI Technology Co., Ltd. „DJI Mavic 3M: Specifications“, besucht am 2026-08-07. Adresse: <https://ag.dji.com/mavic-3-m/specs>
- [33] L. Waldeyer. „Verbuschungsgrad von Heideflächen aus SfM-Punktwolken“. Commit 79ad35a, besucht am 2026-09-15. Adresse: https://github.com/luis-waldi/BA_2026
- [34] QGIS Development Team. „Changelog for QGIS 3.18“, besucht am 2026-09-07. Adresse: <https://qgis.org/en/site/forusers/visualchangelog318/index.html>

Eigenständigkeitserklärung

Hiermit versichere ich, dass die vorliegende Arbeit mit dem Titel Quantifizierung von Verbuschung in Natura-2000-Heideflächen: Ein Vergleich von 2D- und 3D-Deep-Learning-Verfahren zur drohnengestützten Habitatbewertung selbstständig von mir und ohne fremde Hilfe verfasst worden ist, dass keine anderen Quellen und Hilfsmittel, als die angegebenen benutzt worden sind und dass die Stellen der Arbeit, die anderen Werken – auch elektronischen Medien und KI-Tools – dem Wortlaut oder Sinn nach entnommen wurden, auf jeden Fall unter Angabe der Quelle als Entlehnung kenntlich gemacht worden sind. Mir ist bekannt, dass es sich bei einem Plagiat um eine Täuschung handelt, die gemäß der Prüfungsordnung sanktioniert werden kann. Ich erkläre hiermit, dass ich Kenntnis von einer zum Zweck der Plagiatskontrolle vorzunehmenden Speicherung der Arbeit in einer Datenbank sowie von ihrem Abgleich mit anderen Texten zwecks Auffindung von Übereinstimmungen habe. Ich versichere, dass ich die vorliegende Arbeit oder Teile daraus nicht anderweitig als Prüfungsarbeit eingereicht habe.

Münster, 15.9.2026

(Ort, Datum)



(Eigenhändige Unterschrift)