



Universität Münster
Hochschulzentrum Münster

Bachelor Thesis

im Studiengang Geoonformatik

zur Erlangung des Grades eines
Bachelor of Science (B.Sc.)

über das Thema

LATEX-Vorlage - mit Biblatex

von

Luis Waldeyer

Betreuer : Dr. Torsten Prinz
Matrikelnummer : 545669
Abgabedatum : 8. Juli 2026

Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VI
Symbolverzeichnis	VII
1 Einleitung und Motivation	1
1.1 Aufbau der Arbeit	3
2 Theoretischer Hintergrund	5
2.1 Ökologischer Hintergrund	5
2.2 Structure from Motion	6
2.2.1 Allgemeines	6
2.3 Convolutional Neural Networks (CNNs)	6
2.3.1 Allgemeines	7
2.4 Geometric Deep Learning	7
2.4.1 Semantische Segmentierung von 3D-Punktwolken	7
2.4.2 Beispiel: Pointnet	7
2.4.3 Beispiel: Pointnet++	7
3 Verwandte Arbeiten	8
4 Methodik	9
4.1 Untersuchungsgebiet	9
4.2 Datengrundlage	9
4.3 Annotation und Klassenschema	9
4.4 Datenvorverarbeitung	9
4.4.1 Label-Transfer und Qualitätssicherung	9
4.4.2 Tiling und Sampling	9
4.5 Modell und Training	9
4.5.1 PointNet++	9
4.5.2 Training	9
4.6 Quantifizierung des Verbuschungsgrades	9
4.6.1 Rasterisierung	9

5	Fazit und Diskussion	10
5.1	Evaluation der semantischen Segmentierung	10
5.1.1	Gesamtmetriken	10
5.1.2	Klassenweise Auswertung	10
5.1.3	Konfusionsmatrix	10
5.2	Fehleranalyse	10
5.2.1	Einfluss des Klassenungleichgewichts	10
5.2.2	Kritische Verwechslungen	10
5.3	Quantifizierung des Verbuschungsgrades	10
5.4	Vergleich mit dem 2D-Ansatz	10
5.5	Diskussion	10
5.6	Fazit	10
6	Ausblick und Einordnung in den Gesamtkontext	11
	Anhang	12
	Literaturverzeichnis	13

Abbildungsverzeichnis

Tabellenverzeichnis

Abkürzungsverzeichnis

Symbolverzeichnis

1 Einleitung und Motivation

Der Schutz und Erhalt naturnaher Lebensräume ist eine zentrale Aufgabe des europäischen Naturschutzes. Allein das Natura-2000-Netzwerk umfasst rund 25.000 Schutzgebiete in den EU-Mitgliedsstaaten, deren Zustand regelmäßig erfasst und überwacht werden muss [1]. Indikatoren des Habitatzustands sind dabei unverzichtbar, um Fortschritte im Naturschutz nachzuvollziehen. Ihre Erhebung über große Flächen und in feiner Auflösung bleibt jedoch eine Herausforderung [1].

Klassischerweise erfolgt diese Vegetationskartierung durch Geländearbeit: Fachleute begehen die Flächen und erheben Daten manuell vor Ort. Da dieses Vorgehen sehr zeit- und kostenintensiv ist, können auf diese Weise meist nur kleine Flächen kartiert werden. An dieser Stelle setzen Methoden der Fernerkundung an. Insbesondere das Drohnen bzw. UAS-gestützte Monitoring liefert hochauflösende Daten und kann den Aufwand intensiver Geländekartierungen deutlich reduzieren, wobei Genauigkeiten erreicht werden, die klassische Verfahren der Luftbildinterpretation erreichen oder übertreffen [2].

Gerade für die Heideflächen wurde gezeigt, dass sich der Erhaltungszustand fernerkundlich bewerten lässt, sofern die Auswertung eng an die etablierten feldbasierten Kartierschemata angelehnt sind [3]. Allerdings besteht weiterhin eine deutliche Lücke zwischen den feldbasierten Monitoring-Richtlinien und den bestehenden fernerkundlichen Ansätzen, was deren praktische Anwendung erschwert [3]. Der entscheidende Haken klassischer Fernerkundung liegt zudem darin, dass die erhobenen Daten wiederum manuell von Fachleuten ausgewertet werden müssen, was erneut sehr zeitaufwendig ist. Genau hier wird der Einsatz künstlicher Intelligenz interessant, da sie die Auswertung der Fernerkundungsdaten automatisieren kann.

Die Anwendung von Machine-Learning-Verfahren in der Fernerkundung ist seit Jahren etabliert. Klassische Algorithmen wie Random Forest (RF) werden vor allem zur Klassifizierung der Bodenbedeckung eingesetzt. Eischeid et al. (2021) [4] nutzten beispielsweise einen überwachten RF-Klassifikator, um aus Drohnenbildern die Vegetation arktischer Tundra zu kartieren. Auch Support Vector Machines (SVMs) finden Anwendung, etwa bei Cao et al. (2018) [5] zur objektbasierten Klassifizierung von Mangrovenarten aus hochauflösenden UAV-Hyperspektraldaten.

Einen entscheidenden Fortschritt brachte die Einführung von Deep Learning und insbesondere von Convolutional Neural Networks (CNNs), die die Objekterkennung und damit das Habitatmonitoring deutlich verbessert haben [6].

Der wesentliche Vorteil gegenüber klassischen Verfahren liegt darin, dass CNNs die entscheidenden Merkmale automatisch aus komplexen, hochdimensionalen Rohdaten lernen, während klassische Algorithmen auf eine manuelle Merkmalsextraktion angewiesen sind und bei unregelmäßigen oder komplexen Datenmengen schnell an ihre Grenzen stoßen. Eine ausführliche Gegenüberstellung der Ansätze sowie verschiedene CNN-Architekturen erfolgt in Kapitel 2 (Theoretischer Hintergrund).

Aus den genannten Gründen ist es nicht verwunderlich, dass aktuelle Projekte im Bereich des Habitat-Qualitätsmonitorings auf Deep Learning zurückgreifen. So auch das Projekt des Instituts für Landschaftsökologie der Universität Münster: "Ready for Take-Off?! How to integrate UAS remote sensing into the monitoring of EU habitats directive sites?". Dort wird untersucht, wie sich UAS-basierte Fernerkundung in das Monitoring von FFH-Gebieten integrieren lässt, gerade weil UAS deutlich hochauflösendere Daten liefern als Satellitenbilder und flexibler einsetzbar sind. Die zugrunde liegende Flora-Fauna-Habitat-Richtlinie bildet innerhalb des Natura-2000-Netzwerks das Rückgrat des europäischen Naturschutzes [7] und definiert damit die Schutzgebiete, deren Erhaltungszustand im Projekt erfasst werden soll.

Neben der Habitatstruktur (etwas Erica-Lebenszyklusphasen oder Sandanteil) und dem Arteninventar sollen dabei vor allem Degradationsindikatoren wie der Deckungsgrad invasiver Neophyten, von Gras, Gehölzen und die Verbuschung ermittelt werden, da diese sich kritisch auf den Erhaltungszustand von Heideflächen auswirken. Heideflächen sind nährstoffarme Halbkulturbiotope, die erst durch menschliche Nutzung entstanden sind. Bleibt diese Nutzung aus oder werden die Standorte durch Eutrophierung mit Nährstoffen angereichert, setzt natürliche Sukzession ein, bei der Gräser und Gehölze aufkommen und die Zwergstrauchheide durch Nährstoffentzug und die Beschattung zunehmend überwuchern [8]. Die Verbuschung ist daher ein zentraler Degradationsindikator für den Erhaltungszustand von Heideflächen. Da die früheren Nutzungsformen weggefallen sind, lassen sich diese Flächen heute nur durch aufwändige Pflegemaßnahmen offenhalten. Um solche Maßnahmen gezielt planen und ihren Erfolg überprüfen zu können, muss der Verbuschungsgrad objektiv, flächendeckend und reproduzierbar erfasst werden.

Dazu wurden mehrere Flächen mehrfach mit einer Drohne befliegen, um hochauflösende RGB-Bilder zu erhalten und aus den überlappenden 2D-Aufnahmen mittels Structure from Motion einen 3D-Datensatz abzuleiten - ein Verfahren, das aus mehreren überlappenden 2D-Bildern eine dreidimensionale Punktwolke der aufgenommenen Fläche rekonstruiert. Diese Daten dienen als Ausgangspunkt für ein Deep-Learning-Modell, das die einzelnen Vegetationsarten segmentiert und jeweils einer Klasse zuordnet, woraus sich anschließend ein Verbuschungsgrad berechnen lässt.

Da nun zwei Arten von Datensätzen vorliegen, ergibt sich daraus eine zentrale Frage. Welcher Datensatz eignet sich besser zur Segmentierung der Vegetationsarten und damit zur Berechnung des Verbuschungsgrades - die RGB-Bilder oder die SfM-Punktwolken? Beide Ansätze nutzen Deep Learning, für die 2D-Daten das CNN U-Net und für den 3D-Ansatz PointNet++, das eigens auf unstrukturierten 3D-Punktmengen spezialisiert ist. Aufgabe dieser Arbeit ist es, den 3D-Ansatz zu entwickeln, zu testen und zu evaluieren und sein Ergebnis mit dem 2D-Ansatz zu vergleichen, um herauszufinden, welcher Datensatz sich besser für die Segmentierung der Vegetationsarten und damit für die Erfassung des Verbuschungsgrades eignet.

Daraus ergeben sich zwei Forschungsfragen (FF) mit jeweils einer untergeordneten Teilfrage (TF), die den Weg von der Datenaufbereitung über die Segmentierung bis zur praktischen Nutzung abbilden:

FF1: Inwiefern unterscheidet sich die semantische Segmentierung von 3D-SfM-Punktwolken mittels Deep Learning von einem vergleichbaren 2D-Deep-Learning-Ansatz, sowohl quantitativ als auch qualitativ, bei der Erfassung der Verbuschung von Heideflächen?

TF1: Inwiefern lässt sich ein automatisierter Label-Transfer von 2D-Referenzdaten auf 3D-Punktwolken realisieren, um den Trainingsaufwand für tiefe neuronale Netze effizient zu gestalten?

FF2: Inwiefern unterscheidet sich die aus der 3D-Punktwolken-Segmentierung abgeleitete Rasterisierung des Verbuschungsgrades in ihrer Genauigkeit von der aus dem 2D-RGB-Ansatz abgeleiteten Rasterisierung?

TF2: Wie stabil und anwenderfreundlich lässt sich das entwickelte Modell in eine bestehende GIS-Umgebung integrieren, um für Naturschutzpraktiker nutzbar zu sein?

Das übergeordnete Ziel ist schließlich ein vollständiger Workflow, der es Naturschutzpraktikern ermöglicht, den Verbuschungsgrad von Heideflächen effizient und zuverlässig zu erfassen.

1.1 Aufbau der Arbeit

Kapitel 2 (Theoretischer Hintergrund) legt die theoretischen Grundlagen. In Kapitel 3 (Verwandte Arbeiten) werden verwandte Arbeiten vorgestellt. Kapitel 4 (Methodik) beschreibt

das methodische Vorgehen, bevor in Kapitel 5.5 (Diskussion) die Ergebnisse evaluiert werden. Kapitel 6 (Ausblick und Einordnung in den Gesamtkontext) schließt die Arbeit mit einem Ausblick ab.

2 Theoretischer Hintergrund

2.1 Ökologischer Hintergrund

konkret nehmen die Gräser oder Büsche der Heide Platz zum wachsen weg, indem sie sie einfach zuwachsen (eigentlich wachsen Heiden in Standorten mit folgenden abiotische Standorteigenschaften: wie Niederschlagsarmut, große Versickerungsfähigkeit der Böden, starkes Relief oder Südexposition.), jedoch sind ihre heutigen Standorte ausreichend mit Wasser versorgt und vor allem von der Eutrophierung (Nährstoffanreicherung) betroffen (bspw. wenn die Dünger von benachbarten Landwirtschaftlich genutzten Flächen über die Luft verstreut werden), dass das nach und nach, bei ausbleibender Pflege die Pioniergehölze wachsen lässt (Schlehen, Rosen- und Weißdornarten sowie Bäume wie Birken, Zitterpappeln und Kiefern) (https://www.dvl.org/fileadmin/user_upload/Publikationen/Praxishefte_Biotoppflege/DVL-Publikation-Praxisheft_Hinweise_zur_Biotop-_und_Landschaftspflege-Trockenrasen_und_Heiden.pdf) - durch diese natürliche Sukzession breiten sich Dominanzbestände aus, welche so aggressiv wachsen, dass sie die Heide einfach überwuchern (durch entzug von Nährstoffen und beschatten -> kein Sonnenlicht) - aber wie kann man das verhindern, bzw. wie wurde es ursprünglich verhindert? -Heiden und Trockenrasen gebiete sind eigentlich von Menschen geschaffene Halbkulturbiotope mit Nährstoffarmen Böden, die indirekt durch die frühere Bewirtschaftung entstanden sind - beispielsweise wurde durch das "abplaggen" die nährstoffreiche Humusschicht mitsamt der Heidevegetation vom Oberboden entfernt -> Plaggen wurden als Einstreu in Ställen genutzt und später als Dünger auf dem Feld eingesetzt - Methode wurde mit der Einführung von Dünger und dem genug zur Verfügung stehendem Stroh, überflüssig -auch verhinderte die stark verbreitete Schafzucht das wachsen von Bäumen und Sträuchern in diesen Gebieten -> Schafe fressen die jungen Triebe -Schafhaltung ging zurück als Baumwolle und billige Wollimporte aus Übersee populär wurden -neben dem abplaggen wurde auch die "Mahd" eingesetzt -> oberen Schichten wurden mit einer Sense oder Sichel abgemäht und so der Bestand verjüngt (ähnlich wie zurückschneiden von Bäumen, nur dass dadurch auch die jungen, störenden Baumtriebe und Sträucher entfernt wurden) -da diese Methoden jedoch weggefallen sind musste sich der Naturschutz andere Methoden überlegen -maschineller Plaggenhieb mit Planiermaschinen - da das aggressive Sandrohr sich sonst wieder ausbreiten würde, müssen die abgetragenen Bodenschichten komplett aus dem Gebiet entfernt werden - gezielter Einsatz von Schafen oder Heidschnucken - wichtig hierbei: das nächtliche Aufstallern, also das in den Stall bringen oder auf Äckern zusammenpferchen, damit der Dung nicht wieder ins Heidegebiet kommt und gleichzeitig direkt auf dem Acker landet

(heidefläche braucht Nährstoffarmen Boden) -auch die Mahd wird noch gemacht - das abschneiden der Gräser und Büsche ist einer der gängigsten Methoden - wichtig ist der unbedingte Abtransport des Mähguts (sonst Ausbreitung von aggressiven Pflanzenarten wie bei der Abplaggung) -das Entkusseln ist quasi wie die Mahd eine Ebene drüber - das rein mechanische Absägen und Zurückschneiden, mithilfe von Kettensägen, von Gehölzen wie Kiefer oder Birke -auch kontrolliertes Abbrennen von kleinen Flächen wird angewendet - Nährstoffe werden dem Rohhumus entzogen, wodurch sich kein Buschland entwickeln kann und somit offene, konkurrenzarme Standorte für das Heidekraut entstehen Quellen: (<https://www.bund-koeln.de/service/meldungen/detail/news/wiesenpflege-fuer-mehr-artenvielfalt-wieso-das-land-reitgras-in-der-dellbruecker-heide-probleme-macht>) (<https://www.nul-online.de/themen/landschaftspflege/article-8259515-201985/landschaftspflege-in-der-heide-.html>)

2.2 Structure from Motion

2.2.1 Allgemeines

2.3 Convolutional Neural Networks (CNNs)

dabei unterteilt er diese Methoden in vier Hauptkategorien, wobei die erste und zweite Kategorie eher großflächige, ökologische Zusammenhänge aus Satelliten- und Luftbildern analysieren, dringen die dritte und vierte in die Detailebene, nutzen mehr auch LIDAR Daten und stellen die anatomischen Details einzelner Bäume dar - in der 1. KAT. wird eine "forest resource assessment"(FRA) durchgeführt, wobei das CNN U-Net mittels semantischer Segmentierung zur Kartierung von Waldtypen am Beispiel des atlantischen Regenwaldes, eingesetzt wurde - als 2. KAT wurde die "forest ecological disturbance"(FED) überwacht um mithilfe von YOLO-Modellen Waldbrandrauch frühzeitig zu erkennen und mithilfe von Mask R-CNN, kranke von einem Pilz befallene Bäume zu identifizieren - die "forest parameter retrieval at the individual scale"(FPI) wurde angewendet und mittels Deeplab aus Drohnenbildern einzelne Baumkronen zu identifizieren - außerdem kann man mit dieser Methode, über das CNN ResNet auch einzelne Baumarten genau identifizieren - die vierte Hauptkategorie in der man Deep-Learning Anwendungen in Bezug auf Waldmonitoring unterteilt, ist die "tree organ-level measurement"(TOM) - diese wird meist als Vorverarbeitungsschritt eingesetzt um dann noch detaillierter zu untersuchen, da diese Methode beispielsweise mithilfe von LIDAR Daten die Holzstruktur und die Blätter eines Baumes trennen kann, was dann wiederum die Grundlage für die Bestimmung von

Baumarten ist - auch wird TOM vor allem im landwirtschaftlichen Bereich genutzt um Früchte zu lokalisieren und somit den Ernteertrag abzuschätzen

-man sieht klar wie viel mehr flexibel deep learning algorithmen im verleich zu klassischen machine learning algorithmen sind - wohingegen diese noch stark auf die manuelle Merkmalsextraktion angewiesen sind und bei unregelmäßigen oder komplexen Datenmengen (insebesondere bei Baumstrukturen) schnell an ihre Grenzen stoßen - im Vergleich dazu kann deep learning automatisch aus hochdimensionalen, nichtlinearen Rohdaten wichtige und entscheidene Merkmale extrahieren, lernen damit umzugehen und dann auch zu modellieren - diese Flexibilität von deep learning zeigt sich insbesondere dadurch, dass die 4 verschiedenen Methoden die CNNs ganz flexibel nutzen und exakt an das Problem anpassen können - die Pixel- und patch basierten CNNs wie U-Net oder ResNet kartieren fließende Übergänge von Waldtypen, wohingegen Objektbasierte CNNs wie YOLO oder Faster R-CNN, gezielt einzelne Organe wie Früchte, kranke Blätter oder Äste in komplexen Umgebungen lokalisieren

2.3.1 Allgemeines

2.4 Geometric Deep Learning

2.4.1 Semantische Segmentierung von 3D-Punktwolken

2.4.2 Beispiel: Pointnet

2.4.3 Beispiel: Pointnet++

3 Verwandte Arbeiten

4 Methodik

4.1 Untersuchungsgebiet

4.2 Datengrundlage

4.3 Annotation und Klassenschema

4.4 Datenvorverarbeitung

4.4.1 Label-Transfer und Qualitätssicherung

4.4.2 Tiling und Sampling

4.5 Modell und Training

4.5.1 PointNet++

4.5.2 Training

4.6 Quantifizierung des Verbuschungsgrades

4.6.1 Rasterisierung

5 Fazit und Diskussion

5.1 Evaluation der semantischen Segmentierung

5.1.1 Gesamtmetriken

5.1.2 Klassenweise Auswertung

5.1.3 Konfusionsmatrix

5.2 Fehleranalyse

5.2.1 Einfluss des Klassenungleichgewichts

5.2.2 Kritische Verwechslungen

5.3 Quantifizierung des Verbuschungsgrades

5.4 Vergleich mit dem 2D-Ansatz

5.5 Diskussion

5.6 Fazit

6 Ausblick und Einordnung in den Gesamtkontext

Anhang

Anhang 1: Beispielanhang

Dieser Abschnitt dient nur dazu zu demonstrieren, wie ein Anhang aufgebaut sein kann.

Anhang 1.1: Weitere Gliederungsebene

Auch eine zweite Gliederungsebene ist möglich.

Anhang 2: Bilder

Auch mit Bildern. Diese tauchen nicht im Abbildungsverzeichnis auf.

Abbildung 1: Beispielbild

Name	Änderungsdatum	Typ	Größe
 abbildungen	29.08.2013 01:25	Dateiordner	
 kapitel	29.08.2013 00:55	Dateiordner	
 literatur	31.08.2013 18:17	Dateiordner	
 skripte	01.09.2013 00:10	Dateiordner	
 compile.bat	31.08.2013 20:11	Windows-Batchda...	1 KB
 thesis_main.tex	01.09.2013 00:25	LaTeX Document	5 KB

Literaturverzeichnis

- [1] W. D. Kissling, Y. Shi, J. Wang, A. Walicka, C. George, J. E. Moeslund und F. Gerard, „Towards consistently measuring and monitoring habitat condition with airborne laser scanning and unmanned aerial vehicles,“ *Ecological Indicators*, Jg. 169, S. 112970, 2024. DOI: 10.1016/j.ecolind.2024.112970
- [2] J. Gonçalves, R. Henriques, P. Alves, R. Sousa-Silva, A. T. Monteiro, Â. Lomba, B. Marcos und J. Honrado, „Evaluating an unmanned aerial vehicle-based approach for assessing habitat extent and condition in fine-scale early successional mountain mosaics,“ *Applied Vegetation Science*, Jg. 19, Nr. 1, S. 132–146, 2016. DOI: 10.1111/avsc.12204
- [3] J. Schmidt, F. E. Fassnacht, C. Neff, A. Lausch, B. Kleinschmit, M. Förster und S. Schmittlein, „Adapting a Natura 2000 field guideline for a remote sensing-based assessment of heathland conservation status,“ *International Journal of Applied Earth Observation and Geoinformation*, Jg. 60, S. 61–71, 2017. DOI: 10.1016/j.jag.2017.04.005
- [4] I. Eischeid, E. M. Soininen, J. J. Assmann, R. A. Ims, J. Madsen, Å. Ø. Pedersen, F. Pirotti, N. G. Yoccoz und V. T. Ravolainen, „Disturbance Mapping in Arctic Tundra Improved by a Planning Workflow for Drone Studies: Advancing Tools for Future Ecosystem Monitoring,“ *Remote Sensing*, Jg. 13, Nr. 21, S. 4466, 2021. DOI: 10.3390/rs13214466
- [5] J. Cao, W. Leng, K. Liu, L. Liu, Z. He und Y. Zhu, „Object-Based Mangrove Species Classification Using Unmanned Aerial Vehicle Hyperspectral Images and Digital Surface Models,“ *Remote Sensing*, Jg. 10, Nr. 1, S. 89, 2018. DOI: 10.3390/rs10010089
- [6] T. Yun, J. Li, L. Ma, J. Zhou, R. Wang, M. P. Eichhorn und H. Zhang, „Status, advancements and prospects of deep learning methods applied in forest studies,“ *International Journal of Applied Earth Observation and Geoinformation*, Jg. 131, S. 103938, 2024. DOI: 10.1016/j.jag.2024.103938
- [8] T. Schoknecht, *Trockenrasen und Heiden: Hinweise zur Biotop- und Landschaftspflege*, Deutscher Verband für Landschaftspflege (DVL) und Landesumweltamt Brandenburg, Potsdam, 1998.

Internetquellen

- [7] Rat der Europäischen Gemeinschaften. „Richtlinie 92/43/EWG des Rates vom 21. Mai 1992 zur Erhaltung der natürlichen Lebensräume sowie der wildlebenden Tiere und Pflanzen,“ besucht am 2026-07-01. Adresse: <https://eur-lex.europa.eu/legal-content/DE/TXT/?uri=CELEX:31992L0043>

Eigenständigkeitserklärung

Hiermit versichere ich, dass ich die angemeldete Prüfungsleistung in allen Teilen eigenständig ohne Hilfe von Dritten anfertigen und keine anderen als die in der Prüfungsleistung angegebenen Quellen und zugelassenen Hilfsmittel verwenden werde. Sämtliche wörtlichen und sinngemäßen Übernahmen inklusive KI-generierter Inhalte werde ich kenntlich machen.

Diese Prüfungsleistung hat zum Zeitpunkt der Abgabe weder in gleicher noch in ähnlicher Form, auch nicht auszugsweise, bereits einer Prüfungsbehörde zur Prüfung vorgelegen; hiervon ausgenommen sind Prüfungsleistungen, für die in der Modulbeschreibung ausdrücklich andere Regelungen festgelegt sind.

Mir ist bekannt, dass die Zuwiderhandlung gegen den Inhalt dieser Erklärung einen Täuschungsversuch darstellt, der das Nichtbestehen der Prüfung zur Folge hat und daneben strafrechtlich gem. § 156 StGB verfolgt werden kann. Darüber hinaus ist mir bekannt, dass ich bei schwerwiegender Täuschung exmatrikuliert und mit einer Geldbuße bis zu 50.000 EUR nach der für mich gültigen Rahmenprüfungsordnung belegt werden kann.

Ich erkläre mich damit einverstanden, dass diese Prüfungsleistung zwecks Plagiatsprüfung auf die Server externer Anbieter hochgeladen werden darf. Die Plagiatsprüfung stellt keine Zurverfügungstellung für die Öffentlichkeit dar.

Münster, 8.7.2026

(Ort, Datum)

A handwritten signature in black ink, consisting of a large, stylized 'H' followed by a series of loops and a final flourish.

(Eigenhändige Unterschrift)