



Universität Münster
Hochschulzentrum Münster

Bachelor Thesis

im Studiengang Geoonformatik

zur Erlangung des Grades eines
Bachelor of Science (B.Sc.)

über das Thema

LATEX-Vorlage - mit Biblatex

von

Luis Waldeyer

Betreuer : Dr. Torsten Prinz
Matrikelnummer : 545669
Abgabedatum : 6. August 2026

Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VI
Symbolverzeichnis	VII
1 Einleitung und Motivation	1
1.1 Aufbau der Arbeit	3
2 Theoretischer Hintergrund	5
2.1 Ökologischer Hintergrund	5
2.2 Structure from Motion	7
2.2.1 Allgemeines	7
2.2.2 Ablauf der Rekonstruktion	8
2.3 Convolutional Neural Networks (CNNs)	10
2.3.1 Allgemeines	10
2.3.2 Anwendung in der Fernerkundung	12
2.4 Geometric Deep Learning	13
2.4.1 Semantische Segmentierung von 3D-Punktwolken	14
2.4.2 Beispiel: PointNet	14
2.4.3 Beispiel: PointNet++	15
2.5 Evaluationsmetriken	16
2.5.1 Metriken der Segmentierung	16
2.5.2 Metriken des Verbuschungsgrades	18
3 Verwandte Arbeiten	20
4 Methodik	21
4.1 Untersuchungsgebiete und Datengrundlage	21
4.1.1 Untersuchungsgebiete	21
4.1.2 Befliegung und photogrammetrische Auswertung	21
4.1.3 Manuelle Annotation und Klassenschema	21
4.2 Datenvorverarbeitung	21
4.2.1 Aufbereitung und Prüfung der Ausgangsdaten	21
4.2.2 Bodenerkennung und Höhennormalisierung	22

4.2.3	Übertragung der Labels auf die Punktwolke	23
4.2.4	Höhenbasierte Labelkorrektur	24
4.2.5	Klassenkodierung	26
4.2.6	Lokale Höhenmerkmale	26
4.2.7	Kachelung	27
4.2.8	Räumlich getrennte Datenaufteilung	28
4.3	Datenorganisation und Versionsverwaltung	29
4.4	Modell und Trainingssetup	31
4.4.1	Architektur	31
4.4.2	Verlustfunktion	31
4.4.3	Training	32
4.5	Ablationsstudie	33
4.6	Evaluation	34
4.7	Quantifizierung des Verbuschungsgrades	35
5	Fazit und Diskussion	36
5.1	Evaluation der semantischen Segmentierung	36
5.1.1	Gesamtmetriken	36
5.1.2	Klassenweise Auswertung	36
5.1.3	Konfusionsmatrix	36
5.2	Fehleranalyse	36
5.2.1	Einfluss des Klassenungleichgewichts	36
5.2.2	Kritische Verwechslungen	36
5.3	Quantifizierung des Verbuschungsgrades	36
5.4	Vergleich mit dem 2D-Ansatz	36
5.5	Diskussion	36
5.6	Fazit	36
6	Ausblick und Einordnung in den Gesamtkontext	37
	Anhang	38
	Literaturverzeichnis	39

Abbildungsverzeichnis

Abbildung 1: Grundprinzip von Structure from Motion	8
Abbildung 2: Ablauf der inkrementellen SfM-Pipeline	9
Abbildung 3: Funktionsweise der Faltung	12
Abbildung 4: Aufbau eines CNN	12
Abbildung 5: Architektur von PointNet++	16
Abbildung 6: Fehllabel durch den Label-Transfer	24
Abbildung 7: Wirkung der höhenbasierten Labelkorrektur	25

Tabellenverzeichnis

Tabelle 1: Übersicht der Ablationsläufe	33
---	----

Abkürzungsverzeichnis

Symbolverzeichnis

1 Einleitung und Motivation

Der Schutz und Erhalt naturnaher Lebensräume ist eine zentrale Aufgabe des europäischen Naturschutzes. Allein das Natura-2000-Netzwerk umfasst rund 25.000 Schutzgebiete in den EU-Mitgliedsstaaten, deren Zustand regelmäßig erfasst und überwacht werden muss [1]. Indikatoren des Habitatzustands sind dabei unverzichtbar, um Fortschritte im Naturschutz nachzuvollziehen. Ihre Erhebung über große Flächen und in feiner Auflösung bleibt jedoch eine Herausforderung [1].

Klassischerweise erfolgt diese Vegetationskartierung durch Geländearbeit: Fachleute begehen die Flächen und erheben Daten manuell vor Ort. Da dieses Vorgehen sehr zeit- und kostenintensiv ist, können auf diese Weise meist nur kleine Flächen kartiert werden. An dieser Stelle setzen Methoden der Fernerkundung an. Insbesondere das Drohnen bzw. UAS-gestützte Monitoring liefert hochauflösende Daten und kann den Aufwand intensiver Geländekartierungen deutlich reduzieren, wobei Genauigkeiten erreicht werden, die klassische Verfahren der Luftbildinterpretation erreichen oder übertreffen [2].

Gerade für die Heideflächen wurde gezeigt, dass sich der Erhaltungszustand fernerkundlich bewerten lässt, sofern die Auswertung eng an die etablierten feldbasierten Kartierschemata angelehnt sind [3]. Allerdings besteht weiterhin eine deutliche Lücke zwischen den feldbasierten Monitoring-Richtlinien und den bestehenden fernerkundlichen Ansätzen, was deren praktische Anwendung erschwert [3]. Der entscheidende Haken klassischer Fernerkundung liegt zudem darin, dass die erhobenen Daten wiederum manuell von Fachleuten ausgewertet werden müssen, was erneut sehr zeitaufwendig ist. Genau hier wird der Einsatz künstlicher Intelligenz interessant, da sie die Auswertung der Fernerkundungsdaten automatisieren kann.

Die Anwendung von Machine-Learning-Verfahren in der Fernerkundung ist seit Jahren etabliert. Klassische Algorithmen wie Random Forest (RF) werden vor allem zur Klassifizierung der Bodenbedeckung eingesetzt. Eischeid et al. (2021) [4] nutzten beispielsweise einen überwachten RF-Klassifikator, um aus Drohnenbildern die Vegetation arktischer Tundra zu kartieren. Auch Support Vector Machines (SVMs) finden Anwendung, etwa bei Cao et al. (2018) [5] zur objektbasierten Klassifizierung von Mangrovenarten aus hochauflösenden UAV-Hyperspektraldaten.

Einen entscheidenden Fortschritt brachte die Einführung von Deep Learning und insbesondere von Convolutional Neural Networks (CNNs), die die Objekterkennung und damit das Habitatmonitoring deutlich verbessert haben [6].

Der wesentliche Vorteil gegenüber klassischen Verfahren liegt darin, dass CNNs die entscheidenden Merkmale automatisch aus komplexen, hochdimensionalen Rohdaten lernen, während klassische Algorithmen auf eine manuelle Merkmalsextraktion angewiesen sind und bei unregelmäßigen oder komplexen Datenmengen schnell an ihre Grenzen stoßen. Eine ausführliche Gegenüberstellung der Ansätze sowie verschiedene CNN-Architekturen erfolgt in Kapitel 2 (Theoretischer Hintergrund).

Aus den genannten Gründen ist es nicht verwunderlich, dass aktuelle Projekte im Bereich des Habitat-Qualitätsmonitorings auf Deep Learning zurückgreifen. So auch das Projekt des Instituts für Landschaftsökologie der Universität Münster: "Ready for Take-Off?! How to integrate UAS remote sensing into the monitoring of EU habitats directive sites?". Dort wird untersucht, wie sich UAS-basierte Fernerkundung in das Monitoring von FFH-Gebieten integrieren lässt, gerade weil UAS deutlich hochauflösendere Daten liefern als Satellitenbilder und flexibler einsetzbar sind. Die zugrunde liegende Flora-Fauna-Habitat-Richtlinie bildet innerhalb des Natura-2000-Netzwerks das Rückgrat des europäischen Naturschutzes [7] und definiert damit die Schutzgebiete, deren Erhaltungszustand im Projekt erfasst werden soll.

Neben der Habitatstruktur (etwa *Calluna*-Lebenszyklusphasen oder Sandanteil) und dem Arteninventar sollen dabei vor allem Degradationsindikatoren wie der Deckungsgrad invasiver Neophyten, von Gras, Gehölzen und die Verbuschung ermittelt werden, da diese sich kritisch auf den Erhaltungszustand von Heideflächen auswirken. Heideflächen sind nährstoffarme Halbkulturbiotope, die erst durch menschliche Nutzung entstanden sind. Bleibt diese Nutzung aus oder werden die Standorte durch Eutrophierung mit Nährstoffen angereichert, setzt natürliche Sukzession ein, bei der Gräser und Gehölze aufkommen und die Zwergstrauchheide durch Nährstoffentzug und die Beschattung zunehmend überwuchern [8]. Die Verbuschung ist daher ein zentraler Degradationsindikator für den Erhaltungszustand von Heideflächen. Da die früheren Nutzungsformen weggefallen sind, lassen sich diese Flächen heute nur durch aufwändige Pflegemaßnahmen offenhalten. Um solche Maßnahmen gezielt planen und ihren Erfolg überprüfen zu können, muss der Verbuschungsgrad objektiv, flächendeckend und reproduzierbar erfasst werden.

Dazu wurden mehrere Flächen mehrfach mit einer Drohne befliegen, um hochauflösende RGB-Bilder zu erhalten und aus den überlappenden 2D-Aufnahmen mittels Structure from Motion einen 3D-Datensatz abzuleiten - ein Verfahren, das aus mehreren überlappenden 2D-Bildern eine dreidimensionale Punktwolke der aufgenommenen Fläche rekonstruiert. Diese Daten dienen als Ausgangspunkt für ein Deep-Learning-Modell, das die einzelnen Vegetationsarten segmentiert und jeweils einer Klasse zuordnet, woraus sich anschließend ein Verbuschungsgrad berechnen lässt.

Da nun zwei Arten von Datensätzen vorliegen, ergibt sich daraus eine zentrale Frage. Welcher Datensatz eignet sich besser zur Segmentierung der Vegetationsarten und damit zur Berechnung des Verbuschungsgrades - die RGB-Bilder oder die SfM-Punktwolken? Beide Ansätze nutzen Deep Learning, für die 2D-Daten das CNN U-Net und für den 3D-Ansatz PointNet++, das eigens auf unstrukturierten 3D-Punktmengen spezialisiert ist. Aufgabe dieser Arbeit ist es, den 3D-Ansatz zu entwickeln, zu testen und zu evaluieren und sein Ergebnis mit dem 2D-Ansatz zu vergleichen, um herauszufinden, welcher Datensatz sich besser für die Segmentierung der Vegetationsarten und damit für die Erfassung des Verbuschungsgrades eignet.

Daraus ergeben sich zwei Forschungsfragen (FF) mit jeweils einer untergeordneten Teilfrage (TF), die den Weg von der Datenaufbereitung über die Segmentierung bis zur praktischen Nutzung abbilden:

FF1: Inwiefern unterscheidet sich die semantische Segmentierung von 3D-SfM-Punktwolken mittels Deep Learning von einem vergleichbaren 2D-Deep-Learning-Ansatz, sowohl quantitativ als auch qualitativ, bei der Erfassung der Verbuschung von Heideflächen?

TF1: Inwiefern lässt sich ein automatisierter Label-Transfer von 2D-Referenzdaten auf 3D-Punktwolken realisieren, um den Trainingsaufwand für tiefe neuronale Netze effizient zu gestalten?

FF2: Inwiefern unterscheidet sich die aus der 3D-Punktwolken-Segmentierung abgeleitete Rasterisierung des Verbuschungsgrades in ihrer Genauigkeit von der aus dem 2D-RGB-Ansatz abgeleiteten Rasterisierung?

TF2: Wie stabil und anwenderfreundlich lässt sich das entwickelte Modell in eine bestehende GIS-Umgebung integrieren, um für Naturschutzpraktiker nutzbar zu sein?

Das übergeordnete Ziel ist schließlich ein vollständiger Workflow, der es Naturschutzpraktikern ermöglicht, den Verbuschungsgrad von Heideflächen effizient und zuverlässig zu erfassen.

1.1 Aufbau der Arbeit

Kapitel 2 (Theoretischer Hintergrund) legt die theoretischen Grundlagen. In Kapitel 3 (Verwandte Arbeiten) werden verwandte Arbeiten vorgestellt. Kapitel 4 (Methodik) beschreibt

das methodische Vorgehen, bevor in Kapitel 5 (Fazit und Diskussion) die Ergebnisse evaluiert werden. Kapitel 6 (Ausblick und Einordnung in den Gesamtkontext) schließt die Arbeit mit einem Ausblick ab.

2 Theoretischer Hintergrund

2.1 Ökologischer Hintergrund

Als Heiden werden baumfreie Offenlandschaften auf nährstoffarmen, sauren Böden bezeichnet, die überwiegend von niedrigwüchsigen Zwergsträuchern aus der Familie der Heidekrautgewächse (Ericaceae) bewachsen sind. Prägende und namensgebende Leitart ist dabei die Besenheide (*Calluna vulgaris*) [9].

Die heutigen Heideflächen haben sich vor etwa 4.000 Jahren großflächig als Folge menschlicher Waldrodungen entwickelt [9]. Die brachliegenden Flächen wurden anschließend auf vielfältige Weise genutzt, etwa zur Viehhaltung, zum Torfabbau, für die Brandrodung, zur Gewinnung von Brennstoff sowie als Fläche für Tierfutter. Vor allem die Beweidung hielt die Böden nährstoffarm und verhinderte zugleich, dass sich auf den gerodeten Flächen erneut Wald entwickeln konnte, sodass sich dadurch die Heide ausbreiten konnte. Heidekraut selbst gab es allerdings bereits vor dem menschlichen Einfluss, wenn auch nur als Beimischung auf kargen Waldböden, dort wo ein lichtetes, offenes Kronendach genügend Licht auf den Boden fallen ließ. Damit zählen Heideflächen zu den wichtigsten Kulturlandschaften Westeuropas, also zu den durch menschliche Nutzung über lange Zeit geprägten und gestalteten Landschaften, welche im Gegensatz zur vom Menschen unberührten Naturlandschaft stehen. Erstreckten sie sich einst über mehrere Millionen Hektar, sind heute nur noch etwa 350.000 Hektar übrig. Gerade wegen dieser starken Verluste gelten Heidegebiete als Flächen mit hohem Naturschutzpotential [9].

Bleibt die zuvor beschriebene Nutzung aus, setzt an den Heidestandorten eine Sukzession ein, also die gerichtete zeitliche Abfolge von Pflanzengesellschaften an einem Standort. Sie verläuft hier von der Zwergstrauchheide über eine zunehmende Vergrasung bis hin zu Gehölzen und langfristig zurück zum Wald. Ohne Pflege wachsen nach und nach Pioniergehölze auf, etwa Schlehen, Rosen- und Weißdornarten sowie Bäume wie Birken, Zitterpappeln und Kiefern [8]. Diese Dominanzbestände überwuchern die Heide, indem sie ihr Nährstoffe entziehen und beschatten, sodass die niedrigwüchsigen Zwergsträucher zu wenig Licht erhalten. Neben der ausbleibenden Pflege ist die atmosphärische Stickstoffdeposition der zentrale Treiber der heutigen Degradation. Über Jahrzehnte gelangt Stickstoff aus Landwirtschaft und Verkehr über die Luft in die Heide und reichert die von Natur aus nährstoffarmen Böden schleichend an, wobei die Einträge vielerorts über der ökologischen Belastungsgrenze liegen [10]. Dadurch verschiebt sich die Konkurrenz zugunsten schnellwüchsiger Gräser, wodurch auf Trockenheiden die Besenheide (*Calluna vulgaris*) durch das Drahtschmielengras (*Deschampsia flexuosa*) verdrängt wird und

auf Feuchtheiden *Erica tetralix* durch das Pfeifengras (*Molinia caerulea*). Grund dafür ist, dass die Gräser den zusätzlichen Stickstoff effizienter aufnehmen und binden. Mit steigender Stickstoffverfügbarkeit wird die Konkurrenz zunehmend asymmetrisch, und die Zwergsträucher werden unterdrückt [11].

Die Prozesse der schleichenden Vergrasung sowie der anschließenden Ausbreitung von Gehölzen laufen letztlich in der Verbuschung zusammen. Unter Verbuschung versteht man die zunehmende Ausbreitung von Sträuchern und Gehölzen auf der eigentlich offenen Heidefläche. Der Verbuschungsgrad bezeichnet das quantitative Maß dieser Ausbreitung, also den Anteil der von Gehölzen bedeckten Fläche. Da die Verbuschung die charakteristische Zwergstrauchvegetation verdrängt und die offene Struktur der Heide auflöst, gilt sie als Degradationsindikator für den Erhaltungszustand von Heideflächen [3]. Der Erhaltungszustand wiederum ist die Bewertungsgröße, anhand derer die Flora-Fauna-Habitat-Richtlinie den Zustand der geschützten Lebensräume erfasst [7]. Ein hoher Verbuschungsgrad steht damit für einen ungünstigen Erhaltungszustand der Heide.

Um die Heide offenzuhalten und der Sukzession entgegenzuwirken, war schon früher eine kontinuierliche Nutzung nötig, aus der die heutigen Pflegemaßnahmen hervorgegangen sind. So wurde durch das Plaggen die nährstoffreiche Humusschicht samt Heidevegetation vom Oberboden abgetragen. Die Plaggen dienten als Einstreu in den Ställen und gelangten später als Dünger auf die Äcker [12]. Mit der Einführung von Mineraldünger und ausreichend verfügbarem Stroh wurde diese Methode jedoch überflüssig. Auch die weit verbreitete Schafzucht hielt Bäume und Sträucher zurück, da die Schafe die jungen Triebe abfressen [13]. Sie ging zurück, als Baumwolle und billige Wollimporte aus Übersee aufkamen. Daneben wurde die Mahd eingesetzt, bei der die oberen Pflanzenschichten mit Sense oder Sichel abgeschnitten und der Bestand so verjüngt wurde, wobei zugleich junge Baumtriebe und Sträucher entfernt wurden.

Da diese traditionellen Nutzungsformen weggefallen sind, muss der Naturschutz die Offenhaltung heute mit gezielten Pflegemaßnahmen übernehmen. Der maschinelle Plaggenhieb bzw. das Schopfern entfernt Boden- und Rohhumusschichten und entzieht dem System damit gezielt Stickstoff. Die abgetragenen Schichten müssen vollständig aus dem Gebiet entfernt werden, da sich sonst konkurrenzstarke Gräser wie das Land-Reitgras wieder ausbreiten [12]. Bei der Beweidung mit Schafen oder Heidschnucken ist das nächtliche Aufstallen entscheidend, also das Zusammenpferchen auf Äckern oder im Stall, damit der Dung nicht in die Heide zurückgelangt, sondern direkt auf dem Acker landet und somit die Fläche nährstoffarm bleibt [13], [14]. Die Mahd zählt des Weiteren zu den gängigsten Methoden, wobei der Abtransport des Mähguts unbedingt notwendig ist, um eine erneute Nährstoffanreicherung zu vermeiden [15]. Das Entkusseln geht noch einen Schritt

weiter und entfernt aufkommende Gehölze wie Kiefer oder Birke rein mechanisch durch Absägen und Zurückschneiden. Schließlich wird auch das kontrollierte Abbrennen kleiner Flächen angewendet, das dem Rohhumus Nährstoffe entzieht und offene, konkurrenzarme Standorte für das Heidekraut schafft. Anders als beim Plaggen bleibt der Phosphor dabei jedoch über die Asche im System [16]. Vergleichende Untersuchungen zeigen, dass alle diese Verfahren dem System Nährstoffe entziehen, bei anhaltend hoher Stickstoffdeposition aber in kurzen Abständen von etwa fünf Jahren wiederholt werden müssen [15].

Diese Pflegemaßnahmen sind personal-, kosten- und zeitintensiv und müssen regelmäßig wiederholt werden. Ihr gezielter Einsatz und die Kontrolle ihres Erfolgs setzen daher voraus, dass sich der Verbuschungsgrad großflächig, objektiv und wiederholbar bestimmen lässt. Das sind Anforderungen, die eine rein feldbasierte Kartierung nur schwer erfüllt [1]. Damit rücken fernerkundliche und automatisierte Auswertungsverfahren in den Fokus, deren methodische Grundlagen die folgenden Abschnitte behandeln.

2.2 Structure from Motion

2.2.1 Allgemeines

Ausgangspunkt der semantischen Segmentierung sind Drohnenaufnahmen im sichtbaren (RGB-)Spektrum, also zunächst zweidimensionale Bilder. Um daraus eine dreidimensionale Punktwolke zu gewinnen, gibt es grundsätzlich zwei Wege. LiDAR-Punktwolken werden direkt mit einem eigens dafür vorgesehenen Sensor am UAV erfasst und müssen anschließend nur noch über eine herstellereigene Software in ein passendes Format (z.B. LAS) überführt werden. Bei Structure from Motion (SfM) hingegen wird die Punktwolke rechnerisch aus den RGB-Bildern abgeleitet. Spezielle Algorithmen kombinieren viele stark überlappende Einzelbilder zu 2D-Bildmosaiken und 3D-Punktwolken und nutzen die in den UAV-Bildern enthaltene photogrammetrische Information, um daraus hochaufgelöste Gelände- und Oberflächenmodelle (DTMs und DSMs) zu erstellen. Für deren Berechnung stehen zwar zahlreiche Algorithmen zur Verfügung, doch die Wahl der Parameter und die damit verbundenen Unsicherheiten sind häufig nur unzureichend dokumentiert. Abhilfe schaffen quelloffene Softwarewerkzeuge wie COLMAP, die einen reproduzierbaren SfM-Workflow ermöglichen [1].

SfM beruht auf demselben Grundprinzip wie die stereoskopische Photogrammetrie, bei der sich die dreidimensionale Struktur einer Szene aus einer Reihe überlappender, versetzter Aufnahmen ableiten lässt, was dem räumlichen Sehen mit zwei Augen ähnelt (Abbildung 1). Der entscheidende Unterschied zur klassischen Photogrammetrie liegt

darin, dass diese die Position und Ausrichtung der Kamera vorab kennen oder auf Passpunkte mit bekannten 3D-Koordinaten zurückgreifen muss. SfM benötigt beides nicht, da Kamerapositionen und Szenengeometrie allein aus den Bildern automatisch bestimmt werden. Möglich wird das durch einen Bündelausgleich (bundle adjustment), ein Ausgleichsverfahren, das alle Kameraparameter und 3D-Punktpositionen gleichzeitig so optimiert, dass der Rückprojektionsfehler minimal wird. Das Verfahren stammt ursprünglich aus der Computer-Vision-Forschung der 1990er Jahre und wurde durch die Arbeit von Snavely (2008) bekannt, die SfM-Ansätze im Kontext der Cloud-Anwendung Microsoft Photosynth beschreibt [17].




Abbildung 1: Grundprinzip von Structure from Motion: Aufnahme desselben Objekts aus mehreren überlappenden, versetzten Kamerapositionen [17].

Damit die Rekonstruktion gelingt, müssen dieselben Merkmale in mindestens drei Aufnahmen sichtbar sein. Ein hoher Überlappungsgrad und möglichst viele Bilder aus unterschiedlichen Positionen verbessern das Ergebnis, da sie die Zahl zuverlässiger Merkmalszuordnungen und die Redundanz des Systems erhöhen [17].

2.2.2 Ablauf der Rekonstruktion

Die konkrete Umsetzung dieses Prinzips lässt sich an der inkrementellen SfM-Pipeline (Abbildung 2) nachvollziehen, wie sie in COLMAP realisiert ist. Sie gliedert sich in zwei Phasen: die Korrespondenzsuche (correspondence search) und die schrittweise 3D-Rekonstruktion (incremental reconstruction). In der ersten Phase werden zunächst in

jedem Einzelbild lokale Merkmale, sogenannte Keypoints, erkannt, was üblicherweise mit dem SIFT-Verfahren geschieht. Diese Merkmale werden auch dann wiedererkannt, wenn sie in verschiedenen Bildern unterschiedlich groß, gedreht oder beleuchtet erscheinen. Zu jedem Keypoint wird dazu ein Deskriptor berechnet, der ein eindeutiges Zuordnen über viele Bilder hinweg erlaubt. Wie viele Merkmale ein Bild liefert und wie dicht die spätere Punktwolke wird, hängt dabei von Bildtextur und Auflösung ab. Im nächsten Schritt (matching) werden über diese Merkmale Bildpaare gefunden, die denselben Szenenausschnitt zeigen. Ihre korrespondierenden Punkte werden einander zugeordnet. Da diese Zuordnung allein auf dem Aussehen der Merkmale beruht, werden die Paare anschließend geometrisch überprüft (geometric verification) und mithilfe der projektiven Geometrie Fehlzusammenordnungen aussortiert. Das Ergebnis der ersten Phase ist ein Scene Graph, also ein Graph, der festhält, welche Bilder denselben Bildbereich zeigen und welche Punkte einander entsprechen. Er bildet die Grundlage für die Rekonstruktion [18].

In der zweiten Phase wird daraus schrittweise das dreidimensionale Modell aufgebaut. Den Ausgangspunkt bildet ein sorgfältig gewähltes Bildpaar, das als Keim des Modells dient (initialization). Von dort aus werden nach und nach weitere Bilder eingehängt (image registration), indem ihre Kameraposition über bereits bekannte 3D-Punkte bestimmt wird. Anschließend werden durch Triangulation aus mehreren Blickwinkeln neue 3D-Punkte berechnet und der Wolke hinzugefügt. Zwischendurch werden Kamerapositionen und 3D-Punkte immer wieder gemeinsam durch den Bündelausgleich verfeinert und Ausreißer entfernt, damit sich die entstehenden Fehler nicht aufschaukeln. Diese Abfolge aus Einhängen, Triangulieren und Ausgleichen wiederholt sich, bis alle Bilder registriert sind. Als Ergebnis liefert SfM dann die Kamerapositionen (motion) und eine zunächst noch spärliche 3D-Punktwolke (structure) [18].




Abbildung 2: Ablauf der inkrementellen SfM-Pipeline in COLMAP [18].

Diese spärliche Wolke enthält jedoch zunächst nur die markanten Merkmalspunkte. Die dichte Punktwolke, die für die spätere Segmentierung benötigt wird, entsteht erst in einem nachgelagerten, eigenständigen Verfahren, dem Multi-View Stereo (MVS). Während Structure from Motion die Szene nur spärlich modelliert, liefert MVS ihre dichte Modellierung [19]. Den Kern bildet dabei die pixelweise Korrespondenzsuche. Dort

wird für sehr viele Bildpunkte über mehrere Ansichten hinweg nach übereinstimmenden Entsprechungen gesucht, woraus sich für jeden Punkt eine Tiefe schätzen lässt. Welche Ansichten dafür herangezogen werden, steuern photometrische und geometrische Kriterien. Die so entstandenen Tiefenkarten werden anschließend zu einer einheitlichen, dichten Szenenrepräsentation zusammengeführt [19].

Diese Punktwolke liegt allerdings zunächst in einem relativen Koordinatensystem, dem Bildraum (image space) und besitzt weder einen echten Maßstab noch eine räumliche Orientierung. Um sie in reale Koordinaten zu überführen, wird sie anschließend georeferenziert. Das bedeutet, dass die Wolke über wenige Passpunkte (ground control points, GCPs) mit bekannten Objektinformationen vom Bildraum in den realen Objektraum (object space) überführt wird. Dazu dient eine 3D-Ähnlichkeitstransformation, die Maßstab, Drehung und Verschiebung zwischen beiden Koordinatensystemen angleicht [17].

Wie praxistauglich das gerade in der Heide ist, zeigt Schmidt et al. (2017): Aus überlappenden UAV-RGB-Bildern leiteten sie per SfM eine 3D-Punktwolke ab und daraus ein Canopy Height Model, die Differenz aus Oberflächen- und Geländemodell, wodurch die Vegetationshöhe flächig abgebildet wurde. Diese Höheninformationen wurden dann zur Bewertung des Erhaltungszustands Calluna-dominierte Heiden genutzt [3].

2.3 Convolutional Neural Networks (CNNs)

2.3.1 Allgemeines

Klassische Verfahren des maschinellen Lernens konnten Rohdaten wie die Pixelwerte eines Bildes nicht unmittelbar verarbeiten. Stattdessen war ein manuell entworfener Merkmalsextraktor nötig, der die Rohdaten mit viel Fachwissen in eine geeignete interne Repräsentation, einen Merkmalsvektor, überführte [20]. Deep Learning überwindet diese Einschränkung, indem es die entscheidenden Merkmale automatisch aus den Rohdaten lernt, also ohne die manuelle Merkmalskonstruktion durchzuführen, und ist damit besonders für hochdimensionale, nichtlineare und komplexe Daten geeignet [6].

Diese Fähigkeit beruht auf dem Prinzip des Representation Learning. Dieses beschreibt Methoden, die es einer Maschine erlauben, aus Rohdaten selbständig die für die Erkennung oder Klassifikation nötigen Repräsentationen zu finden. Deep Learning ist sozusagen Representation Learning mit mehreren Repräsentationsebenen. Dabei überführen verkettete, einfache und nicht-lineare Module die Repräsentation Schritt für Schritt von der Rohform in eine jeweils höhere, abstraktere Ebene. Entscheidend ist dabei,

dass diese Merkmalsebenen, welche zudem hierarchisch aufeinander aufbauen, nicht von Menschen entworfen, sondern mit allgemeinen Lernverfahren aus den Daten gelernt werden. Bei einem Bild zum Beispiel erkennt die erste Ebene typischerweise Kanten, die zweite setzt diese zu Motiven zusammen, die dritte zu Teilen bekannter Objekte und weitere Ebenen schließlich zu ganzen Objekten. So entsteht schrittweise aus einfachen Merkmalen eine immer abstraktere Darstellung [20].

Ein Convolutional Neural Network (CNN) ist eine spezielle Deep-Learning-Architektur, die auf gitterförmige Daten zugeschnitten ist, wie sie etwa ein Bild darstellt. Ein Farbbild liegt beispielsweise als drei zweidimensionale Arrays vor, je eines für die Pixelwerte der drei Farbkanäle. Dieses Netzwerk setzt das allgemeine Prinzip des mehrschichtigen, hierarchischen Merkmalslernens um, inklusive der Faltung (convolution) und der Hinzunahme geteilter Gewichte. Die vier prägenden Grundideen eines CNN sind neben lokalen Verbindungen, geteilten Gewichten und Pooling, auch die Verwendung vieler Schichten [6]. Die ersten Stufen bestehen aus zwei Schichttypen, Faltungs- und Pooling-Schichten. In einer Faltungsschicht sind die Einheiten in Merkmalskarten (feature maps) organisiert. Jede Einheit ist nur mit einem lokalen Ausschnitt (local patch) der vorherigen Schicht verbunden, und zwar über einen Satz Gewichte, der sogenannten filter bank. Das lokale gewichtete Summenergebnis läuft anschließend durch eine Nichtlinearität, z.B. eine ReLU (Rectified Linear Unit), die negative Werte auf null setzt und positive unverändert weitergibt. Alle Einheiten einer Merkmalskarte teilen sich dabei dieselbe filter bank, da benachbarte Werte in Bildern stark korreliert sind und lokale Motive bilden, die zudem ortsunabhängig überall auftreten können [20].

Anschaulich lässt sich das so verstehen, dass ein kleiner, lernbarer Filter schrittweise über das gesamte Bild geschoben wird und an jeder Position aus dem lokalen Ausschnitt eine Antwort berechnet. Alle Antworten zusammen bilden dann die Merkmalskarte (Abbildung 3). Weil derselbe Filter an jeder Stelle verwendet wird, erkennt er dasselbe lokale Muster überall im Bild, während verschiedene Filter jeweils ein anderes Muster detektieren und so verschiedene Merkmalskarten erzeugen.




Abbildung 3: Funktionsweise der Faltung. [Eigene Darstellung].

Die Pooling-Schicht fasst anschließend semantisch ähnliche Merkmale zusammen. Dabei typisch ist das Max-Pooling, das den Maximalwert eines lokalen Ausschnitts einer Merkmalskarte übernimmt, wodurch die Dimension der Repräsentation reduziert und eine Invarianz gegenüber kleinen Verschiebungen und Verzerrungen erzeugt wird [20].

Im Gesamtaufbau durchläuft das Eingabebild schließlich mehrere gestapelte Stufen aus Faltung, Nichtlinearität und Pooling (Abbildung 4). Mit jeder Stufe wird die räumliche Auflösung gröber, die Merkmale aber zahlreicher und abstrakter, so wie es die Hierarchie von Kanten über Motive und Objektteile bis hin zu ganzen Objekten vorgibt. Am Ende folgen voll verbundene Schichten, die aus diesen Merkmalen die eigentliche Vorhersage berechnen [20].




Abbildung 4: Aufbau eines CNN aus gestapelten Faltungs- und Pooling-Stufen [20].

2.3.2 Anwendung in der Fernerkundung

In der Fernerkundung von Vegetation sind CNNs inzwischen breit erprobt. Für die Bildanalyse haben sich zwei Netzfamilien herausgebildet, die sich darin unterscheiden, wie

kleinteilig sie ein Bild auswerten. Pixelbasierte Netze klassifizieren jeden einzelnen Bildpunkt und liefern so eine semantische Segmentierung, also eine flächendeckende Klassenkarte. Objektbasierte Netze, sogenannte anchor-based Netze, gehen anders vor. Sie legen vordefinierte Referenzboxen (anchors) über das Bild, um Objekte zu lokalisieren und ihre Kategorie und Position zu bestimmen. Ein bekanntes Beispiel ist YOLO (You Only Look Once) [6]. Für das Auffinden einzelner Objekte wie Baumkronen eignen sich solche Netze gut, für flächendeckende Klassenkarten kommen vor allem U-Net und DeepLab zum Einsatz, während ResNet eher der patchweisen Klassifikation dient, bei der ein ganzer Bildausschnitt eine einzige Klasse erhält statt jeder Bildpunkt einzeln. Die Gemeinsamkeit bei allen ist, dass sie ihre Merkmale über Faltung und Pooling gewinnen [6]. U-Net besteht aus zwei aufeinander abgestimmten Teilen. Ein kontrahierender Pfad, der Encoder, reduziert die räumliche Auflösung schrittweise und verdichtet zugleich die Merkmalsinformation, während der expandierende Pfad, der Decoder, sie über Up-Convolutions und die Verkettung (concatenation) mit den hochaufgelösten Merkmalen des Encoders wieder zu einer pixelgenauen Ausgabe zusammenführt. Die direkten Verbindungen zwischen beiden Pfaden erhalten dabei die räumliche Genauigkeit [6]. Wie leistungsfähig dieser Ansatz ist, zeigen zahlreiche Anwendungen. So kartierte ein U-Net Waldtypen und Störungen im atlantischen Regenwald aus WorldView-3-Satellitenbildern mit einer Klassifikationsgenauigkeit von über 95 %, und in weiteren Arbeiten ließen sich einzelne Baumarten aus UAV-Satellitenbildern mit Genauigkeiten von rund 84 bis 96 % bestimmen [6].

Methodisch ist das dieselbe Aufgabe wie in dieser Arbeit, nämlich eine pixelweise semantische Segmentierung zur Kartierung von Vegetationsklassen. Die vorliegende Arbeit überträgt sie vom Wald auf die Heide und vom zweidimensionalen Bild auf die dreidimensionale Punktwolke. U-Net dient hier als etabliertes 2D-Verfahren, an dem sich der neu entwickelte 3D-Ansatz PointNet++ messen lässt.

2.4 Geometric Deep Learning

Die im vorigen Abschnitt beschriebenen CNNs setzen ein regelmäßiges Gitter voraus, wie es ein Bild bietet. Eine dreidimensionale Punktwolke ist dagegen unstrukturiert. Sie besteht aus einer ungeordneten Menge von Punkten ohne feste Nachbarschaftsbeziehungen, weshalb sich die Faltung nicht unmittelbar anwenden lässt. Für genau solche Daten wurde das Geometric Deep Learning (GDL) entwickelt. Der Begriff fasst Verfahren zusammen, die tiefe neuronale Netze von gitterförmigen auf nicht-euklidische Daten wie Graphen, Mannigfaltigkeiten und eben Punktwolken verallgemeinern [21].

Ein naheliegender Ausweg besteht darin, die Punktwolke vor der Verarbeitung in ein regelmäßiges Format zu überführen, etwa in ein 3D-Voxelgitter, das dreidimensionale Pendant zu Pixeln, oder eine Sammlung von Bildern. Dieser Umweg bläht die Daten jedoch unnötig auf und bringt weitere Probleme mit sich [22]. Sinnvoller ist ein Netz, das direkt auf den Punkten arbeitet. Die fehlende Ordnung, also die beliebige Reihenfolge der Punkte in einer Punktwolke, stellt dabei eine besondere Herausforderung dar. Aus diesem Grund muss ein solches Netz permutationsinvariant sein. Werden dieselben Punkte anders angeordnet, soll das Ergebnis gleich bleiben [22].

2.4.1 Semantische Segmentierung von 3D-Punktwolken

Die für diese Arbeit zentrale Aufgabe ist die semantische Segmentierung einer Punktwolke. Dabei erhält jeder einzelne Punkt eine von mehreren Zielklassen, ohne dass verschiedene Objekte derselben Klasse unterschieden werden [23]. Das trennt die Segmentierung von der reinen Klassifikation, bei der die gesamte Wolke ein einziges Label bekommt, während die Segmentierung ein Label je Punkt liefert [22]. Ein entsprechendes Netz gibt für jeden Punkt einen Wert pro Klasse aus, sodass sich jedem die wahrscheinlichste Klasse zuordnen lässt [22]. Übertragen auf diese Arbeit heißt das, jedem Punkt der Heide-Punktwolke eine Vegetationsklasse zuzuweisen. Aus dieser punktweisen Zuordnung lässt sich anschließend der Verbuschungsgrad berechnen.

2.4.2 Beispiel: PointNet

PointNet war das erste Netz, das ungeordnete Punktwolken direkt verarbeitet [22]. Jeder Punkt wird dabei zunächst einzeln betrachtet und ist im einfachsten Fall nur durch seine drei Koordinaten gegeben, die sich um weitere Merkmale wie Normalen ergänzen lassen. Auf jeden Punkt wird dasselbe kleine neuronale Netz angewendet, ein sogenanntes Multilayer Perceptron (MLP). Ein MLP ist ein einfaches, vollständig verbundenes Netz aus mehreren Schichten, das einen Eingabevektor auf einen Ausgabevektor abbildet. Weil für alle Punkte dieselben Gewichte genutzt werden, spricht man von einem geteilten MLP, welches den geteilten Gewichten der filter bank bei CNNs entspricht und lediglich auf einzelne Punkte statt auf ganze Bildausschnitte angewendet wird [22].

Damit die Reihenfolge der Punkte keine Rolle spielt, führt PointNet die einzelnen Punktmerkmale mit einer symmetrischen Funktion zusammen, dem Max-Pooling. Es übernimmt für jedes Merkmal den größten Wert über alle Punkte hinweg, wodurch ein einziges globales Merkmal (global feature) entsteht, das die gesamte Punktwolke beschreibt

und nicht von der Reihenfolge der Punkte abhängt [22]. Aus diesem globalen Merkmal berechnet PointNet je nach Aufgabe unterschiedliche Ausgaben. Wohingegen das Netz für die Klassifikation ein einziges Label für die gesamte Wolke liefert, erhält bei der semantischen Segmentierung jeder Punkt sein eigenes Label. Dazu wird unter anderem das globale Merkmal mit den lokalen Merkmalen jedes einzelnen Punktes verkettet [22]. Die größte Schwäche, die dabei bleibt, ist, dass sich PointNet stark auf dieses eine globale Merkmal stützt und jeden Punkt unabhängig von seinen Nachbarn verarbeitet. Lokale Strukturen, die sich aus den Abständen benachbarter Punkte ergeben, erfasst es daher kaum, was die Erkennung feiner Muster begrenzt [24]. Genau hier setzt die Weiterentwicklung PointNet++ an.

2.4.3 Beispiel: PointNet++

PointNet++ begegnet dieser Schwäche mit einem hierarchischen Aufbau (Abbildung 5), der PointNet wiederholt auf ineinander verschachtelte Teilmengen der Punktwolke anwendet [24]. Indem es benachbarte Punkte anhand ihrer räumlichen Abstände zu lokalen Regionen zusammenfasst, lernt das Netz lokale Merkmale auf zunehmend größeren Kontext-Skalen, angefangen bei kleinen Nachbarschaften bis hin zu größeren Regionen. Kern des Verfahrens ist die sogenannte Set Abstraction, eine Verarbeitungsstufe aus drei Schritten. Im Sampling werden zunächst einzelne Punkte als Zentren (centroids) lokaler Regionen ausgewählt. Das anschließende Grouping bildet um jedes dieser Zentren eine lokale Region aus den benachbarten Punkten. In der abschließenden PointNet-Schicht fasst ein kleines PointNet jede solche Region zu einem einzelnen Merkmalsvektor zusammen. Mehrere solcher Stufen hintereinander erzeugen die Hierarchie, in der die Zahl der Punkte von Stufe zu Stufe abnimmt, während die Merkmale immer reichhaltiger werden [24].

Für die Segmentierung muss am Ende jeder ursprüngliche Punkt ein Label erhalten, nicht nur die wenigen verbliebenen Zentren. Dazu werden die auf den groben Stufen gelernten Merkmale schrittweise wieder auf alle Punkte übertragen, ein Vorgang, der als feature propagation bezeichnet wird. Die Übertragung erfolgt durch eine abstandsgewichtete Interpolation über die k nächsten Nachbarn und wird durch Skip-Verbindungen (skip connections) ergänzt, die Merkmale früherer Stufen direkt mit einbringen. So erhält am Ende jeder Punkt der Wolke eine Klasse [24].




Abbildung 5: Architektur von PointNet++ mit hierarchischen Set-Abstraction-Stufen sowie Segmentierungs- und Klassifikationszweig [24].

PointNet++ ist damit das in dieser Arbeit eingesetzte 3D-Verfahren. Es weist jedem Punkt der Heide-Punktwolke eine Vegetationsklasse zu und erfasst dabei die lokalen Strukturen, die für die Unterscheidung der Vegetationsarten und damit für die Bestimmung der Verbuschung entscheidend sind.

2.5 Evaluationsmetriken

Die Bewertung der Ergebnisse erfolgt auf zwei Ebenen, die den beiden Forschungsfragen entsprechen. Auf der ersten Ebene wird die Güte der punktweisen Segmentierung beurteilt, also wie zuverlässig das Netz jedem Punkt die richtige Vegetationsklasse zuweist. Die dafür üblichen Maße leiten sich aus der Konfusionsmatrix ab, die für jede Klasse die korrekten und die falschen Zuordnungen gegenüberstellt [23]. Auf der zweiten Ebene wird der daraus abgeleitete Verbuschungsgrad geprüft, indem der vorhergesagte Wert je Rasterzelle mit einem Referenzwert verglichen wird. Da hier kein Klassenlabel, sondern ein flächiger Anteil bewertet wird, kommen statistische Maße für die Übereinstimmung zum Einsatz. Die folgenden beiden Abschnitte stellen die jeweils verwendeten Metriken vor.

2.5.1 Metriken der Segmentierung

Die erste Forschungsfrage betrifft die Güte der punktweisen Segmentierung. Grundlage der Bewertung ist die Konfusionsmatrix (confusion matrix), die die vorhergesagten Klassen den tatsächlichen Klassen gegenüberstellt. In ihren Zeilen steht die wahre Klasse eines Punktes, in ihren Spalten die vom Netz vorhergesagte Klasse, sodass der Eintrag c_{ij} angibt, wie viele Punkte der Klasse i als Klasse j klassifiziert wurden. Auf der Diagonalen stehen folglich die korrekt zugeordneten Punkte, während die Einträge außerhalb der Diagonalen

die Verwechslungen zwischen den Klassen sichtbar machen [23]. Aus dieser Matrix leiten sich die folgenden Maße ab, wobei N die Anzahl der Klassen bezeichnet.

Die Gesamtgenauigkeit (Overall Accuracy, OA) beschreibt den Anteil aller korrekt klassifizierten Punkte an der Gesamtzahl der Punkte. Sie ergibt sich als Summe der Diagonaleinträge geteilt durch die Summe aller Einträge der Matrix [23]:

$$OA = \frac{\sum_{i=1}^N c_{ii}}{\sum_{i=1}^N \sum_{j=1}^N c_{ij}}$$

Die Gesamtgenauigkeit lässt sich einfach interpretieren, reagiert aber empfindlich auf ungleich große Klassen. Dominiert eine Klasse den Datensatz, kann ein hoher Wert vor allem deren gute Trennung widerspiegeln, ohne dass seltene Klassen zuverlässig erkannt werden.

Um die einzelnen Klassen unabhängig von ihrer Häufigkeit zu beurteilen, wird die Schnittmenge über Vereinigung (Intersection over Union, IoU) je Klasse betrachtet. Sie setzt die korrekt erkannten Punkte einer Klasse ins Verhältnis zur Vereinigung aus vorhergesagten und tatsächlichen Punkten dieser Klasse und berücksichtigt so sowohl übersehene als auch fälschlich zugeordnete Punkte [23]:

$$IoU_i = \frac{c_{ii}}{c_{ii} + \sum_{j \neq i} c_{ij} + \sum_{j \neq i} c_{ji}}$$

Als zusammenfassendes Maß über alle Klassen dient die mittlere Schnittmenge über Vereinigung (mean IoU, mIoU), der Mittelwert der klassenweisen IoU-Werte [23]:

$$mIoU = \frac{1}{N} \sum_{i=1}^N IoU_i$$

Da jede Klasse gleich in den Mittelwert eingeht, gewichtet die mittlere IoU seltene und häufige Klassen gleichermaßen und eignet sich daher als Hauptkennzahl für den Vergleich der Segmentierungsgüte. In dieser Arbeit lässt die klassenweise IoU erkennen, welche Vegetationsklassen das Netz gut voneinander trennt und welche es häufig verwechselt, während die mittlere IoU die Gesamtleistung in einer einzigen Kennzahl bündelt. Die Konfusionsmatrix ergänzt diese Werte, indem sie zeigt, zwischen welchen Klassen die Fehler konkret auftreten.

Wird eine einzelne Klasse gegen alle übrigen betrachtet, kommen drei weitere Maße hinzu, die sich ebenfalls aus der Konfusionsmatrix ergeben [23]. Die richtig erkannten Punkte

dieser Klasse heißen richtig positiv (true positives, TP), die ihr fälschlich zugeordneten falsch positiv (false positives, FP) und die übersehenen falsch negativ (false negatives, FN). Die Präzision (Precision) gibt an, welcher Anteil der vorhergesagten Punkte tatsächlich zu dieser Klasse gehört [23]:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Die Trefferquote (Recall) beschreibt umgekehrt, welcher Anteil der tatsächlich vorhandenen Punkte dieser Klasse auch als solcher erkannt wurde [23]:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Beide Maße lassen sich gegeneinander ausspielen, denn wer vorsichtig vorhersagt, erreicht eine hohe Präzision bei niedriger Trefferquote und umgekehrt. Das F1-Maß fasst sie deshalb als harmonisches Mittel zusammen [23]:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Für diese Arbeit erlauben Präzision und Trefferquote die Unterscheidung, in welche Richtung sich das Netz irrt. Eine niedrige Präzision bedeutet, dass zu viel als Gehölz ausgewiesen und der Verbuschungsgrad überschätzt wird, eine niedrige Trefferquote das Gegenteil. Für die Bewertung des Erhaltungszustands ist dieser Unterschied erheblich, weil beide Fehler zu gegensätzlichen Pflegeempfehlungen führen.

2.5.2 Metriken des Verbuschungsgrades

Die zweite Forschungsfrage betrifft die Genauigkeit des aus der Segmentierung abgeleiteten Verbuschungsgrades. Anders als bei der Segmentierung wird hier keine Klassenzuordnung, sondern ein flächiger Anteil je Rasterzelle bewertet. Für jede Zelle liegt ein vorhergesagter Verbuschungsgrad $\hat{y}_i$ und ein Referenzwert y_i vor. Die Bewertung stützt sich dabei auf die Abweichung zwischen beiden Werten. Diese Abweichung entspricht dem Residuum $\hat{\epsilon}_i = y_i - \hat{y}_i$, das die Differenz zwischen beobachtetem und vorhergesagtem Wert angibt [25]. Aus den Residuen über alle n Zellen leiten sich die folgenden Maße ab.

Der Wurzelwert des mittleren quadratischen Fehlers (Root Mean Squared Error, RMSE) mittelt die quadrierten Residuen und zieht daraus die Wurzel. Durch die Quadrierung gehen

große Abweichungen stärker ein, sodass der RMSE einzelne grobe Fehleinschätzungen betont:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Das Bestimmtheitsmaß (Coefficient of Determination, R^2) gibt den Anteil der Streuung der Referenzwerte an, der durch die Vorhersage erklärt wird. Es setzt die verbleibende Residualstreuung ins Verhältnis zur Gesamtstreuung der Referenzwerte, wobei $\bar{y}$ deren Mittelwert bezeichnet [25]:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

R^2 nimmt Werte zwischen null und eins an. Ein Wert nahe eins bedeutet, dass die Vorhersagen den Referenzwerten weitgehend folgen, während ein Wert nahe null anzeigt, dass die Vorhersage kaum mehr erklärt als der Mittelwert der Referenz.

Solche Maße sind in der Heide-Fernerkundung etabliert. Schmidt et al. bewerten die Übereinstimmung ihrer fernerkundlich geschätzten Calluna-Deckung und Bestandshöhen mit Referenzdaten ebenfalls über R^2 und RMSE [3]. Für diese Arbeit erlaubt der RMSE eine Aussage über die durchschnittliche Größe der Abweichung im Verbuschungsgrad, während das Bestimmtheitsmaß die Güte des Zusammenhangs mit der Referenz bewertet.

3 Verwandte Arbeiten

4 Methodik

4.1 Untersuchungsgebiete und Datengrundlage

4.1.1 Untersuchungsgebiete

4.1.2 Befliegung und photogrammetrische Auswertung

4.1.3 Manuelle Annotation und Klassenschema

4.2 Datenvorverarbeitung

Die Vorverarbeitung überführt drei Ausgangsgrößen in einen Trainingsdatensatz für PointNet++, nämlich die SfM-Punktwolken der drei Gebiete, die manuell annotierten Polygone und die daran hängenden Qualitätsattribute. Sie ist vollständig in R umgesetzt und stützt sich auf das Paket `lidR` für die Verarbeitung der Punktwolken [26] sowie auf `sf` für die Vektoroperationen [27] und `terra` für die Rasteroperationen [28]. Am Ende steht ein Verzeichnis aus Textdateien, in dem jede Datei eine Kachel der Fläche beschreibt und jede Zeile einen Punkt mit seinen Merkmalen und seinem Label enthält.

4.2.1 Aufbereitung und Prüfung der Ausgangsdaten

Für die Arbeit standen drei photogrammetrisch erzeugte Punktwolken zur Verfügung. Die Wolke der Schneise I im Authausener Wald umfasst 8,3 Millionen Punkte auf einer Ausdehnung von rund 529 mal 263 Metern. Die Punktwolke der 110-kV-Trasse, ebenfalls im Authausener Wald, enthält 67,4 Millionen Punkte auf rund 3.900 mal 1.000 Metern, die Wolke der Cuxhavener Küstenheide 415,3 Millionen Punkte auf rund 2.800 mal 2.150 Metern. Zusammen enthalten die drei Datensätze also etwa 491 Millionen Punkte.

Voraussetzung für den Label-Transfer ist, dass die annotierten Polygone und die Punktwolke im selben Koordinatensystem liegen und räumlich deckungsgleich sind. Beides wurde vorab geprüft, und zwar zuerst rechnerisch über einen Vergleich der EPSG-Codes und der Ausdehnungen und anschließend visuell durch eine gemeinsame Darstellung von Punkten und Polygonrändern. Alle verwendeten Daten liegen in der UTM-Zone 32N (EPSG 25832) vor. Ein weiteres zunächst vorgesehenes Gebiet musste verworfen werden, da seine Daten in geografischen Koordinaten in Grad vorlagen und die metrischen Schwellenwerte der späteren Verarbeitungsschritte dort keine sinnvolle Bedeutung gehabt hätten.

Punktwolken dieser Größe lassen sich nicht vollständig im Arbeitsspeicher halten. Daher wird beim Einlesen das Filterargument von `readLAS()` genutzt, um Punkte bereits während des Lesevorgangs anhand ihrer Koordinaten zu verwerfen. Für jedes annotierte Tile wird nur der Ausschnitt geladen, der innerhalb des umschließenden Rechtecks (bounding box) der zugehörigen Polygone liegt. Da diese Rechtecke die tatsächlichen Annotationsflächen nur grob umschreiben, enthalten die geladenen Ausschnitte auch Punkte außerhalb der Polygone, die im weiteren Verlauf als ungelabelt aussortiert werden. Von den mitgeführten Punktattributen werden ausschließlich die Koordinaten, die vier Farbkanaäle sowie die Klassen- und Qualitätsangaben übernommen, da die Punktwolken der drei Gebiete unterschiedliche Zusatzattribute enthalten und sich sonst nicht zu einem gemeinsamen Datensatz zusammenführen ließen.

4.2.2 Bodenerkennung und Höhennormalisierung

Die Z-Koordinate der Rohpunkte gibt die absolute Höhe an und ist für eine vegetationskundliche Auswertung wenig aussagekräftig, weil sie das Relief des Geländes enthält. Für die Unterscheidung von Heide, Gras und Gehölzen ist dagegen die Höhe über dem Boden entscheidend, also die Wuchshöhe der Pflanze an ihrem Standort. Die Punktwolke wird deshalb höhennormalisiert, wodurch jeder Punkt statt seiner absoluten Höhe seinen vertikalen Abstand zur Geländeoberfläche erhält.

Der erste Schritt ist die automatische Erkennung der Bodenpunkte mit einem Cloth Simulation Filter (CSF) [29]. Anschaulich lässt sich das Verfahren so verstehen, dass die Punktwolke auf den Kopf gestellt wird und ein virtuelles Tuch auf die dabei entstandene Oberfläche fällt. Dessen Form nähert nach dem Absinken die Geländeoberfläche an, und alle Punkte, deren Abstand zu dieser Fläche unter einem Schwellenwert liegt, werden als Boden klassifiziert. Gegenüber älteren hangneigungs- und morphologiebasierten Filtern kommt CSF mit wenigen, einfach zu setzenden Parametern aus [29]. Gesetzt wurden der horizontale Abstand zweier benachbarter Tuchknoten (grid resolution) auf 0,5 Meter, der Abstandsschwellenwert für die Trennung von Boden- und Objektpunkten auf 0,3 Meter sowie die Steifigkeit des Tuchs (rigidness) auf 2, den mittleren der drei zulässigen Werte.

Aus den so bestimmten Bodenpunkten wird anschließend für jeden Punkt der Wolke die lokale Geländehöhe geschätzt und von seiner Z-Koordinate abgezogen. Die Schätzung erfolgt über eine inverse Distanzgewichtung (inverse distance weighting) der zehn nächstgelegenen Bodenpunkte, deren Beitrag zur Schätzung mit dem Quadrat ihres Abstands abnimmt. Bodenpunkte liegen danach nahe null, während die Höhe eines Vegetationspunktes seiner Wuchshöhe entspricht.

Diese Normalisierung erfolgt getrennt für jede der 16 annotierten Teilflächen und nicht gemeinsam über alle Gebiete. Die Höhe über Boden ist eine lokale Größe, wodurch ein einziges Geländemodell über mehrere hundert Kilometer hinweg weder fachlich sinnvoll noch mit vertretbarem Rechenaufwand zu erzeugen wäre. An den Rändern der Gebiete entstehen Werte, wo die photogrammetrische Rekonstruktion ungenau wird und das Geländemodell aus weiter entfernt liegenden Bodenpunkten extrapoliert werden muss. Aus diesem Grund werden nach der Normalisierung Punkte unterhalb von minus einem Meter verworfen.

4.2.3 Übertragung der Labels auf die Punktwolke

Auf der so normalisierten Punktwolke lassen sich nun die Annotationen übertragen. Diese liegen als zweidimensionale Polygone im Luftbild vor, das Modell benötigt jedoch ein Label je Punkt der dreidimensionalen Wolke. Diese Übertragung erfolgt über einen räumlichen Verschnitt, bei dem für jeden Punkt geprüft wird, in welchem Polygon seine X- und Y-Koordinate liegt, woraufhin er dessen Klasse übernimmt. Neben der Vegetationsklasse werden auf demselben Weg die drei Qualitätsattribute `shadow`, `overexposed` und `confidence` übertragen, die festhalten, ob ein Segment verschattet oder überbelichtet war und wie sicher die Zuordnung bei der Annotation war. Punkte ohne zugeordnetes Polygon werden anschließend entfernt, wobei neben fehlenden Werten auch leere Zeichenketten abgefangen werden, da diese in R nicht als fehlender Wert gelten und sonst als eigene Scheinklasse in die weitere Verarbeitung gelangt wären.

Dieses Vorgehen beantwortet die erste Teilfrage nach einem automatisierten Label-Transfer, bringt jedoch eine systematische Schwäche mit sich. Die Polygone wurden auf der von oben sichtbaren Oberfläche gezeichnet, ihre Klasse wird beim Verschnitt aber auf die gesamte darunterliegende Punktsäule übertragen. Jedes Polygon wirkt damit wie ein Ausstecher, der seine Klasse durch die volle Höhe der Punktwolke stempelt.

Ragt eine Baumkrone über eine Heidefläche, ist im Luftbild nur die Krone zu sehen. Dort entsteht ein Baumpolygon, und die darunter wachsende Heide erhält das Label `tree`. An den Rändern derselben Krone kehrt sich der Fehler um. Einzelne Zweige reichen über die benachbarte Fläche hinaus, werden im Bild aber nicht eigens abgegrenzt, weil die Polygongrenze vereinfacht entlang der sichtbaren Kronenkante verläuft. Punkte auf diesen Zweigen fallen in ein Heide- oder Graspolygon und tragen dessen Label. Der Ausstecher wirkt damit in beide Richtungen.

Nachweisen lassen sich beide Fehlerarten an der Höhenverteilung je Klasse. Ein erheblicher Teil der als `tree` gelabelten Punktmasse liegt nahe der Bodenoberfläche und bildet damit

Unterwuchs statt Baum ab. In der Gegenrichtung reichen einzelne als `heath` gelabelte Punkte bis 22 Meter, als `graminoid` gelabelte bis 23 Meter und als `sand` gelabelte bis 14 Meter über den Boden, was für diese Klassen ausgeschlossen ist. Betroffen sind davon allerdings nur wenige Punkte, denn das 95. Perzentil der Heidepunkte liegt bei 1,26 Metern. Dass die Kontamination durch Überhang auftritt und nicht auf einzelne Flächen beschränkt bleibt, zeigen diese Extremwerte dennoch. Anschaulich wird das durch eine Abbildung, die einen senkrechten Schnitt durch die Punktwolke darstellt (Abbildung 6), in dem beide Fehlerarten nebeneinander auftreten.




Abbildung 6: Senkrechter Schnitt durch die Punktwolke der Schneise I nach dem Label-Transfer. [Eigene Darstellung].

4.2.4 Höhenbasierte Labelkorrektur

Um diese Fehllabel zu bereinigen, wird auf der normalisierten Höhe ein Regelwerk angewendet, das Punkte in zwei Richtungen umklassifiziert. Die Aufwärtsregeln stufen Punkte, die für ihre Klasse zu hoch liegen, zur Klasse `tree` hoch. Die Abwärtsregeln behandeln den umgekehrten Fall und weisen tiefliegende Punkte unter Baumpolygonen dem Unterwuchs zu, wobei Punkte unterhalb von 0,5 Metern die Klasse `heath` und Punkte zwischen 0,5 und 2,0 Metern die Klasse `bush` erhalten (Abbildung 7). Die Rückstufung ist dadurch gerechtfertigt, dass die Punktwolke photogrammetrisch aus Aufnahmen von oben entstanden ist und Baumstämme unter geschlossenen Kronen kaum rekonstruiert werden, sodass tiefliegende Punkte unter einem Baumpolygon mit hoher Wahrscheinlichkeit Vegetation am Boden abbilden.




Abbildung 7: Senkrechter Schnitt durch die Punktwolke der 110-kV-Trasse vor (a) und nach (b) der Labelkorrektur. Die Linien bei 0,5 und 2,0 Metern markieren die Grenzen der Abwärtsregeln. [Eigene Darstellung].

Die Schwellenwerte der Aufwärtsregeln wurden nicht geschätzt, sondern aus den Daten selbst abgeleitet. Für jede Klasse wurde über alle 16 annotierten Tiles das 95. Perzentil der normierten Höhe berechnet und auf einen gerundeten Wert festgelegt, woraus sich ein Höhenschwellenwert von 1,15 Meter für `soil`, 1,4 Meter für `sand`, 1,2 Meter für `graminoid` und 1,3 Meter für `heath` ergibt. Auf die Klasse `bush` ist dieses Vorgehen nicht anwendbar, da ihr oberes Perzentil durch überstehende Bäume so stark verfälscht wird, dass es mit 13,5 Metern weit oberhalb jeder realistischen Strauchhöhe liegt. Ihre Schwelle wurde deshalb als eigene Setzung auf 3,5 Meter festgelegt. Dieser Wert orientiert sich an der Wuchshöhe der auf Heideflächen typischen Pioniergehölze wie Schlehe, Weißdorn und Rosenarten [8] und liegt bewusst unterhalb der in der Vegetationskunde üblichen Obergrenze der Strauchschicht von etwa fünf Metern, da Gehölze dieser Höhe im Untersuchungsgebiet bereits durchweg als Birke oder Kiefer und damit als Baum auftreten. Die Klasse `deadwood` bleibt bewusst ohne Höhenregel, weil Totholz sowohl liegend als auch stehend vorkommt und ihre Höhenverteilung deshalb zweigipflig ist, sodass eine einzelne Schwelle eine der beiden Erscheinungsformen systematisch falsch behandeln würde.

Verlässlich ist die Zuweisung des Unterwuchses über feste Höhenbänder allerdings nicht und bleibt somit eine Näherung. Tiefliegende Punkte unter Baumkronen können auch

offener Boden oder Sand sein, werden durch die Abwärtsregeln aber je nach Höhe entweder der Heide oder den Büschen zugeordnet. Beide Klassen können dadurch überschätzt werden, was im Fall von `bush` sogar unmittelbar die Zielgröße dieser Arbeit betrifft.

Hinzu kommt, dass die Regeln punktweise und nicht objektbezogen arbeiten. Ein Strauch, dessen Basis am Boden ansetzt, wird an der Grenze von 0,5 Metern waagrecht durchgeschnitten und unterhalb davon der Heide, oberhalb den Büschen zugeschlagen, obwohl es sich um dieselbe Pflanze handelt. In Abbildung 7 ist das an mehreren Stellen zu erkennen.

Eine weitere Nebenwirkung entsteht aus der Reihenfolge der Regeln. Weil die Aufwärtsregeln zuerst greifen, wird etwa ein Graspunkt oberhalb von 1,2 Metern zunächst zu `tree` hochgestuft und unmittelbar danach von der Abwärtsregel zu `bush` zurückgestuft, obwohl kein Regelsatz diesen Übergang direkt vorsieht. Betroffen sind davon vor allem die Klassen `graminoid` und `heath`. Wie stark beide Effekte die Buschklassen verschieben, wird bei der Einordnung der Ergebnisse aufgegriffen (Kapitel 5). Die Schwellenwerte selbst beruhen zudem auf den 16 annotierten Teilflächen und wären bei einer erneuten Erweiterung des Datensatzes neu zu bestimmen.

4.2.5 Klassenkodierung

Mit der Labelkorrektur stehen die endgültigen Klassen fest. Für die Verarbeitung im neuronalen Netz müssen ihre Namen nun in ganzzahlige Bezeichner überführt werden. Die Zuordnung erfolgt über eine fest im Skript hinterlegte Namensliste und nicht über die in R naheliegende Umwandlung in einen Faktor. Eine solche Umwandlung würde die Bezeichner alphabetisch aus den jeweils vorhandenen Klassen vergeben, sodass sich die Nummerierung bei jeder neuen Datencharge verschieben könnte, sobald eine Klasse hinzukommt oder in einem Datensatz nicht vorkommt. Die feste Liste hält die Bezeichner über alle Chargen stabil und lässt neue Klassen nur am Ende zu. Ein Klassenname, der nicht in der Liste steht, führt zum Abbruch des Skripts, statt unbemerkt einen fehlenden Wert zu erzeugen. Die Klasse `water` ist als Bezeichner reserviert, wird aber erst zur Modellklasse, sobald tatsächlich entsprechende Punkte annotiert sind, da ein Training auf einer leeren Klasse nicht möglich ist.

4.2.6 Lokale Höhenmerkmale

Die bisher vorliegenden Merkmale beschreiben jeden Punkt über seine Lage, seine Farbe und seine Höhe über dem Boden. Für die entscheidende Trennung reicht das nicht aus,

denn die Höhe allein trennt einen 40 Zentimeter hohen Busch nicht von einem gleich hohen Heidebestand. Was eine annotierende Person in diesem Fall nutzt, ist nicht die absolute Höhe, sondern die Struktur des Bestandes, also die Frage, ob die Oberfläche geschlossen und flächig ist oder ob einzelne Zweige aus ihrer Umgebung herausragen. Um diese Information für das Netz verfügbar zu machen, werden je Punkt zwei zusätzliche Merkmale berechnet. Das Merkmal `z_range` gibt die Höhenspanne innerhalb einer Rasterzelle von 0,5 Metern an und erreicht große Werte bei Sträuchern mit Ästen und Lücken, kleine Werte im geschlossenen Heideteppich und nahezu den Wert null auf offenem Boden. Das Merkmal `z_rel` beschreibt die Höhe eines Punktes über der medianen Höhe seiner Umgebung von 2,5 Metern und wird positiv, wenn eine Struktur aus dem umgebenden Bestand herausragt.

Wie schon die Höhennormalisierung erfolgt auch diese Berechnung getrennt je Gebiet. Ein durchgehendes Raster mit 0,5 Metern Zellweite über alle drei Gebiete hinweg bestünde aus so vielen Zellen, dass die verwendete Rasterbibliothek sie nicht mehr adressieren kann, denn zwischen Authausen und Cuxhaven liegen mehrere hundert Kilometer.

Beide Merkmale werden bei fünf Metern begrenzt, `z_rel` zusätzlich nach unten bei minus fünf Metern, da ihr Wertebereich sonst zu groß würde. Schneidet eine Rasterzelle eine Baumkrone, fallen Kronendach und Bodenpunkte in dieselbe Zelle, und `z_range` erreicht dort über 20 Meter. Für die Fragestellung entscheidend ist dagegen der Abstand zwischen einem geschlossenen Heidebestand mit rund 0,1 Metern und einem Busch mit rund einem Meter. Dieser Abstand macht bei einem Wertebereich von 20 Metern nur etwa ein Zwanzigstel der gesamten Spanne aus, sodass das Netz die für die Verbuschung wichtige Unterscheidung aus einem sehr schmalen Ausschnitt des Merkmals herauslesen müsste. Nach der Begrenzung auf fünf Meter entspricht derselbe Abstand rund einem Fünftel der Spanne und tritt für das Netz deutlicher hervor. Verloren geht dabei wenig, da Spannen über fünf Metern nur in Zellen mit Baumkronen vorkommen und Bäume sich bereits über die normalisierte Höhe zuverlässig von der niedrigen Vegetation abheben.

4.2.7 Kachelung

Damit sind alle Merkmale berechnet, und die Punktwolke kann in die Form gebracht werden, die das Netz erwartet. Da PointNet++ keine beliebig großen Szenen verarbeitet, sondern Punktmengen fester Größe, muss sie zuvor zerlegt werden. Ein gleitendes Fenster (sliding window) von zehn Metern Kantenlänge wandert dafür über die Fläche und schneidet daraus quadratische Kacheln. Zwischen zwei Fenstern liegen jeweils fünf Meter Versatz, sodass benachbarte Kacheln sich zur Hälfte überlappen. Damit verdoppelt sich nicht nur

die Zahl der Trainingsbeispiele, das Netz sieht dieselbe Struktur auch an wechselnder Stelle innerhalb der Kachel, was einer Datenerweiterung (data augmentation) entspricht.

Das gleitende Fenster wird je zusammenhängendem Bereich verschoben und nicht über alle Gebiete hinweg, damit die großen unannotierten Zwischenräume ausgelassen werden. Die acht aneinandergrenzenden Teilflächen der Schneise I bilden ein durchgehendes Raster, während alle übrigen Teilflächen isoliert liegen und einzeln verarbeitet werden.

Jede Kachel muss dieselbe Anzahl an Punkten enthalten, weil das Netz eine feste Eingabegröße erwartet. Aus jedem Fenster werden deshalb 8.192 Punkte ohne Zurücklegen gezogen, damit kein Punkt doppelt in eine Kachel gelangt und dort eine Dichte vortäuscht, die in den Daten nicht vorhanden ist. Enthält ein Fenster weniger Punkte, wird es verworfen. Betroffen sind davon vor allem Randfenster, die nur zum Teil innerhalb einer annotierten Fläche liegen. Von 4.170 Fenstern bleiben auf diesem Weg 3.017 Kacheln übrig. Gezogen wird mit einem festen Startwert des Zufallsgenerators, sodass ein erneuter Export dieselben Kacheln erzeugt. Ohne ihn würde sich der Datensatz bei jedem Durchlauf leicht verändern, und die Läufe der Ablationsstudie wären nicht mehr sauber miteinander vergleichbar. Wie viele Punkte eine Kachel enthält, gehört selbst zu den Faktoren, die dort variiert werden (Abschnitt 4.5).

Die Punkte jeder Kachel werden auf die Fenstermitte zentriert, damit das Netz keine absoluten Koordinaten lernt, sondern nur die Anordnung der Punkte zueinander. Die Farbkanäle einschließlich des Nahinfrarotkanals erhalten Werte zwischen null und eins, die Klassenbezeichner werden von eins bis acht auf null bis sieben umgeschrieben, so wie es die Implementierung erwartet. Abgelegt wird jede Kachel als Textdatei, in der eine Zeile einem Punkt entspricht. Dort stehen in fester Reihenfolge die zentrierten X- und Y-Koordinaten, die normalisierte Höhe, die vier Farbkanäle, die beiden lokalen Höhenmerkmale, das Label sowie die drei Qualitätsattribute.

Da mit der Zentrierung die Lage einer Kachel verloren geht, hält eine Begleittabelle zu jeder Kachel den Bereich, den Block, den Ursprung in X und Y sowie Kantenlänge und Punktzahl fest. Über sie lässt sich jeder vorhergesagte Punkt in absolute Koordinaten zurückrechnen, was sowohl für das Auflösen der Überlappung als auch für die spätere Rasterisierung des Verbuschungsgrades gebraucht wird.

4.2.8 Räumlich getrennte Datenaufteilung

Bevor trainiert werden kann, muss der Kacheldatensatz in drei Teile zerlegt werden. Der Trainingsteil enthält die meisten Kacheln und dient der Optimierung der Netzgewichte.

Während des Trainings wird mit dem Validierungsteil beurteilt, welcher Zwischenstand des trainierten Modells der beste ist, ohne dass das Netz seine Gewichte an diesen Kacheln anpasst. Der Testteil bleibt bis zum Schluss unberührt und liefert am Ende die Kennzahlen für die endgültige Bewertung. Sinn dieser Trennung ist, dass die Bewertung auf Daten beruht, die das Netz nie gesehen hat. Ohne sie ließe sich nicht unterscheiden, ob es die Vegetationsklassen tatsächlich erkennt oder die Trainingskacheln nur auswendig gelernt hat.

Die Kacheln zufällig auf die drei Teile zu verteilen wäre in diesem Fall die falsche Herangehensweise. Wegen der 50-prozentigen Überlappung enthalten zwei benachbarte Kacheln zur Hälfte dieselben Punkte. Landet nun die eine im Training und die andere in der Validierung, wird das Netz an Punkten geprüft, mit denen es trainiert wurde, und die gemessene Güte fiel zu optimistisch aus.

Auf Grund dessen werden nicht einzelne Kacheln, sondern räumlich voneinander getrennte Blöcke auf die drei Teile verteilt. Alle Kacheln eines Blocks gehen geschlossen in denselben Teil, sodass keine Überlappung eine Grenze überschreiten kann. Die isoliert liegenden Teilflächen bilden jeweils einen eigenen Block, wohingegen die Schneise I als großes, zusammenhängendes Gebiet in drei Blöcke aufgeteilt wird, zwischen denen jeweils ein zehn Meter breiter Streifen frei bleibt, sodass kein Fenster über eine Blockgrenze reichen kann. Ohne diese Aufteilung fiel der gesamte Landschaftstyp der Schneise I in einen einzigen Teil, sodass das Netz auf ihm entweder nicht trainiert oder nicht geprüft würde.

Welchem Block eine Kachel angehört, steht in ihrem Dateinamen, sodass die Zuordnung ohne Rückgriff auf die Koordinaten erfolgen kann. Ein eigenes Skript liest diese Angabe aus und verteilt die Blöcke der Größe nach, beginnend beim größten. Jeder Block geht in den Teil, dem im Verhältnis zu seiner angestrebten Größe noch die meisten Kacheln fehlen. Ziel ist eine Aufteilung von 70 zu 15 zu 15 Prozent, die sich nur annähern lässt, weil immer ganze Blöcke vergeben werden. Von den 3.017 Kacheln entfallen am Ende 2.094 auf das Training, 455 auf die Validierung und 468 auf den Test, was 69, 15 und 16 Prozent entspricht. Beide Untersuchungsgebiete, der Authausener Wald und die Cuxhavener Küstenheide, sind in allen drei Teilen vertreten, sodass keiner der beiden Landschaftstypen ausschließlich im Training oder ausschließlich im Test vorkommt.

4.3 Datenorganisation und Versionsverwaltung

Der gesamte Programmcode dieser Arbeit liegt in einem privaten GitHub-Repository, die Daten liegen hingegen bewusst außerhalb davon. Die drei Rohpunktwolken belegen

zusammen mehrere Gigabyte. Allein die Cuxhavener Wolke ist rund fünf Gigabyte groß und eine Versionsverwaltung wie Git ist auf zeilenweise vergleichbare Textdateien ausgelegt und nicht auf binäre Dateien dieser Größenordnung. Versioniert wird deshalb ausschließlich der Programmcode. Trainingsartefakte, also Modellgewichte und Protokolldateien, die bei jedem Lauf neu entstehen und sich aus Code und Daten jederzeit reproduzieren lassen, sind über `.gitignore` ausgeschlossen.

Innerhalb des Datenverzeichnisses folgt die Ablage der Dateien dem Bearbeitungsstand. Unter `raw` liegen die unveränderten Punktwolken und Orthophotos, unter `labeling` die Flächen, an denen noch annotiert wird, und unter `labeled` die abgeschlossenen Annotationen. Alles daraus Abgeleitete sammelt sich in `processed`. Ältere Zwischenstände wandern in ein Archivverzeichnis, statt überschrieben zu werden. Das Repository selbst enthält sowohl die R-Skripte der Vorverarbeitung als auch den Python-Code für Training und Auswertung.

Eine zweite Ebene der Versionierung betrifft die exportierten Kacheln. Jede Änderung am R-Export schreibt in ein neues, durchnummeriertes Verzeichnis, sodass mehrere Exportstände nebeneinander bestehen bleiben. Notwendig wird das durch die Ablationsstudie, deren Läufe auf unterschiedlichen Exporten beruhen. Ohne die älteren Stände ließen sich frühere Läufe weder nachvollziehen noch erneut auswerten, was für die nachträgliche Vereinheitlichung der Testmenge erforderlich war (Abschnitt 4.5).

Als Grundlage des Modellcodes dient die frei verfügbare PyTorch-Implementierung von PointNet und PointNet++ von Yan [30], die unter der MIT-Lizenz steht. Sie wurde unverändert als eigener Commit in das Repository übernommen, bevor die erste eigene Zeile entstand. Jeder spätere Vergleich mit diesem Stand zeigt deshalb genau, welche Änderungen im Rahmen dieser Arbeit vorgenommen wurden, was sich bei einer Fremdimplementierung sonst nur schwer belegen ließe. Neue Arbeitsschritte entstanden jeweils auf einem eigenen Entwicklungszweig und gingen erst nach erfolgreicher Erprobung in den Hauptzweig ein.

Für die Ausführung wurde eine eigene Conda-Umgebung mit Python 3.9 angelegt, getrennt von den vorhandenen Installationen für R und QGIS, damit sich die Abhängigkeiten nicht gegenseitig verdrängen. Das Training selbst lief nicht lokal, sondern auf einer CUDA-fähigen Grafikkarte im JupyterHub der Universität. Der verwendete Arbeitsrechner besitzt keine für PyTorch nutzbare Grafikkarte, sodass bereits die ersten Versuche zeigten, dass eine Berechnung auf dem Prozessor durch thermisches Drosseln unbrauchbar instabil wird (Abschnitt 4.5).

4.4 Modell und Trainingssetup

4.4.1 Architektur

Als Netz kommt PointNet++ in der Variante für semantische Segmentierung zum Einsatz, deren Aufbau in Abschnitt 2.4.3 beschrieben ist [24]. Ausschlaggebend für die Wahl war, dass es Punktwolken unmittelbar verarbeitet und die Höhenstruktur des Bestandes dabei erhalten bleibt, während zweidimensionale Verfahren die dritte Dimension auf ein Rasterbild projizieren müssen. Genau diese Struktur unterscheidet einen Busch von einem gleich hohen Heidebestand.

Die Umsetzung folgt der Referenzimplementierung von Yan [30]. Das Netz betrachtet eine Kachel in vier Set-Abstraction-Stufen mit jeweils größerem Blickfeld. In der ersten Stufe wählt es 1.024 Punkte als Zentren aus und beschreibt jedes davon anhand von bis zu 32 Nachbarn im Umkreis von 0,1 Metern, wodurch feine Textur erfasst wird. Über die folgenden Stufen sinkt die Zahl der Zentren auf 256, 64 und schließlich auf 16, während der Umkreis auf 0,2, 0,4 und 0,8 Meter wächst. Die Szene wird dadurch von Stufe zu Stufe gröber betrachtet, dafür aber im größeren Zusammenhang. Vier Feature-Propagation-Stufen verteilen die so gewonnenen Beschreibungen anschließend wieder auf alle Punkte, sodass am Ende jeder einzelne Punkt einen Wert je Klasse erhält. Eine Dropout-Schicht mit einer Rate von 0,5 schaltet während des Trainings zufällig die Hälfte der Merkmale ab und wirkt damit der Überanpassung entgegen. Eingabekanäle, Nachbarschaftsradien und die Zahl der Radien je Stufe sind umschaltbar und gehören zu den Faktoren, die in Abschnitt 4.5 variiert werden.

4.4.2 Verlustfunktion

Was ein Netz lernt, steuert die Verlustfunktion (loss function). Sie misst, wie weit die Vorhersage vom Label abweicht, und genau dieser Wert wird beim Training möglichst klein gemacht. Zwei Eigenschaften der Trainingsdaten machen an dieser Stelle einen Eingriff nötig.

Die erste ist das Klassenungleichgewicht (class imbalance). Bäume und Heide stellen zusammen den weit überwiegenden Teil der Punkte, `deadwood` und `soil` kommen dagegen nur vereinzelt vor. Ein Netz kann den Fehler am einfachsten senken, indem es die seltenen Klassen gar nicht erst vorhersagt. Um dem entgegenzuwirken, geht jede Klasse mit einem eigenen Klassengewicht in den Verlust ein. Es fällt umso größer aus, je seltener die Klasse ist, und berechnet sich aus dem Kehrwert der Wurzel ihrer Häufigkeit. Die Wurzel

schwächt den Ausgleich bewusst ab. Ohne sie bekämen die seltensten Klassen ein so hohes Gewicht, dass das Training instabil wird.

Die zweite Eigenschaft ist die unterschiedliche Verlässlichkeit der Labels. Nicht jedes annotierte Segment war im Luftbild gleich gut zu erkennen. Aus den drei Qualitätsattributen wird deshalb je Punkt ein zusätzliches Gewicht zwischen 0,05 und 1,0 berechnet. Ausgangswert ist die Sicherheit der Annotation, geteilt durch zehn. Liegt der Punkt im Schatten oder ist er überbelichtet, wird dieser Wert jeweils mit 0,3 multipliziert. Unsichere und schlecht sichtbare Punkte tragen dadurch weniger zum Verlust bei, fallen aber nicht vollständig heraus.

Beide Gewichtungen wirken zusammen, indem für jeden Punkt zunächst der klassengewichtete Fehler bestimmt wird und anschließend diese Werte mit den Punktgewichten gemittelt werden. Die Qualitätsattribute sind damit kein Eingabemerkmale des Netzes, sondern steuern nur, wie stark ein Punkt beim Lernen zählt.

4.4.3 Training

Die Trainingsparameter bleiben über alle Läufe unverändert, damit Unterschiede zwischen ihnen allein auf den jeweils geänderten Faktor zurückgehen. Optimiert wird mit dem Adam-Verfahren [31], das auch die Referenzimplementierung verwendet. Die Lernrate beginnt bei 0,001 und fällt alle zehn Epochen auf 70 Prozent ihres Wertes, sodass das Netz zunächst grob und gegen Ende fein nachjustiert. Hinzu kommt ein Gewichtsverfall (weight decay) von 0,0001. Das Training läuft über 64 Epochen in Stapeln (batches) von 32 Kacheln, wobei es ab run08 nur noch 16 sind, weil die verdoppelte Punktzahl je Kachel den Speicherbedarf entsprechend erhöht.

Neben der Überlappung der Kacheln (Abschnitt 4.2.7) kommt während des Trainings eine zweite Form der Datenerweiterung hinzu. Jede Kachel wird vor der Verarbeitung um die Z-Achse um einen zufälligen Winkel gedreht, und auf ihre Koordinaten wird ein Rauschen mit einer Standardabweichung von einem Zentimeter, begrenzt auf fünf Zentimeter, hinzugerechnet. Die Drehung ist fachlich begründet, denn in welche Himmelsrichtung eine Kachel zeigt, sagt nichts über die Vegetation darin aus. Das Rauschen macht das Netz unempfindlicher gegen die Ungenauigkeiten der photogrammetrischen Rekonstruktion.

Gespeichert wird der Zwischenstand mit der höchsten mittleren IoU auf dem Validierungsteil. Als Kriterium dient bewusst nicht der Verlust, sondern die mittlere IoU, weil sie alle Klassen gleich gewichtet und damit derselben Größe folgt, an der die Ergebnisse später gemessen werden.

4.5 Ablationsstudie

Der Studie ging eine Sondierungsphase voraus, in der drei Läufe auf einer kleineren Datenbasis mit sechs annotierten Teilflächen entstanden. Aus ihr stammen die Kachelparameter, die Wahl der Architektur und die Gewichtung der Punkte über die Qualitätsattribute. Nach der Erweiterung auf 16 Teilflächen wurden alle Läufe neu und ohne Warmstart gerechnet, sodass die Vorläufe auf einer anderen Datengrundlage beruhen und nicht berichtet werden.

Für die eigentliche Studie gilt durchgehend derselbe Grundsatz: Gegenüber seinem Vergleichslauf ändert jeder Lauf genau einen Faktor, alles Übrige bleibt gleich. Trainiert wird jedes Mal von Grund auf, statt auf einem vorhandenen Modell aufzusetzen, denn nur so lässt sich eine Veränderung dem geänderten Faktor zuordnen. Möglich wird dieses Vorgehen dadurch, dass sich Klassenschema und Nachbarschaftsradien über Umgebungsvariablen umstellen lassen und die Zahl der Eingabemerkmale aus der Spaltenzahl der Kacheldateien abgeleitet wird. Trainings- und Auswertungsskript bleiben für alle Varianten unverändert und ein Protokoll hält fest, welche Einstellungen ein Lauf verwendet hat. Streng eingehalten wird das bei allen Läufen außer run08. Dort zieht die verdoppelte Punktzahl je Kachel zwei weitere Änderungen nach sich, nämlich eine halbierte Stapelgröße und den Wegfall des Auffüllens unvollständiger Fenster.

Tabelle 1: Übersicht der Ablationsläufe mit dem jeweils geänderten Faktor und dem Lauf, gegen den verglichen wird. [Eigene Darstellung].

Lauf	Geänderter Faktor	Vergleich
run01	Ausgangskonfiguration mit acht Klassen und sechs Kanälen	
run02	Nahinfrarot als siebter Kanal	run01
run03	Focal Loss statt gewichtetem Verlust	run02
run04	Reduktion auf sechs Klassen	run02
run05	Zwei lokale Höhenmerkmale als achter und neunter Kanal	run04
run06	Reduktion auf zwei Klassen, Gehölz gegen Rest	run05
run07	Nachbarschaftsradien um Faktor 2,5 vergrößert	run05
run08	8.192 statt 4.096 Punkte je Kachel	run07
run09	Zwei Radien je Stufe (multi-scale grouping)	run08

Wie Tabelle 1 zeigt, greifen die neun Läufe an vier Stellen an. Zwei erweitern die Merkmale je Punkt, einer verändert die Verlustfunktion, zwei vereinfachen das Klassenschema, und die letzten drei verändern die Geometrie der Nachbarschaftssuche im Netz. Zu dieser letzten Gruppe kam es erst durch eine Zwischenauswertung. Nachdem mehrere Änderungen an Merkmalen und Verlustfunktion ohne Wirkung geblieben waren, wurde geprüft, ob die Nachbarschaftsparameter des Netzes überhaupt zur Punktdichte der Daten passen. Die

Radien der Referenzimplementierung sind auf den Innenraumdatensatz S3DIS abgestimmt, dessen Blöcke einen Meter Kantenlänge haben und ebenfalls 4.096 Punkte enthalten. Auf Kacheln von zehn Metern übertragen findet die erste Set-Abstraction-Stufe bei einem Radius von 0,1 Metern im Median nur einen einzigen Punkt, nämlich ihr eigenes Zentrum, und lernt dort folglich nichts. Daraus ergaben sich die Wege, entweder die Radien zu vergrößern oder die Punktzahl je Kachel zu erhöhen.

Eine Einschränkung des Vergleichs ergibt sich aus dem Export für run08. Mit ihm änderten sich nicht nur die Trainings-, sondern auch die Testkacheln. Randfenster mit zu wenigen Punkten wurden bis dahin durch Kopien vorhandener Punkte aufgefüllt und blieben so erhalten, nun werden sie verworfen. Übrig bleiben dadurch 468 statt 487 Testkacheln. Da Läufe auf unterschiedlichen Testmengen nicht vergleichbar sind, wurden run05 bis run07 nachträglich gegen die neue Testmenge ausgewertet. Möglich ist das ohne Neutraining, weil PointNet++ beliebige Punktzahlen verarbeitet und diese drei Läufe, wie run08 und run09, mit neun Eingabekanälen arbeiten. Berichtet werden sie deshalb alle auf derselben Grundlage. Für run01 bis run04 gilt das nicht, denn sie verwenden sechs oder sieben Kanäle und lassen sich auf den neuen Kacheln nicht auswerten. Sie bilden eine eigene Tabelle mit der ursprünglichen Testmenge.

4.6 Evaluation

Bewertet wird jeder Lauf auf dem Testteil, der bis dahin unberührt geblieben ist. Ein eigenes Skript sammelt die Vorhersagen über alle Testkacheln in einer gemeinsamen Konfusionsmatrix und leitet daraus die in Abschnitt 2.5 definierten Kennzahlen ab, also Genauigkeit und IoU je Klasse sowie Gesamtgenauigkeit und mittlere IoU. Ergänzend gibt es die zehn häufigsten Verwechslungen aus, woran sich ablesen lässt, zwischen welchen Klassen die Fehler tatsächlich auftreten.

Für die Fragestellung reicht die mittlere IoU allerdings nicht aus. Sie mittelt über alle Klassen und ist deshalb zwischen Läufen mit acht, sechs oder zwei Klassen nicht vergleichbar. Zusätzlich werden die Vorhersagen jedes Modells nachträglich zu Gehölz, also `bush` und `tree`, sowie dem Rest zusammengefasst und für diese Zweiteilung IoU, Precision, Recall und F1-Score berechnet. Diese Größe hängt nicht vom trainierten Klassenschema ab und entspricht unmittelbar dem, was für den Verbuschungsgrad gebraucht wird. Zugleich ist sie der Maßstab, an dem sich der binäre Lauf messen lassen muss. Die Gehölzklasse lässt sich nämlich auf zwei Wegen gewinnen, entweder durch ein eigens auf zwei Klassen trainiertes Modell oder durch nachträgliches Zusammenfassen der Vorhersagen eines

Mehrklassenmodells. Der zweite Weg verursacht keinen zusätzlichen Aufwand, sodass sich ein eigens binär trainiertes Modell nur rechtfertigt, wenn es besser abschneidet.

Zu jedem Lauf entsteht ein Protokoll mit Konfusionsmatrix, Kennzahlen je Klasse und der Zusammenfassung Gehölz gegen Rest, sodass sich die Läufe im Nachhinein ohne erneute Berechnung gegenüberstellen lassen.

4.7 Quantifizierung des Verbuschungsgrades

5 Fazit und Diskussion

5.1 Evaluation der semantischen Segmentierung

5.1.1 Gesamtmetriken

5.1.2 Klassenweise Auswertung

5.1.3 Konfusionsmatrix

5.2 Fehleranalyse

5.2.1 Einfluss des Klassenungleichgewichts

5.2.2 Kritische Verwechslungen

5.3 Quantifizierung des Verbuschungsgrades

5.4 Vergleich mit dem 2D-Ansatz

5.5 Diskussion

5.6 Fazit

6 Ausblick und Einordnung in den Gesamtkontext

Anhang

Anhang 1: Beispielanhang

Dieser Abschnitt dient nur dazu zu demonstrieren, wie ein Anhang aufgebaut sein kann.

Anhang 1.1: Weitere Gliederungsebene

Auch eine zweite Gliederungsebene ist möglich.

Anhang 2: Bilder

Auch mit Bildern. Diese tauchen nicht im Abbildungsverzeichnis auf.

Name	Änderungsdatum	Typ	Größe
 abbildungen	29.08.2013 01:25	Dateiordner	
 kapitel	29.08.2013 00:55	Dateiordner	
 literatur	31.08.2013 18:17	Dateiordner	
 skripte	01.09.2013 00:10	Dateiordner	
 compile.bat	31.08.2013 20:11	Windows-Batchda...	1 KB
 thesis_main.tex	01.09.2013 00:25	LaTeX Document	5 KB

Abbildung 8: Beispielbild

Literaturverzeichnis

- [1] W. D. Kissling, Y. Shi, J. Wang, A. Walicka, C. George, J. E. Moeslund und F. Gerard, „Towards consistently measuring and monitoring habitat condition with airborne laser scanning and unmanned aerial vehicles,“ *Ecological Indicators*, Jg. 169, S. 112970, 2024. DOI: 10.1016/j.ecolind.2024.112970
- [2] J. Gonçalves, R. Henriques, P. Alves, R. Sousa-Silva, A. T. Monteiro, Â. Lomba, B. Marcos und J. Honrado, „Evaluating an unmanned aerial vehicle-based approach for assessing habitat extent and condition in fine-scale early successional mountain mosaics,“ *Applied Vegetation Science*, Jg. 19, Nr. 1, S. 132–146, 2016. DOI: 10.1111/avsc.12204
- [3] J. Schmidt, F. E. Fassnacht, C. Neff, A. Lausch, B. Kleinschmit, M. Förster und S. Schmidtlein, „Adapting a Natura 2000 field guideline for a remote sensing-based assessment of heathland conservation status,“ *International Journal of Applied Earth Observation and Geoinformation*, Jg. 60, S. 61–71, 2017. DOI: 10.1016/j.jag.2017.04.005
- [4] I. Eischeid, E. M. Soininen, J. J. Assmann, R. A. Ims, J. Madsen, Å. Ø. Pedersen, F. Pirotti, N. G. Yoccoz und V. T. Ravolainen, „Disturbance Mapping in Arctic Tundra Improved by a Planning Workflow for Drone Studies: Advancing Tools for Future Ecosystem Monitoring,“ *Remote Sensing*, Jg. 13, Nr. 21, S. 4466, 2021. DOI: 10.3390/rs13214466
- [5] J. Cao, W. Leng, K. Liu, L. Liu, Z. He und Y. Zhu, „Object-Based Mangrove Species Classification Using Unmanned Aerial Vehicle Hyperspectral Images and Digital Surface Models,“ *Remote Sensing*, Jg. 10, Nr. 1, S. 89, 2018. DOI: 10.3390/rs10010089
- [6] T. Yun, J. Li, L. Ma, J. Zhou, R. Wang, M. P. Eichhorn und H. Zhang, „Status, advancements and prospects of deep learning methods applied in forest studies,“ *International Journal of Applied Earth Observation and Geoinformation*, Jg. 131, S. 103938, 2024. DOI: 10.1016/j.jag.2024.103938
- [8] T. Schoknecht, *Trockenrasen und Heiden: Hinweise zur Biotop- und Landschaftspflege*, Deutscher Verband für Landschaftspflege (DVL) und Landesumweltamt Brandenburg, Potsdam, 1998.
- [9] N. R. Webb, „The traditional management of European heathlands,“ *Journal of Applied Ecology*, Jg. 35, Nr. 6, S. 987–990, 1998. DOI: 10.1111/j.1365-2664.1998.tb00020.x
- [10] R. Bobbink, K. Hicks, J. Galloway, T. Spranger, R. Alkemade, M. Ashmore, M. Bustamante, S. Cinderby, E. Davidson, F. Dentener, B. Emmett, J.-W. Erisman, M. Fenn, F. Gilliam, A. Nordin, L. Pardo und W. de Vries, „Global assessment of nitrogen deposition effects on terrestrial plant diversity: a synthesis,“ *Ecological Applications*, Jg. 20, Nr. 1, S. 30–59, 2010. DOI: 10.1890/08-1140.1

-
- [11] U. Friedrich, G. von Oheimb, C. Dzedek, W.-U. Kriebitzsch, K. Selbmann und W. Härdtle, „Mechanisms of purple moor-grass (*Molinia caerulea*) encroachment in dry heathland ecosystems with chronic nitrogen inputs,” *Environmental Pollution*, Jg. 159, Nr. 12, S. 3553–3559, 2011. DOI: 10.1016/j.envpol.2011.08.010
 - [12] M. Niemeyer, T. Niemeyer, S. Fottner, W. Härdtle und A. Mohamed, „Impact of sod-cutting and choppering on nutrient budgets of dry heathlands,” *Biological Conservation*, Jg. 134, Nr. 3, S. 344–353, 2007. DOI: 10.1016/j.biocon.2006.07.013
 - [13] J. P. Bakker, S. de Bie, J. H. Dallinga, P. Tjaden und Y. de Vries, „Sheep-grazing as a management tool for heathland conservation and regeneration in the Netherlands,” *Journal of Applied Ecology*, Jg. 20, Nr. 2, S. 541–560, 1983. DOI: 10.2307/2403525
 - [14] R. Rosa García, R. Celaya, U. García und K. Osoro, „Grazing land management and biodiversity in the Atlantic European heathlands: a review,” *Agroforestry Systems*, Jg. 87, Nr. 1, S. 19–43, 2013. DOI: 10.1007/s10457-012-9519-3
 - [15] W. Härdtle, G. von Oheimb, A.-K. Gerke, M. Niemeyer, T. Niemeyer, T. Assmann, C. Drees, A. Matern und H. Meyer, „Shifts in N and P budgets of heathland ecosystems: effects of management and atmospheric inputs,” *Ecosystems*, Jg. 12, Nr. 2, S. 298–310, 2009. DOI: 10.1007/s10021-008-9223-3
 - [16] A. Mohamed, W. Härdtle, B. Jirjahn, T. Niemeyer und G. von Oheimb, „Effects of prescribed burning on plant available nutrients in dry heathland ecosystems,” *Plant Ecology*, Jg. 189, Nr. 2, S. 279–289, 2007. DOI: 10.1007/s11258-006-9183-7
 - [17] M. J. Westoby, J. Brasington, N. F. Glasser, M. J. Hambrey und J. M. Reynolds, „‘Structure-from-Motion’ photogrammetry: A low-cost, effective tool for geoscience applications,” *Geomorphology*, Jg. 179, S. 300–314, 2012. DOI: 10.1016/j.geomorph.2012.08.021
 - [18] J. L. Schönberger und J.-M. Frahm, „Structure-from-Motion Revisited,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, S. 4104–4113. DOI: 10.1109/CVPR.2016.445
 - [19] J. L. Schönberger, E. Zheng, M. Pollefeys und J.-M. Frahm, „Pixelwise View Selection for Unstructured Multi-View Stereo,” in *Computer Vision – ECCV 2016*, Ser. Lecture Notes in Computer Science, Bd. 9907, Springer, 2016, S. 501–518. DOI: 10.1007/978-3-319-46487-9_31
 - [20] Y. LeCun, Y. Bengio und G. Hinton, „Deep learning,” *Nature*, Jg. 521, Nr. 7553, S. 436–444, 2015. DOI: 10.1038/nature14539
 - [21] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam und P. Vandergheynst, „Geometric deep learning: going beyond Euclidean data,” *IEEE Signal Processing Magazine*, Jg. 34, Nr. 4, S. 18–42, 2017. DOI: 10.1109/MSP.2017.2693418
 - [22] C. R. Qi, H. Su, K. Mo und L. J. Guibas, „PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, S. 652–660. DOI: 10.1109/CVPR.2017.16
 - [23] A. Diab, R. Kashef und A. Shaker, „Deep Learning for LiDAR Point Cloud Classification in Remote Sensing,” *Sensors*, Jg. 22, Nr. 20, S. 7868, 2022. DOI: 10.3390/s22207868

- [24] C. R. Qi, L. Yi, H. Su und L. J. Guibas, „PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space,“ in *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 2017, S. 5099–5108.
- [25] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz, *Statistik: Der Weg zur Datenanalyse*, 9. Aufl. Berlin, Heidelberg: Springer Spektrum, 2023, ISBN: 978-3-662-67525-0. DOI: 10.1007/978-3-662-67526-7
- [26] J.-R. Roussel, D. Auty, N. C. Coops, P. Tompalski, T. R. H. Goodbody, A. Sánchez Meador, J.-F. Bourdon, F. de Boissieu und A. Achim, „lidR: An R package for analysis of Airborne Laser Scanning (ALS) data,“ *Remote Sensing of Environment*, Jg. 251, S. 112 061, 2020. DOI: 10.1016/j.rse.2020.112061
- [27] E. Pebesma, „Simple Features for R: Standardized Support for Spatial Vector Data,“ *The R Journal*, Jg. 10, Nr. 1, S. 439–446, 2018. DOI: 10.32614/RJ-2018-009
- [28] R. J. Hijmans, *terra: Spatial Data Analysis*, R package version 1.8-86, 2025. DOI: 10.32614/CRAN.package.terra Adresse: <https://CRAN.R-project.org/package=terra>
- [29] W. Zhang, J. Qi, P. Wan, H. Wang, D. Xie, X. Wang und G. Yan, „An Easy-to-Use Airborne LiDAR Data Filtering Method Based on Cloth Simulation,“ *Remote Sensing*, Jg. 8, Nr. 6, S. 501, 2016. DOI: 10.3390/rs8060501
- [31] D. P. Kingma und J. L. Ba, „Adam: A Method for Stochastic Optimization,“ in *3rd International Conference on Learning Representations (ICLR)*, San Diego, CA, USA, 2015. arXiv: 1412.6980.

Internetquellen

- [7] Rat der Europäischen Gemeinschaften. „Richtlinie 92/43/EWG des Rates vom 21. Mai 1992 zur Erhaltung der natürlichen Lebensräume sowie der wildlebenden Tiere und Pflanzen,“ besucht am 2026-07-01. Adresse: <https://eur-lex.europa.eu/legal-content/DE/TXT/?uri=CELEX:31992L0043>
- [30] X. Yan. „Pointnet/Pointnet++ Pytorch,“ besucht am 2026-08-04. Adresse: https://github.com/yanx27/Pointnet_Pointnet2_pytorch

Eigenständigkeitserklärung

Hiermit versichere ich, dass ich die angemeldete Prüfungsleistung in allen Teilen eigenständig ohne Hilfe von Dritten anfertigen und keine anderen als die in der Prüfungsleistung angegebenen Quellen und zugelassenen Hilfsmittel verwenden werde. Sämtliche wörtlichen und sinngemäßen Übernahmen inklusive KI-generierter Inhalte werde ich kenntlich machen.

Diese Prüfungsleistung hat zum Zeitpunkt der Abgabe weder in gleicher noch in ähnlicher Form, auch nicht auszugsweise, bereits einer Prüfungsbehörde zur Prüfung vorgelegen; hiervon ausgenommen sind Prüfungsleistungen, für die in der Modulbeschreibung ausdrücklich andere Regelungen festgelegt sind.

Mir ist bekannt, dass die Zuwiderhandlung gegen den Inhalt dieser Erklärung einen Täuschungsversuch darstellt, der das Nichtbestehen der Prüfung zur Folge hat und daneben strafrechtlich gem. § 156 StGB verfolgt werden kann. Darüber hinaus ist mir bekannt, dass ich bei schwerwiegender Täuschung exmatrikuliert und mit einer Geldbuße bis zu 50.000 EUR nach der für mich gültigen Rahmenprüfungsordnung belegt werden kann.

Ich erkläre mich damit einverstanden, dass diese Prüfungsleistung zwecks Plagiatsprüfung auf die Server externer Anbieter hochgeladen werden darf. Die Plagiatsprüfung stellt keine Zurverfügungstellung für die Öffentlichkeit dar.

Münster, 6.8.2026

(Ort, Datum)

A handwritten signature in black ink, consisting of a large, stylized 'H' followed by a series of loops and a final horizontal stroke.

(Eigenhändige Unterschrift)