



Universität Münster
Hochschulzentrum Münster

Bachelor Thesis

im Studiengang Geoonformatik

zur Erlangung des Grades eines
Bachelor of Science (B.Sc.)

über das Thema

LATEX-Vorlage - mit Biblatex

von

Luis Waldeyer

Betreuer : Dr. Torsten Prinz
Matrikelnummer : 545669
Abgabedatum : 18. Juli 2026

Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VI
Symbolverzeichnis	VII
1 Einleitung und Motivation	1
1.1 Aufbau der Arbeit	3
2 Theoretischer Hintergrund	5
2.1 Ökologischer Hintergrund	5
2.2 Structure from Motion	7
2.2.1 Allgemeines	7
2.2.2 Ablauf der Rekonstruktion	8
2.3 Convolutional Neural Networks (CNNs)	10
2.3.1 Allgemeines	10
2.3.2 Anwendung in der Fernerkundung	12
2.4 Geometric Deep Learning	13
2.4.1 Semantische Segmentierung von 3D-Punktwolken	14
2.4.2 Beispiel: PointNet	14
2.4.3 Beispiel: PointNet++	15
2.5 Evaluationsmetriken	16
2.5.1 Metriken der Segmentierung	16
2.5.2 Metriken des Verbuschungsgrades	17
3 Verwandte Arbeiten	19
4 Methodik	20
4.1 Untersuchungsgebiet	20
4.2 Datengrundlage	20
4.3 Annotation und Klassenschema	20
4.4 Datenvorverarbeitung	20
4.4.1 Label-Transfer und Qualitätssicherung	20
4.4.2 Tiling und Sampling	20

4.5	Modell und Training	20
4.5.1	PointNet++	20
4.5.2	Training	20
4.6	Quantifizierung des Verbuschungsgrades	20
4.6.1	Rasterisierung	20
5	Fazit und Diskussion	21
5.1	Evaluation der semantischen Segmentierung	21
5.1.1	Gesamtmetriken	21
5.1.2	Klassenweise Auswertung	21
5.1.3	Konfusionsmatrix	21
5.2	Fehleranalyse	21
5.2.1	Einfluss des Klassenungleichgewichts	21
5.2.2	Kritische Verwechslungen	21
5.3	Quantifizierung des Verbuschungsgrades	21
5.4	Vergleich mit dem 2D-Ansatz	21
5.5	Diskussion	21
5.6	Fazit	21
6	Ausblick und Einordnung in den Gesamtkontext	22
	Anhang	23
	Literaturverzeichnis	24

Abbildungsverzeichnis

Abbildung 1: Grundprinzip von Structure from Motion	8
Abbildung 2: Ablauf der inkrementellen SfM-Pipeline	9
Abbildung 3: Funktionsweise der Faltung	11
Abbildung 4: Aufbau eines CNN	12
Abbildung 5: Architektur von PointNet++	15

Tabellenverzeichnis

Abkürzungsverzeichnis

Symbolverzeichnis

1 Einleitung und Motivation

Der Schutz und Erhalt naturnaher Lebensräume ist eine zentrale Aufgabe des europäischen Naturschutzes. Allein das Natura-2000-Netzwerk umfasst rund 25.000 Schutzgebiete in den EU-Mitgliedsstaaten, deren Zustand regelmäßig erfasst und überwacht werden muss [1]. Indikatoren des Habitatzustands sind dabei unverzichtbar, um Fortschritte im Naturschutz nachzuvollziehen. Ihre Erhebung über große Flächen und in feiner Auflösung bleibt jedoch eine Herausforderung [1].

Klassischerweise erfolgt diese Vegetationskartierung durch Geländearbeit: Fachleute begehen die Flächen und erheben Daten manuell vor Ort. Da dieses Vorgehen sehr zeit- und kostenintensiv ist, können auf diese Weise meist nur kleine Flächen kartiert werden. An dieser Stelle setzen Methoden der Fernerkundung an. Insbesondere das Drohnen bzw. UAS-gestützte Monitoring liefert hochauflösende Daten und kann den Aufwand intensiver Geländekartierungen deutlich reduzieren, wobei Genauigkeiten erreicht werden, die klassische Verfahren der Luftbildinterpretation erreichen oder übertreffen [2].

Gerade für die Heideflächen wurde gezeigt, dass sich der Erhaltungszustand fernerkundlich bewerten lässt, sofern die Auswertung eng an die etablierten feldbasierten Kartierschemata angelehnt sind [3]. Allerdings besteht weiterhin eine deutliche Lücke zwischen den feldbasierten Monitoring-Richtlinien und den bestehenden fernerkundlichen Ansätzen, was deren praktische Anwendung erschwert [3]. Der entscheidende Haken klassischer Fernerkundung liegt zudem darin, dass die erhobenen Daten wiederum manuell von Fachleuten ausgewertet werden müssen, was erneut sehr zeitaufwendig ist. Genau hier wird der Einsatz künstlicher Intelligenz interessant, da sie die Auswertung der Fernerkundungsdaten automatisieren kann.

Die Anwendung von Machine-Learning-Verfahren in der Fernerkundung ist seit Jahren etabliert. Klassische Algorithmen wie Random Forest (RF) werden vor allem zur Klassifizierung der Bodenbedeckung eingesetzt. Eischeid et al. (2021) [4] nutzten beispielsweise einen überwachten RF-Klassifikator, um aus Drohnenbildern die Vegetation arktischer Tundra zu kartieren. Auch Support Vector Machines (SVMs) finden Anwendung, etwa bei Cao et al. (2018) [5] zur objektbasierten Klassifizierung von Mangrovenarten aus hochauflösenden UAV-Hyperspektraldaten.

Einen entscheidenden Fortschritt brachte die Einführung von Deep Learning und insbesondere von Convolutional Neural Networks (CNNs), die die Objekterkennung und damit das Habitatmonitoring deutlich verbessert haben [6].

Der wesentliche Vorteil gegenüber klassischen Verfahren liegt darin, dass CNNs die entscheidenden Merkmale automatisch aus komplexen, hochdimensionalen Rohdaten lernen, während klassische Algorithmen auf eine manuelle Merkmalsextraktion angewiesen sind und bei unregelmäßigen oder komplexen Datenmengen schnell an ihre Grenzen stoßen. Eine ausführliche Gegenüberstellung der Ansätze sowie verschiedene CNN-Architekturen erfolgt in Kapitel 2 (Theoretischer Hintergrund).

Aus den genannten Gründen ist es nicht verwunderlich, dass aktuelle Projekte im Bereich des Habitat-Qualitätsmonitorings auf Deep Learning zurückgreifen. So auch das Projekt des Instituts für Landschaftsökologie der Universität Münster: "Ready for Take-Off?! How to integrate UAS remote sensing into the monitoring of EU habitats directive sites?". Dort wird untersucht, wie sich UAS-basierte Fernerkundung in das Monitoring von FFH-Gebieten integrieren lässt, gerade weil UAS deutlich hochauflösendere Daten liefern als Satellitenbilder und flexibler einsetzbar sind. Die zugrunde liegende Flora-Fauna-Habitat-Richtlinie bildet innerhalb des Natura-2000-Netzwerks das Rückgrat des europäischen Naturschutzes [7] und definiert damit die Schutzgebiete, deren Erhaltungszustand im Projekt erfasst werden soll.

Neben der Habitatstruktur (etwa *Calluna*-Lebenszyklusphasen oder Sandanteil) und dem Arteninventar sollen dabei vor allem Degradationsindikatoren wie der Deckungsgrad invasiver Neophyten, von Gras, Gehölzen und die Verbuschung ermittelt werden, da diese sich kritisch auf den Erhaltungszustand von Heideflächen auswirken. Heideflächen sind nährstoffarme Halbkulturbiotope, die erst durch menschliche Nutzung entstanden sind. Bleibt diese Nutzung aus oder werden die Standorte durch Eutrophierung mit Nährstoffen angereichert, setzt natürliche Sukzession ein, bei der Gräser und Gehölze aufkommen und die Zwergstrauchheide durch Nährstoffentzug und die Beschattung zunehmend überwuchern [8]. Die Verbuschung ist daher ein zentraler Degradationsindikator für den Erhaltungszustand von Heideflächen. Da die früheren Nutzungsformen weggefallen sind, lassen sich diese Flächen heute nur durch aufwändige Pflegemaßnahmen offenhalten. Um solche Maßnahmen gezielt planen und ihren Erfolg überprüfen zu können, muss der Verbuschungsgrad objektiv, flächendeckend und reproduzierbar erfasst werden.

Dazu wurden mehrere Flächen mehrfach mit einer Drohne befliegen, um hochauflösende RGB-Bilder zu erhalten und aus den überlappenden 2D-Aufnahmen mittels Structure from Motion einen 3D-Datensatz abzuleiten - ein Verfahren, das aus mehreren überlappenden 2D-Bildern eine dreidimensionale Punktwolke der aufgenommenen Fläche rekonstruiert. Diese Daten dienen als Ausgangspunkt für ein Deep-Learning-Modell, das die einzelnen Vegetationsarten segmentiert und jeweils einer Klasse zuordnet, woraus sich anschließend ein Verbuschungsgrad berechnen lässt.

Da nun zwei Arten von Datensätzen vorliegen, ergibt sich daraus eine zentrale Frage. Welcher Datensatz eignet sich besser zur Segmentierung der Vegetationsarten und damit zur Berechnung des Verbuschungsgrades - die RGB-Bilder oder die SfM-Punktwolken? Beide Ansätze nutzen Deep Learning, für die 2D-Daten das CNN U-Net und für den 3D-Ansatz PointNet++, das eigens auf unstrukturierten 3D-Punktmengen spezialisiert ist. Aufgabe dieser Arbeit ist es, den 3D-Ansatz zu entwickeln, zu testen und zu evaluieren und sein Ergebnis mit dem 2D-Ansatz zu vergleichen, um herauszufinden, welcher Datensatz sich besser für die Segmentierung der Vegetationsarten und damit für die Erfassung des Verbuschungsgrades eignet.

Daraus ergeben sich zwei Forschungsfragen (FF) mit jeweils einer untergeordneten Teilfrage (TF), die den Weg von der Datenaufbereitung über die Segmentierung bis zur praktischen Nutzung abbilden:

FF1: Inwiefern unterscheidet sich die semantische Segmentierung von 3D-SfM-Punktwolken mittels Deep Learning von einem vergleichbaren 2D-Deep-Learning-Ansatz, sowohl quantitativ als auch qualitativ, bei der Erfassung der Verbuschung von Heideflächen?

TF1: Inwiefern lässt sich ein automatisierter Label-Transfer von 2D-Referenzdaten auf 3D-Punktwolken realisieren, um den Trainingsaufwand für tiefe neuronale Netze effizient zu gestalten?

FF2: Inwiefern unterscheidet sich die aus der 3D-Punktwolken-Segmentierung abgeleitete Rasterisierung des Verbuschungsgrades in ihrer Genauigkeit von der aus dem 2D-RGB-Ansatz abgeleiteten Rasterisierung?

TF2: Wie stabil und anwenderfreundlich lässt sich das entwickelte Modell in eine bestehende GIS-Umgebung integrieren, um für Naturschutzpraktiker nutzbar zu sein?

Das übergeordnete Ziel ist schließlich ein vollständiger Workflow, der es Naturschutzpraktikern ermöglicht, den Verbuschungsgrad von Heideflächen effizient und zuverlässig zu erfassen.

1.1 Aufbau der Arbeit

Kapitel 2 (Theoretischer Hintergrund) legt die theoretischen Grundlagen. In Kapitel 3 (Verwandte Arbeiten) werden verwandte Arbeiten vorgestellt. Kapitel 4 (Methodik) beschreibt

das methodische Vorgehen, bevor in Kapitel 5.5 (Diskussion) die Ergebnisse evaluiert werden. Kapitel 6 (Ausblick und Einordnung in den Gesamtkontext) schließt die Arbeit mit einem Ausblick ab.

2 Theoretischer Hintergrund

2.1 Ökologischer Hintergrund

Als Heiden werden baumfreie Offenlandschaften auf nährstoffarmen, sauren Böden bezeichnet, die überwiegend von niedrigwüchsigen Zwergsträuchern aus der Familie der Heidekrautgewächse (Ericaceae) bewachsen sind. Prägende und namensgebende Leitart ist dabei die Besenheide (*Calluna vulgaris*) [9].

Die heutigen Heideflächen haben sich vor etwa 4.000 Jahren großflächig als Folge menschlicher Waldrodungen entwickelt [9]. Die brachliegenden Flächen wurden anschließend auf vielfältige Weise genutzt, etwa zur Viehhaltung, zum Torfabbau, für die Brandrodung, zur Gewinnung von Brennstoff sowie als Fläche für Tierfutter. Vor allem die Beweidung hielt die Böden nährstoffarm und verhinderte zugleich, dass sich auf den gerodeten Flächen erneut Wald entwickeln konnte, sodass sich dadurch die Heide ausbreiten konnte. Heidekraut selbst gab es allerdings bereits vor dem menschlichen Einfluss, wenn auch nur als Beimischung auf kargen Waldböden, dort wo ein lichtetes, offenes Kronendach genügend Licht auf den Boden fallen ließ. Damit zählen Heideflächen zu den wichtigsten Kulturlandschaften Westeuropas, also zu den durch menschliche Nutzung über lange Zeit geprägten und gestalteten Landschaften, welche im Gegensatz zur vom Menschen unberührten Naturlandschaft stehen. Erstreckten sie sich einst über mehrere Millionen Hektar, sind heute nur noch etwa 350.000 Hektar übrig. Gerade wegen dieser starken Verluste gelten Heidegebiete als Flächen mit hohem Naturschutzpotential [9].

Bleibt die zuvor beschriebene Nutzung aus, setzt an den Heidestandorten eine Sukzession ein, also die gerichtete zeitliche Abfolge von Pflanzengesellschaften an einem Standort. Sie verläuft hier von der Zwergstrauchheide über eine zunehmende Vergrasung bis hin zu Gehölzen und langfristig zurück zum Wald. Ohne Pflege wachsen nach und nach Pioniergehölze auf, etwa Schlehen, Rosen- und Weißdornarten sowie Bäume wie Birken, Zitterpappeln und Kiefern [8]. Diese Dominanzbestände überwuchern die Heide, indem sie ihr Nährstoffe entziehen und beschatten, sodass die niedrigwüchsigen Zwergsträucher zu wenig Licht erhalten. Neben der ausbleibenden Pflege ist die atmosphärische Stickstoffdeposition der zentrale Treiber der heutigen Degradation. Über Jahrzehnte gelangt Stickstoff aus Landwirtschaft und Verkehr über die Luft in die Heide und reichert die von Natur aus nährstoffarmen Böden schleichend an, wobei die Einträge vielerorts über der ökologischen Belastungsgrenze liegen [10]. Dadurch verschiebt sich die Konkurrenz zugunsten schnellwüchsiger Gräser, wodurch auf Trockenheiden die Besenheide (*Calluna vulgaris*) durch das Drahtschmielengras (*Deschampsia flexuosa*) verdrängt wird und

auf Feuchtheiden *Erica tetralix* durch das Pfeifengras (*Molinia caerulea*). Grund dafür ist, dass die Gräser den zusätzlichen Stickstoff effizienter aufnehmen und binden. Mit steigender Stickstoffverfügbarkeit wird die Konkurrenz zunehmend asymmetrisch, und die Zwergsträucher werden unterdrückt [11].

Die Prozesse der schleichenden Vergrasung sowie der anschließenden Ausbreitung von Gehölzen laufen letztlich in der Verbuschung zusammen. Unter Verbuschung versteht man die zunehmende Ausbreitung von Sträuchern und Gehölzen auf der eigentlich offenen Heidefläche. Der Verbuschungsgrad bezeichnet das quantitative Maß dieser Ausbreitung, also den Anteil der von Gehölzen bedeckten Fläche. Da die Verbuschung die charakteristische Zwergstrauchvegetation verdrängt und die offene Struktur der Heide auflöst, gilt sie als Degradationsindikator für den Erhaltungszustand von Heideflächen [3]. Der Erhaltungszustand wiederum ist die Bewertungsgröße, anhand derer die Flora-Fauna-Habitat-Richtlinie den Zustand der geschützten Lebensräume erfasst [7]. Ein hoher Verbuschungsgrad steht damit für einen ungünstigen Erhaltungszustand der Heide.

Um die Heide offenzuhalten und der Sukzession entgegenzuwirken, war schon früher eine kontinuierliche Nutzung nötig, aus der die heutigen Pflegemaßnahmen hervorgegangen sind. So wurde durch das Plaggen die nährstoffreiche Humusschicht samt Heidevegetation vom Oberboden abgetragen. Die Plaggen dienten als Einstreu in den Ställen und gelangten später als Dünger auf die Äcker [12]. Mit der Einführung von Mineraldünger und ausreichend verfügbarem Stroh wurde diese Methode jedoch überflüssig. Auch die weit verbreitete Schafzucht hielt Bäume und Sträucher zurück, da die Schafe die jungen Triebe abfressen [13]. Sie ging zurück, als Baumwolle und billige Wollimporte aus Übersee aufkamen. Daneben wurde die Mahd eingesetzt, bei der die oberen Pflanzenschichten mit Sense oder Sichel abgeschnitten und der Bestand so verjüngt wurde, wobei zugleich junge Baumtriebe und Sträucher entfernt wurden. Da diese traditionellen Nutzungsformen weggefallen sind, muss der Naturschutz die Offenhaltung heute mit gezielten Pflegemaßnahmen übernehmen. Der maschinelle Plaggenhieb bzw. das Schopfern entfernt Boden- und Rohhumusschichten und entzieht dem System damit gezielt Stickstoff. Die abgetragenen Schichten müssen vollständig aus dem Gebiet entfernt werden, da sich sonst konkurrenzstarke Gräser wie das Land-Reitgras wieder ausbreiten [12]. Bei der Beweidung mit Schafen oder Heidschnucken ist das nächtliche Aufstallen entscheidend, also das Zusammenpferchen auf Äckern oder im Stall, damit der Dung nicht in die Heide zurückgelangt, sondern direkt auf dem Acker landet und somit die Fläche nährstoffarm bleibt [13], [14]. Die Mahd zählt des Weiteren zu den gängigsten Methoden, wobei der Abtransport des Mähguts unbedingt notwendig ist, um eine erneute Nährstoffanreicherung zu vermeiden [15]. Das Entkusseln geht noch einen Schritt weiter und entfernt aufkommende Gehölze wie Kiefer oder Birke rein mechanisch durch Absägen und Zurückschneiden. Schließlich wird auch das kontrollierte Abbrennen kleiner

Flächen angewendet, das dem Rohhumus Nährstoffe entzieht und offene, konkurrenzarme Standorte für das Heidekraut schafft. Anders als beim Plaggen bleibt der Phosphor dabei jedoch über die Asche im System [16]. Vergleichende Untersuchungen zeigen, dass alle diese Verfahren dem System Nährstoffe entziehen, bei anhaltend hoher Stickstoffdeposition aber in kurzen Abständen von etwa fünf Jahren wiederholt werden müssen [15].

Diese Pflegemaßnahmen sind personal-, kosten- und zeitintensiv und müssen regelmäßig wiederholt werden. Ihr gezielter Einsatz und die Kontrolle ihres Erfolgs setzen daher voraus, dass sich der Verbuschungsgrad großflächig, objektiv und wiederholbar bestimmen lässt. Das sind Anforderungen, die eine rein feldbasierte Kartierung nur schwer erfüllt [1]. Damit rücken fernerkundliche und automatisierte Auswertungsverfahren in den Fokus, deren methodische Grundlagen die folgenden Abschnitte behandeln.

2.2 Structure from Motion

2.2.1 Allgemeines

Ausgangspunkt der semantischen Segmentierung sind Drohnenaufnahmen im sichtbaren (RGB-)Spektrum, also zunächst zweidimensionale Bilder. Um daraus eine dreidimensionale Punktwolke zu gewinnen, gibt es grundsätzlich zwei Wege. LiDAR-Punktwolken werden direkt mit einem eigens dafür vorgesehenen Sensor am UAV erfasst und müssen anschließend nur noch über eine herstellereigene Software in ein passendes Format (z.B. LAS) überführt werden. Bei Structure from Motion (SfM) hingegen wird die Punktwolke rechnerisch aus den RGB-Bildern abgeleitet. Spezielle Algorithmen kombinieren viele stark überlappende Einzelbilder zu 2D-Bildmosaiken und 3D-Punktwolken und nutzen die in den UAV-Bildern enthaltene photogrammetrische Information, um daraus hochaufgelöste Gelände- und Oberflächenmodelle (DTMs und DSMs) zu erstellen. Für deren Berechnung stehen zwar zahlreiche Algorithmen zur Verfügung, doch die Wahl der Parameter und die damit verbundenen Unsicherheiten sind häufig nur unzureichend dokumentiert. Abhilfe schaffen quelloffene Softwarewerkzeuge wie COLMAP, die einen reproduzierbaren SfM-Workflow ermöglichen [1].

SfM beruht auf demselben Grundprinzip wie die stereoskopische Photogrammetrie, bei der sich die dreidimensionale Struktur einer Szene aus einer Reihe überlappender, versetzter Aufnahmen ableiten lässt, was dem räumlichen Sehen mit zwei Augen ähnelt (Abbildung 1). Der entscheidende Unterschied zur klassischen Photogrammetrie liegt darin, dass diese die Position und Ausrichtung der Kamera vorab kennen oder auf Passpunkte mit bekannten 3D-Koordinaten zurückgreifen muss. SfM benötigt beides

nicht, da Kamerapositionen und Szenengeometrie allein aus den Bildern automatisch bestimmt werden. Möglich wird das durch einen Bündelausgleich (bundle adjustment), ein Ausgleichsverfahren, das alle Kameraparameter und 3D-Punktpositionen gleichzeitig so optimiert, dass der Rückprojektionsfehler minimal wird. Das Verfahren stammt ursprünglich aus der Computer-Vision-Forschung der 1990er Jahre und wurde durch die Arbeit von Snavely (2008) bekannt, die SfM-Ansätze im Kontext der Cloud-Anwendung Microsoft Photosynth beschreibt [17].




Abbildung 1: Grundprinzip von Structure from Motion: Aufnahme desselben Objekts aus mehreren überlappenden, versetzten Kamerapositionen [17].

Damit die Rekonstruktion gelingt, müssen dieselben Merkmale in mindestens drei Aufnahmen sichtbar sein. Ein hoher Überlappungsgrad und möglichst viele Bilder aus unterschiedlichen Positionen verbessern das Ergebnis, da sie die Zahl zuverlässiger Merkmalszuordnungen und die Redundanz des Systems erhöhen [17].

2.2.2 Ablauf der Rekonstruktion

Die konkrete Umsetzung dieses Prinzips lässt sich an der inkrementellen SfM-Pipeline (Abbildung 2) nachvollziehen, wie sie in COLMAP realisiert ist. Sie gliedert sich in zwei Phasen: die Korrespondenzsuche (correspondence search) und die schrittweise 3D-Rekonstruktion (incremental reconstruction). In der ersten Phase werden zunächst in jedem Einzelbild lokale Merkmale, sogenannte Keypoints, erkannt, was üblicherweise mit dem SIFT-Verfahren geschieht. Diese Merkmale werden auch dann wiedererkannt, wenn

sie in verschiedenen Bildern unterschiedlich groß, gedreht oder beleuchtet erscheinen. Zu jedem Keypoint wird dazu ein Deskriptor berechnet, der ein eindeutiges Zuordnen über viele Bilder hinweg erlaubt. Wie viele Merkmale ein Bild liefert und wie dicht die spätere Punktwolke wird, hängt dabei von Bildtextur und Auflösung ab. Im nächsten Schritt (matching) werden über diese Merkmale Bildpaare gefunden, die denselben Szenenausschnitt zeigen. Ihre korrespondierenden Punkte werden einander zugeordnet. Da diese Zuordnung allein auf dem Aussehen der Merkmale beruht, werden die Paare anschließend geometrisch überprüft (geometric verification) und mithilfe der projektiven Geometrie Fehlzusammenordnungen aussortiert. Das Ergebnis der ersten Phase ist ein Scene Graph, also ein Graph, der festhält, welche Bilder denselben Bildbereich zeigen und welche Punkte einander entsprechen. Er bildet die Grundlage für die Rekonstruktion [18]. In der zweiten Phase wird daraus schrittweise das dreidimensionale Modell aufgebaut. Den Ausgangspunkt bildet ein sorgfältig gewähltes Bildpaar, das als Keim des Modells dient (initialization). Von dort aus werden nach und nach weitere Bilder eingehängt (image registration), indem ihre Kameraposition über bereits bekannte 3D-Punkte bestimmt wird. Anschließend werden durch Triangulation aus mehreren Blickwinkeln neue 3D-Punkte berechnet und der Wolke hinzugefügt. Zwischendurch werden Kamerapositionen und 3D-Punkte immer wieder gemeinsam durch den Bündelausgleich verfeinert und Ausreißer entfernt, damit sich die entstehenden Fehler nicht aufschaukeln. Diese Abfolge aus Einhängen, Triangulieren und Ausgleichen wiederholt sich, bis alle Bilder registriert sind. Als Ergebnis liefert SfM dann die Kamerapositionen (motion) und eine zunächst noch spärliche 3D-Punktwolke (structure) [18].




Abbildung 2: Ablauf der inkrementellen SfM-Pipeline in COLMAP [18].

Diese spärliche Wolke enthält jedoch zunächst nur die markanten Merkmalspunkte. Die dichte Punktwolke, die für die spätere Segmentierung benötigt wird, entsteht erst in einem nachgelagerten, eigenständigen Verfahren, dem Multi-View Stereo (MVS). Während Structure from Motion die Szene nur spärlich modelliert, liefert MVS ihre dichte Modellierung [19]. Den Kern bildet dabei die pixelweise Korrespondenzsuche. Dort wird für sehr viele Bildpunkte über mehrere Ansichten hinweg nach übereinstimmenden Entsprechungen gesucht, woraus sich für jeden Punkt eine Tiefe schätzen lässt. Welche

Ansichten dafür herangezogen werden, steuern photometrische und geometrische Kriterien. Die so entstandenen Tiefenkarten werden anschließend zu einer einheitlichen, dichten Szenenrepräsentation zusammengeführt [19].

Diese Punktwolke liegt allerdings zunächst in einem relativen Koordinatensystem, dem Bildraum (image space) und besitzt weder einen echten Maßstab noch eine räumliche Orientierung. Um sie in reale Koordinaten zu überführen, wird sie anschließend georeferenziert. Das bedeutet, dass die Wolke über wenige Passpunkte (ground control points, GCPs) mit bekannten Objektinformationen vom Bildraum in den realen Objektraum (object space) überführt wird. Dazu dient eine 3D-Ähnlichkeitstransformation, die Maßstab, Drehung und Verschiebung zwischen beiden Koordinatensystemen angleicht [17].

Wie praxistauglich das gerade in der Heide ist, zeigt Schmidt et al. (2017): Aus überlappenden UAV-RGB-Bildern leiteten sie per SfM eine 3D-Punktwolke ab und daraus ein Canopy Height Model, die Differenz aus Oberflächen- und Geländemodell, wodurch die Vegetationshöhe flächig abgebildet wurde. Diese Höheninformationen wurden dann zur Bewertung des Erhaltungszustands Calluna-dominierte Heiden genutzt [3].

2.3 Convolutional Neural Networks (CNNs)

2.3.1 Allgemeines

Klassische Verfahren des maschinellen Lernens konnten Rohdaten wie die Pixelwerte eines Bildes nicht unmittelbar verarbeiten. Stattdessen war ein manuell entworfener Merkmalsextraktor nötig, der die Rohdaten mit viel Fachwissen in eine geeignete interne Repräsentation, einen Merkmalsvektor, überführte [20]. Deep Learning überwindet diese Einschränkung, indem es die entscheidenden Merkmale automatisch aus den Rohdaten lernt, also ohne die manuelle Merkmalskonstruktion durchzuführen, und ist damit besonders für hochdimensionale, nichtlineare und komplexe Daten geeignet [6].

Diese Fähigkeit beruht auf dem Prinzip des Representation Learning. Dieses beschreibt Methoden, die es einer Maschine erlauben, aus Rohdaten selbständig die für die Erkennung oder Klassifikation nötigen Repräsentationen zu finden. Deep Learning ist sozusagen Representation Learning mit mehreren Repräsentationsebenen. Dabei überführen verkettete, einfache und nicht-lineare Module die Repräsentation Schritt für Schritt von der Rohform in eine jeweils höhere, abstraktere Ebene. Entscheidend ist dabei, dass diese Merkmalsebenen, welche zudem hierarchisch aufeinander aufbauen, nicht von Menschen entworfen, sondern mit allgemeinen Lernverfahren aus den Daten gelernt

werden. Bei einem Bild zum Beispiel erkennt die erste Ebene typischerweise Kanten, die zweite setzt diese zu Motiven zusammen, die dritte zu Teilen bekannter Objekte und weitere Ebenen schließlich zu ganzen Objekten. So entsteht schrittweise aus einfachen Merkmalen eine immer abstraktere Darstellung [20].

Ein Convolutional Neural Network (CNN) ist eine spezielle Deep-Learning-Architektur, die auf gitterförmige Daten zugeschnitten ist, wie sie etwa ein Bild darstellt. Ein Farbbild liegt beispielsweise als drei zweidimensionale Arrays vor, je eines für die Pixelwerte der drei Farbkanaäle. Dieses Netzwerk setzt das allgemeine Prinzip des mehrschichtigen, hierarchischen Merkmalslernens um, inklusive der Faltung (convolution) und der Hinzunahme geteilter Gewichte. Die vier prägenden Grundideen eines CNN sind neben lokalen Verbindungen, geteilten Gewichten und Pooling, auch die Verwendung vieler Schichten [6]. Die ersten Stufen bestehen aus zwei Schichttypen, Faltungs- und Pooling-Schichten. In einer Faltungsschicht sind die Einheiten in Merkmalskarten (feature maps) organisiert. Jede Einheit ist nur mit einem lokalen Ausschnitt (local patch) der vorherigen Schicht verbunden, und zwar über einen Satz Gewichte, der sogenannten filter bank. Das lokale gewichtete Summenergebnis läuft anschließend durch eine Nichtlinearität, z.B. eine ReLU (Rectified Linear Unit), die negative Werte auf null setzt und positive unverändert weitergibt. Alle Einheiten einer Merkmalskarte teilen sich dabei dieselbe filter bank, da benachbarte Werte in Bildern stark korreliert sind und lokale Motive bilden, die zudem ortsunabhängig überall auftreten können [20]. Anschaulich lässt sich das so verstehen, dass ein kleiner, lernbarer Filter schrittweise über das gesamte Bild geschoben wird und an jeder Position aus dem lokalen Ausschnitt eine Antwort berechnet. Alle Antworten zusammen bilden dann die Merkmalskarte (Abbildung 3). Weil derselbe Filter an jeder Stelle verwendet wird, erkennt er dasselbe lokale Muster überall im Bild, während verschiedene Filter jeweils ein anderes Muster detektieren und so verschiedene Merkmalskarten erzeugen.




Abbildung 3: Funktionsweise der Faltung. [Eigene Darstellung].

Die Pooling-Schicht fasst anschließend semantisch ähnliche Merkmale zusammen. Dabei typisch ist das Max-Pooling, das den Maximalwert eines lokalen Ausschnitts einer Merkmalskarte übernimmt, wodurch die Dimension der Repräsentation reduziert und eine Invarianz gegenüber kleinen Verschiebungen und Verzerrungen erzeugt wird [20].

Im Gesamtaufbau durchläuft das Eingabebild schließlich mehrere gestapelte Stufen aus Faltung, Nichtlinearität und Pooling (Abbildung 4). Mit jeder Stufe wird die räumliche Auflösung gröber, die Merkmale aber zahlreicher und abstrakter, so wie es die Hierarchie von Kanten über Motive und Objektteile bis hin zu ganzen Objekten vorgibt. Am Ende folgen voll verbundene Schichten, die aus diesen Merkmalen die eigentliche Vorhersage berechnen [20].




Abbildung 4: Aufbau eines CNN aus gestapelten Faltungs- und Pooling-Stufen [20].

2.3.2 Anwendung in der Fernerkundung

In der Fernerkundung von Vegetation sind CNNs inzwischen breit erprobt. Für die Bildanalyse haben sich zwei Netzfamilien herausgebildet, die sich darin unterscheiden, wie kleinteilig sie ein Bild auswerten. Pixelbasierte Netze klassifizieren jeden einzelnen Bildpunkt und liefern so eine semantische Segmentierung, also eine flächendeckende Klassenkarte. Objektbasierte Netze, sogenannte anchor-based Netze, gehen anders vor. Sie legen vordefinierte Referenzboxen (anchors) über das Bild, um Objekte zu lokalisieren und ihre Kategorie und Position zu bestimmen. Ein bekanntes Beispiel ist YOLO (You Only Look Once) [6]. Für das Auffinden einzelner Objekte wie Baumkronen eignen sich solche Netze gut, für flächendeckende Klassenkarten kommen vor allem U-Net und DeepLab zum Einsatz, während ResNet eher der patchweisen Klassifikation dient, bei der ein ganzer Bildausschnitt eine einzige Klasse erhält statt jeder Bildpunkt einzeln. Die Gemeinsamkeit bei allen ist,

dass sie ihre Merkmale über Faltung und Pooling gewinnen [6]. U-Net besteht aus zwei aufeinander abgestimmten Teilen. Ein kontrahierender Pfad, der Encoder, reduziert die räumliche Auflösung schrittweise und verdichtet zugleich die Merkmalsinformation, während der expandierende Pfad, der Decoder, sie über Up-Convolutions und die Verkettung (concatenation) mit den hochaufgelösten Merkmalen des Encoders wieder zu einer pixelgenauen Ausgabe zusammenführt. Die direkten Verbindungen zwischen beiden Pfaden erhalten dabei die räumliche Genauigkeit [6]. Wie leistungsfähig dieser Ansatz ist, zeigen zahlreiche Anwendungen. So kartierte ein U-Net Waldtypen und Störungen im atlantischen Regenwald aus WorldView-3-Satellitenbildern mit einer Klassifikationsgenauigkeit von über 95 %, und in weiteren Arbeiten ließen sich einzelne Baumarten aus UAV-Satellitenbildern mit Genauigkeiten von rund 84 bis 96 % bestimmen [6]. Methodisch ist das dieselbe Aufgabe wie in dieser Arbeit, nämlich eine pixelweise semantische Segmentierung zur Kartierung von Vegetationsklassen. Die vorliegende Arbeit überträgt sie vom Wald auf die Heide und vom zweidimensionalen Bild auf die dreidimensionale Punktwolke. U-Net dient hier als etabliertes 2D-Verfahren, an dem sich der neu entwickelte 3D-Ansatz PointNet++ messen lässt.

2.4 Geometric Deep Learning

Die im vorigen Abschnitt beschriebenen CNNs setzen ein regelmäßiges Gitter voraus, wie es ein Bild bietet. Eine dreidimensionale Punktwolke ist dagegen unstrukturiert. Sie besteht aus einer ungeordneten Menge von Punkten ohne feste Nachbarschaftsbeziehungen, weshalb sich die Faltung nicht unmittelbar anwenden lässt. Für genau solche Daten wurde das Geometric Deep Learning (GDL) entwickelt. Der Begriff fasst Verfahren zusammen, die tiefe neuronale Netze von gitterförmigen auf nicht-euklidische Daten wie Graphen, Mannigfaltigkeiten und eben Punktwolken verallgemeinern [21]. Ein naheliegender Ausweg besteht darin, die Punktwolke vor der Verarbeitung in ein regelmäßiges Format zu überführen, etwa in ein 3D-Voxelgitter, das dreidimensionale Pendant zu Pixeln, oder eine Sammlung von Bildern. Dieser Umweg bläht die Daten jedoch unnötig auf und bringt weitere Probleme mit sich [22]. Sinnvoller ist ein Netz, das direkt auf den Punkten arbeitet. Die fehlende Ordnung, also die beliebige Reihenfolge der Punkte in einer Punktwolke, stellt dabei eine besondere Herausforderung dar. Aus diesem Grund muss ein solches Netz permutationsinvariant sein. Werden dieselben Punkte anders angeordnet, soll das Ergebnis gleich bleiben [22].

2.4.1 Semantische Segmentierung von 3D-Punktwolken

Die für diese Arbeit zentrale Aufgabe ist die semantische Segmentierung einer Punktwolke. Dabei erhält jeder einzelne Punkt eine von mehreren Zielklassen, ohne dass verschiedene Objekte derselben Klasse unterschieden werden [23]. Das trennt die Segmentierung von der reinen Klassifikation, bei der die gesamte Wolke ein einziges Label bekommt, während die Segmentierung ein Label je Punkt liefert [22]. Ein entsprechendes Netz gibt für jeden Punkt einen Wert pro Klasse aus, sodass sich jedem die wahrscheinlichste Klasse zuordnen lässt [22]. Übertragen auf diese Arbeit heißt das, jedem Punkt der Heide-Punktwolke eine Vegetationsklasse zuzuweisen. Aus dieser punktwweisen Zuordnung lässt sich anschließend der Verbuschungsgrad berechnen.

2.4.2 Beispiel: PointNet

PointNet war das erste Netz, das ungeordnete Punktwolken direkt verarbeitet [22]. Jeder Punkt wird dabei zunächst einzeln betrachtet und ist im einfachsten Fall nur durch seine drei Koordinaten gegeben, die sich um weitere Merkmale wie Normalen ergänzen lassen. Auf jeden Punkt wird dasselbe kleine neuronale Netz angewendet, ein sogenanntes Multilayer Perceptron (MLP). Ein MLP ist ein einfaches, vollständig verbundenes Netz aus mehreren Schichten, das einen Eingabevektor auf einen Ausgabevektor abbildet. Weil für alle Punkte dieselben Gewichte genutzt werden, spricht man von einem geteilten MLP, welches den geteilten Gewichten der filter bank bei CNNs entspricht und lediglich auf einzelne Punkte statt auf ganze Bildausschnitte angewendet wird [22]. Damit die Reihenfolge der Punkte keine Rolle spielt, führt PointNet die einzelnen Punktmerkmale mit einer symmetrischen Funktion zusammen, dem Max-Pooling. Es übernimmt für jedes Merkmal den größten Wert über alle Punkte hinweg, wodurch ein einziges globales Merkmal (global feature) entsteht, das die gesamte Punktwolke beschreibt und nicht von der Reihenfolge der Punkte abhängt [22]. Aus diesem globalen Merkmal berechnet PointNet je nach Aufgabe unterschiedliche Ausgaben. Wohingegen das Netz für die Klassifikation ein einziges Label für die gesamte Wolke liefert, erhält bei der semantischen Segmentierung jeder Punkt sein eigenes Label. Dazu wird unter anderem das globale Merkmal mit den lokalen Merkmalen jedes einzelnen Punktes verkettet [22]. Die größte Schwäche, die dabei bleibt, ist, dass sich PointNet stark auf dieses eine globale Merkmal stützt und jeden Punkt unabhängig von seinen Nachbarn verarbeitet. Lokale Strukturen, die sich aus den Abständen benachbarter Punkte ergeben, erfasst es daher kaum, was die Erkennung feiner Muster begrenzt [24]. Genau hier setzt die Weiterentwicklung PointNet++ an.

2.4.3 Beispiel: PointNet++

PointNet++ begegnet dieser Schwäche mit einem hierarchischen Aufbau (Abbildung 5), der PointNet wiederholt auf ineinander verschachtelte Teilmengen der Punktwolke anwendet [24]. Indem es benachbarte Punkte anhand ihrer räumlichen Abstände zu lokalen Regionen zusammenfasst, lernt das Netz lokale Merkmale auf zunehmend größeren Kontext-Skalen, angefangen bei kleinen Nachbarschaften bis hin zu größeren Regionen. Kern des Verfahrens ist die sogenannte Set Abstraction, eine Verarbeitungsstufe aus drei Schritten. Im Sampling werden zunächst einzelne Punkte als Zentren (centroids) lokaler Regionen ausgewählt. Das anschließende Grouping bildet um jedes dieser Zentren eine lokale Region aus den benachbarten Punkten. In der abschließenden PointNet-Schicht fasst ein kleines PointNet jede solche Region zu einem einzelnen Merkmalsvektor zusammen. Mehrere solcher Stufen hintereinander erzeugen die Hierarchie, in der die Zahl der Punkte von Stufe zu Stufe abnimmt, während die Merkmale immer reichhaltiger werden [24]. Für die Segmentierung muss am Ende jeder ursprüngliche Punkt ein Label erhalten, nicht nur die wenigen verbliebenen Zentren. Dazu werden die auf den groben Stufen gelernten Merkmale schrittweise wieder auf alle Punkte übertragen, ein Vorgang, der als feature propagation bezeichnet wird. Die Übertragung erfolgt durch eine abstandsgewichtete Interpolation über die k nächsten Nachbarn und wird durch Skip-Verbindungen (skip connections) ergänzt, die Merkmale früherer Stufen direkt mit einbringen. So erhält am Ende jeder Punkt der Wolke eine Klasse [24].




Abbildung 5: Architektur von PointNet++ mit hierarchischen Set-Abstraction-Stufen sowie Segmentierungs- und Klassifikationszweig [24].

PointNet++ ist damit das in dieser Arbeit eingesetzte 3D-Verfahren. Es weist jedem Punkt der Heide-Punktwolke eine Vegetationsklasse zu und erfasst dabei die lokalen Strukturen, die für die Unterscheidung der Vegetationsarten und damit für die Bestimmung der Verbuschung entscheidend sind.

2.5 Evaluationsmetriken

Die Bewertung der Ergebnisse erfolgt auf zwei Ebenen, die den beiden Forschungsfragen entsprechen. Auf der ersten Ebene wird die Güte der punktweisen Segmentierung beurteilt, also wie zuverlässig das Netz jedem Punkt die richtige Vegetationsklasse zuweist. Die dafür üblichen Maße leiten sich aus der Konfusionsmatrix ab, die für jede Klasse die korrekten und die falschen Zuordnungen gegenüberstellt [23]. Auf der zweiten Ebene wird der daraus abgeleitete Verbuschungsgrad geprüft, indem der vorhergesagte Wert je Rasterzelle mit einem Referenzwert verglichen wird. Da hier kein Klassenlabel, sondern ein flächiger Anteil bewertet wird, kommen statistische Maße für die Übereinstimmung zum Einsatz. Die folgenden beiden Abschnitte stellen die jeweils verwendeten Metriken vor.

2.5.1 Metriken der Segmentierung

Die erste Forschungsfrage betrifft die Güte der punktweisen Segmentierung. Grundlage der Bewertung ist die Konfusionsmatrix (confusion matrix), die die vorhergesagten Klassen den tatsächlichen Klassen gegenüberstellt. In ihren Zeilen steht die wahre Klasse eines Punktes, in ihren Spalten die vom Netz vorhergesagte Klasse, sodass der Eintrag c_{ij} angibt, wie viele Punkte der Klasse i als Klasse j klassifiziert wurden. Auf der Diagonalen stehen folglich die korrekt zugeordneten Punkte, während die Einträge außerhalb der Diagonalen die Verwechslungen zwischen den Klassen sichtbar machen [23]. Aus dieser Matrix leiten sich die folgenden Maße ab, wobei N die Anzahl der Klassen bezeichnet.

Die Gesamtgenauigkeit (Overall Accuracy, OA) beschreibt den Anteil aller korrekt klassifizierten Punkte an der Gesamtzahl der Punkte. Sie ergibt sich als Summe der Diagonaleinträge geteilt durch die Summe aller Einträge der Matrix [23]:

$$OA = \frac{\sum_{i=1}^N c_{ii}}{\sum_{i=1}^N \sum_{j=1}^N c_{ij}}$$

Die Gesamtgenauigkeit lässt sich einfach interpretieren, reagiert aber empfindlich auf ungleich große Klassen. Dominiert eine Klasse den Datensatz, kann ein hoher Wert vor allem deren gute Trennung widerspiegeln, ohne dass seltene Klassen zuverlässig erkannt werden.

Um die einzelnen Klassen unabhängig von ihrer Häufigkeit zu beurteilen, wird die Schnittmenge über Vereinigung (Intersection over Union, IoU) je Klasse betrachtet. Sie setzt die korrekt erkannten Punkte einer Klasse ins Verhältnis zur Vereinigung aus

vorhergesagten und tatsächlichen Punkten dieser Klasse und berücksichtigt so sowohl übersehene als auch fälschlich zugeordnete Punkte [23]:

$$\text{IoU}_i = \frac{c_{ii}}{c_{ii} + \sum_{j \neq i} c_{ij} + \sum_{j \neq i} c_{ji}}$$

Als zusammenfassendes Maß über alle Klassen dient die mittlere Schnittmenge über Vereinigung (mean IoU, mIoU), der Mittelwert der klassenweisen IoU-Werte [23]:

$$\text{mIoU} = \frac{1}{N} \sum_{i=1}^N \text{IoU}_i$$

Da jede Klasse gleich in den Mittelwert eingeht, gewichtet die mittlere IoU seltene und häufige Klassen gleichermaßen und eignet sich daher als Hauptkennzahl für den Vergleich der Segmentierungsgüte. In dieser Arbeit lässt die klassenweise IoU erkennen, welche Vegetationsklassen das Netz gut voneinander trennt und welche es häufig verwechselt, während die mittlere IoU die Gesamtleistung in einer einzigen Kennzahl bündelt. Die Konfusionsmatrix ergänzt diese Werte, indem sie zeigt, zwischen welchen Klassen die Fehler konkret auftreten.

2.5.2 Metriken des Verbuschungsgrades

Die zweite Forschungsfrage betrifft die Genauigkeit des aus der Segmentierung abgeleiteten Verbuschungsgrades. Anders als bei der Segmentierung wird hier keine Klassenzuordnung, sondern ein flächiger Anteil je Rasterzelle bewertet. Für jede Zelle liegt ein vorhergesagter Verbuschungsgrad $\hat{y}_i$ und ein Referenzwert y_i vor. Die Bewertung stützt sich dabei auf die Abweichung zwischen beiden Werten. Diese Abweichung entspricht dem Residuum $\hat{\epsilon}_i = y_i - \hat{y}_i$, das die Differenz zwischen beobachtetem und vorhergesagtem Wert angibt [25]. Aus den Residuen über alle n Zellen leiten sich die folgenden Maße ab.

Der Wurzelwert des mittleren quadratischen Fehlers (Root Mean Squared Error, RMSE) mittelt die quadrierten Residuen und zieht daraus die Wurzel. Durch die Quadrierung gehen große Abweichungen stärker ein, sodass der RMSE einzelne grobe Fehleinschätzungen betont:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Das Bestimmtheitsmaß (Coefficient of Determination, R^2) gibt den Anteil der Streuung der Referenzwerte an, der durch die Vorhersage erklärt wird. Es setzt die verbleibende Residualstreuung ins Verhältnis zur Gesamtstreuung der Referenzwerte, wobei $\bar{y}$ deren Mittelwert bezeichnet [25]:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Das Bestimmtheitsmaß nimmt außerdem nur Werte zwischen null und eins an. Ein Wert nahe eins bedeutet, dass die Vorhersagen den Referenzwerten weitgehend folgen, während ein Wert nahe null anzeigt, dass die Vorhersage kaum mehr erklärt als der Mittelwert der Referenz.

Solche Maße sind in der Heide-Fernerkundung etabliert. Schmidt et al. bewerten die Übereinstimmung ihrer fernerkundlich geschätzten Calluna-Deckung und Bestandshöhen mit Referenzdaten ebenfalls über R^2 und RMSE [3]. Für diese Arbeit erlaubt der RMSE eine Aussage über die durchschnittliche Größe der Abweichung im Verbuschungsgrad, während das Bestimmtheitsmaß die Güte des Zusammenhangs mit der Referenz bewertet.

3 Verwandte Arbeiten

4 Methodik

4.1 Untersuchungsgebiet

4.2 Datengrundlage

4.3 Annotation und Klassenschema

4.4 Datenvorverarbeitung

4.4.1 Label-Transfer und Qualitätssicherung

4.4.2 Tiling und Sampling

4.5 Modell und Training

4.5.1 PointNet++

4.5.2 Training

4.6 Quantifizierung des Verbuschungsgrades

4.6.1 Rasterisierung

5 Fazit und Diskussion

5.1 Evaluation der semantischen Segmentierung

5.1.1 Gesamtmetriken

5.1.2 Klassenweise Auswertung

5.1.3 Konfusionsmatrix

5.2 Fehleranalyse

5.2.1 Einfluss des Klassenungleichgewichts

5.2.2 Kritische Verwechslungen

5.3 Quantifizierung des Verbuschungsgrades

5.4 Vergleich mit dem 2D-Ansatz

5.5 Diskussion

5.6 Fazit

6 Ausblick und Einordnung in den Gesamtkontext

Anhang

Anhang 1: Beispielanhang

Dieser Abschnitt dient nur dazu zu demonstrieren, wie ein Anhang aufgebaut sein kann.

Anhang 1.1: Weitere Gliederungsebene

Auch eine zweite Gliederungsebene ist möglich.

Anhang 2: Bilder

Auch mit Bildern. Diese tauchen nicht im Abbildungsverzeichnis auf.

Name	Änderungsdatum	Typ	Größe
 abbildungen	29.08.2013 01:25	Dateiordner	
 kapitel	29.08.2013 00:55	Dateiordner	
 literatur	31.08.2013 18:17	Dateiordner	
 skripte	01.09.2013 00:10	Dateiordner	
 compile.bat	31.08.2013 20:11	Windows-Batchda...	1 KB
 thesis_main.tex	01.09.2013 00:25	LaTeX Document	5 KB

Abbildung 6: Beispielbild

Literaturverzeichnis

- [1] W. D. Kissling, Y. Shi, J. Wang, A. Walicka, C. George, J. E. Moeslund und F. Gerard, „Towards consistently measuring and monitoring habitat condition with airborne laser scanning and unmanned aerial vehicles,“ *Ecological Indicators*, Jg. 169, S. 112970, 2024. DOI: 10.1016/j.ecolind.2024.112970
- [2] J. Gonçalves, R. Henriques, P. Alves, R. Sousa-Silva, A. T. Monteiro, Â. Lomba, B. Marcos und J. Honrado, „Evaluating an unmanned aerial vehicle-based approach for assessing habitat extent and condition in fine-scale early successional mountain mosaics,“ *Applied Vegetation Science*, Jg. 19, Nr. 1, S. 132–146, 2016. DOI: 10.1111/avsc.12204
- [3] J. Schmidt, F. E. Fassnacht, C. Neff, A. Lausch, B. Kleinschmit, M. Förster und S. Schmidtlein, „Adapting a Natura 2000 field guideline for a remote sensing-based assessment of heathland conservation status,“ *International Journal of Applied Earth Observation and Geoinformation*, Jg. 60, S. 61–71, 2017. DOI: 10.1016/j.jag.2017.04.005
- [4] I. Eischeid, E. M. Soininen, J. J. Assmann, R. A. Ims, J. Madsen, Å. Ø. Pedersen, F. Pirotti, N. G. Yoccoz und V. T. Ravolainen, „Disturbance Mapping in Arctic Tundra Improved by a Planning Workflow for Drone Studies: Advancing Tools for Future Ecosystem Monitoring,“ *Remote Sensing*, Jg. 13, Nr. 21, S. 4466, 2021. DOI: 10.3390/rs13214466
- [5] J. Cao, W. Leng, K. Liu, L. Liu, Z. He und Y. Zhu, „Object-Based Mangrove Species Classification Using Unmanned Aerial Vehicle Hyperspectral Images and Digital Surface Models,“ *Remote Sensing*, Jg. 10, Nr. 1, S. 89, 2018. DOI: 10.3390/rs10010089
- [6] T. Yun, J. Li, L. Ma, J. Zhou, R. Wang, M. P. Eichhorn und H. Zhang, „Status, advancements and prospects of deep learning methods applied in forest studies,“ *International Journal of Applied Earth Observation and Geoinformation*, Jg. 131, S. 103938, 2024. DOI: 10.1016/j.jag.2024.103938
- [8] T. Schoknecht, *Trockenrasen und Heiden: Hinweise zur Biotop- und Landschaftspflege*, Deutscher Verband für Landschaftspflege (DVL) und Landesumweltamt Brandenburg, Potsdam, 1998.
- [9] N. R. Webb, „The traditional management of European heathlands,“ *Journal of Applied Ecology*, Jg. 35, Nr. 6, S. 987–990, 1998. DOI: 10.1111/j.1365-2664.1998.tb00020.x
- [10] R. Bobbink, K. Hicks, J. Galloway, T. Spranger, R. Alkemade, M. Ashmore, M. Bustamante, S. Cinderby, E. Davidson, F. Dentener, B. Emmett, J.-W. Erisman, M. Fenn, F. Gilliam, A. Nordin, L. Pardo und W. de Vries, „Global assessment of nitrogen deposition effects on terrestrial plant diversity: a synthesis,“ *Ecological Applications*, Jg. 20, Nr. 1, S. 30–59, 2010. DOI: 10.1890/08-1140.1

-
- [11] U. Friedrich, G. von Oheimb, C. Dzedek, W.-U. Kriebitzsch, K. Selbmann und W. Härdtle, „Mechanisms of purple moor-grass (*Molinia caerulea*) encroachment in dry heathland ecosystems with chronic nitrogen inputs,“ *Environmental Pollution*, Jg. 159, Nr. 12, S. 3553–3559, 2011. DOI: 10.1016/j.envpol.2011.08.010
 - [12] M. Niemeyer, T. Niemeyer, S. Fottner, W. Härdtle und A. Mohamed, „Impact of sod-cutting and choppering on nutrient budgets of dry heathlands,“ *Biological Conservation*, Jg. 134, Nr. 3, S. 344–353, 2007. DOI: 10.1016/j.biocon.2006.07.013
 - [13] J. P. Bakker, S. de Bie, J. H. Dallinga, P. Tjaden und Y. de Vries, „Sheep-grazing as a management tool for heathland conservation and regeneration in the Netherlands,“ *Journal of Applied Ecology*, Jg. 20, Nr. 2, S. 541–560, 1983. DOI: 10.2307/2403525
 - [14] R. Rosa García, R. Celaya, U. García und K. Osoro, „Grazing land management and biodiversity in the Atlantic European heathlands: a review,“ *Agroforestry Systems*, Jg. 87, Nr. 1, S. 19–43, 2013. DOI: 10.1007/s10457-012-9519-3
 - [15] W. Härdtle, G. von Oheimb, A.-K. Gerke, M. Niemeyer, T. Niemeyer, T. Assmann, C. Drees, A. Matern und H. Meyer, „Shifts in N and P budgets of heathland ecosystems: effects of management and atmospheric inputs,“ *Ecosystems*, Jg. 12, Nr. 2, S. 298–310, 2009. DOI: 10.1007/s10021-008-9223-3
 - [16] A. Mohamed, W. Härdtle, B. Jirjahn, T. Niemeyer und G. von Oheimb, „Effects of prescribed burning on plant available nutrients in dry heathland ecosystems,“ *Plant Ecology*, Jg. 189, Nr. 2, S. 279–289, 2007. DOI: 10.1007/s11258-006-9183-7
 - [17] M. J. Westoby, J. Brasington, N. F. Glasser, M. J. Hambrey und J. M. Reynolds, „‘Structure-from-Motion’ photogrammetry: A low-cost, effective tool for geoscience applications,“ *Geomorphology*, Jg. 179, S. 300–314, 2012. DOI: 10.1016/j.geomorph.2012.08.021
 - [18] J. L. Schönberger und J.-M. Frahm, „Structure-from-Motion Revisited,“ in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, S. 4104–4113. DOI: 10.1109/CVPR.2016.445
 - [19] J. L. Schönberger, E. Zheng, M. Pollefeys und J.-M. Frahm, „Pixelwise View Selection for Unstructured Multi-View Stereo,“ in *Computer Vision – ECCV 2016*, Ser. Lecture Notes in Computer Science, Bd. 9907, Springer, 2016, S. 501–518. DOI: 10.1007/978-3-319-46487-9_31
 - [20] Y. LeCun, Y. Bengio und G. Hinton, „Deep learning,“ *Nature*, Jg. 521, Nr. 7553, S. 436–444, 2015. DOI: 10.1038/nature14539
 - [21] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam und P. Vandergheynst, „Geometric deep learning: going beyond Euclidean data,“ *IEEE Signal Processing Magazine*, Jg. 34, Nr. 4, S. 18–42, 2017. DOI: 10.1109/MSP.2017.2693418
 - [22] C. R. Qi, H. Su, K. Mo und L. J. Guibas, „PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation,“ in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, S. 652–660. DOI: 10.1109/CVPR.2017.16
 - [23] A. Diab, R. Kashef und A. Shaker, „Deep Learning for LiDAR Point Cloud Classification in Remote Sensing,“ *Sensors*, Jg. 22, Nr. 20, S. 7868, 2022. DOI: 10.3390/s22207868

- [24] C. R. Qi, L. Yi, H. Su und L. J. Guibas, „PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space,“ in *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 2017, S. 5099–5108.
- [25] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz, *Statistik: Der Weg zur Datenanalyse*, 9. Aufl. Berlin, Heidelberg: Springer Spektrum, 2023, ISBN: 978-3-662-67525-0. DOI: 10.1007/978-3-662-67526-7

Internetquellen

- [7] Rat der Europäischen Gemeinschaften. „Richtlinie 92/43/EWG des Rates vom 21. Mai 1992 zur Erhaltung der natürlichen Lebensräume sowie der wildlebenden Tiere und Pflanzen,“ besucht am 2026-07-01. Adresse: <https://eur-lex.europa.eu/legal-content/DE/TXT/?uri=CELEX:31992L0043>

Eigenständigkeitserklärung

Hiermit versichere ich, dass ich die angemeldete Prüfungsleistung in allen Teilen eigenständig ohne Hilfe von Dritten anfertigen und keine anderen als die in der Prüfungsleistung angegebenen Quellen und zugelassenen Hilfsmittel verwenden werde. Sämtliche wörtlichen und sinngemäßen Übernahmen inklusive KI-generierter Inhalte werde ich kenntlich machen.

Diese Prüfungsleistung hat zum Zeitpunkt der Abgabe weder in gleicher noch in ähnlicher Form, auch nicht auszugsweise, bereits einer Prüfungsbehörde zur Prüfung vorgelegen; hiervon ausgenommen sind Prüfungsleistungen, für die in der Modulbeschreibung ausdrücklich andere Regelungen festgelegt sind.

Mir ist bekannt, dass die Zuwiderhandlung gegen den Inhalt dieser Erklärung einen Täuschungsversuch darstellt, der das Nichtbestehen der Prüfung zur Folge hat und daneben strafrechtlich gem. § 156 StGB verfolgt werden kann. Darüber hinaus ist mir bekannt, dass ich bei schwerwiegender Täuschung exmatrikuliert und mit einer Geldbuße bis zu 50.000 EUR nach der für mich gültigen Rahmenprüfungsordnung belegt werden kann.

Ich erkläre mich damit einverstanden, dass diese Prüfungsleistung zwecks Plagiatsprüfung auf die Server externer Anbieter hochgeladen werden darf. Die Plagiatsprüfung stellt keine Zurverfügungstellung für die Öffentlichkeit dar.

Münster, 18.7.2026

(Ort, Datum)

A handwritten signature in black ink, consisting of a large, stylized 'H' followed by a series of loops and a final horizontal stroke.

(Eigenhändige Unterschrift)